分类号：_____　　单位代码：10300

密　级：_____　　学　　号：20211249676

南京信息工程大学

硕士专业学位论文

论文题目：基于小样本学习的频谱管控关键技术研究

申请人姓名：	程润梦
指 导 教 师：	朱艳萍 张建照
类 别 名 称：	电子信息
领 域 方 向：	通信工程（含宽带网络、移动通信等）
培 养 学 院：	电子与信息工程学院
提 交 时 间：	2024 年 6 月 7 日

二〇二四年六月

中国知网　https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状及发展动态.....3
1.2.1 频谱管理架构演进.....3
1.2.2 频谱接入技术研究现状.....4
1.2.3 频谱接入技术研究现状.....8
1.3 论文结构安排.....10
1.3.1 主要研究内容.....10
1.3.2 主要创新点.....12
第二章 基于迁移学习的时间卷积网络频谱预测方法.....14
2.1 引言.....14
2.2 系统模型.....15
2.2.1 问题建模.....15
2.2.2 数据集.....16
2.2.3 相关性分析.....18
2.2.4 时间卷积网络.....19
2.3 提出的预测模型.....21
2.3.1 基于自迁移时间卷积网络的频谱预测模型.....21
2.3.2 基于迁移的小样本学习频谱预测模型.....21
2.3.3 算法复杂度分析.....23
2.4 仿真与结果分析.....23
2.4.1 仿真设置与评估指标.....23
2.4.2 仿真结果分析.....24
2.5 本章小结.....26
第三章 基于知识蒸馏的小样本频谱预测方法.....28
3.1 引言.....28
3.2 知识蒸馏频谱预测模型构建.....29
3.2.1 知识蒸馏学习.....29
3.2.2 双分支学生网络.....30
3.3 提出的小样本预测方法.....31
3.3.1 所提预测模型.....31
3.3.2 TCN-KD 算法流程.....32
3.3.3 算法复杂度分析.....34
3.4 仿真与结果分析.....34

中国知网 https://www.cnki.net

3.4.1 仿真设置与评估指标.....34
3.4.2 仿真结果分析.....34
3.5 本章小结.....38
第四章 基于预测的深度强化学习频谱接入方法.....40
4.1 引言.....40
4.2 系统模型与问题建模.....41
4.2.1 系统模型.....41
4.2.2 问题建模.....42
4.3 算法设计.....43
4.3.1 深度强化学习.....43
4.3.2 基于预测的接入优化方法.....44
4.3.3 算法流程.....46
4.4 仿真与结果分析.....47
4.4.1 仿真设置与评价指标.....47
4.4.2 仿真结果分析.....48
4.5 本章小结.....51
第五章 总结与展望.....52
5.1 论文工作总结.....52
5.2 展望.....53
参考文献.....54

中国知网 https://www.cnki.net

摘要

随着 5G、物联网等新兴技术不断涌现，用频需求与有限频谱之间矛盾日益加剧，数据采集设备的不确定性以及复杂用频环境导致样本稀缺问题逐渐凸显。从频谱分配角度，当前优质低频段已划分完毕；从频谱利用角度，大部分频段的利用率还有待提高。针对复杂电磁频谱环境中样本稀疏和当前频谱利用率不高问题，本文重点研究了小样本情况下频谱预测技术和多用户多信道场景下的动态频谱接入问题，论文研究工作及其创新性主要包括以下三个方面：

1) 针对实测频谱数据中时间相关性挖掘问题，构建了一种基于时间卷积网络的自迁移频谱预测模型。该模型在充分利用历史频谱数据时间相关性的基础上，避免了因扩张因子过高造成隐藏层遗漏问题，通过动态时间规整分析不同频段的相似性并讨论迁移学习对预测性能的影响。仿真结果表明，基于自迁移的时间卷积网络相比原始网络在误差评价指标均方根误差和平均绝对误差上分别降低了 5.8%、4.2%。通过对不同频段的小样本数据进行迁移学习，验证了在相似性差距较小情况下，使用迁移学习在一定程度上能够有效提高预测性能。

2) 针对频谱预测模型在训练时参数过多、训练样本需求量较大问题，提出了结合知识蒸馏和时间卷积网络的轻量化频谱预测方法。以预训练的自迁移时间卷积网络为教师网络，以双分支神经网络为学生网络，通过知识蒸馏将复杂模型知识传递给双分支神经网络，减少模型待训练参数，提升预测精度。仿真结果表明，所提方法相比于长短时记忆网络预测，在样本充足情况下精确度提升了 19.5%，减少了 71.1%待训练参数。此外，在历史数据稀缺情况下，与门控循环单元相比预测准确性提高了 17.9%。

3) 针对次用户过度依赖频谱感知检测频谱空洞问题，提出了一种基于预测的深度强化学习频谱接入方法。通过主动预测未来频谱状态，使模型更关注频谱使用长期趋势，帮助智能体快速地学习和优化接入策略，并考虑次用户传输速率和主用户受干扰情况同步优化信道选择和传输功率。仿真结果表明，所提算法在传输速率、公平性和降低干扰方面表现出明显优势，相较于没有预测的接入算法，所提算法系统传输速率提高了 14.5%，并且在相同回报值下，搜索次数减少了 56.2%。

关键词：电磁频谱管控，小样本学习，频谱预测，动态频谱接入

中国知网 https://www.cnki.net

Abstract

With the advent of emerging technologies such as 5G and the Internet of Things, the conflict between frequency demand and limited spectrum is becoming increasingly prominent. The uncertainty of data collection equipment and the complex frequency environment have led to the problem of sample scarcity. From a spectrum allocation perspective, the current high-quality low-frequency bands have been already allocated. From spectrum utilization perspective, the utilization ratio of most frequency bands still needs to be improved. To address the problems of small-sample and low spectrum utilization in spectrum environments, this thesis primarily focuses on spectrum prediction technology in few-shot sample scenarios and the dynamic spectrum access problem in multi-user and multi-channel scenarios. The research work and innovation mainly include the following three aspects:

1) A self-transferring spectrum prediction model based on temporal convolutional network was constructed to address the problem of mining time correlation in measured spectrum data. This model fully utilizes the time correlation of historical spectrum data and avoids the problem of hidden layer leakage caused by high expansion factors. Analyze the similarity of different frequency bands through dynamic time warping and discuss the impact of transfer learning on predictive performance. The simulation results show that the temporal convolutional network based on self-transferring has a certain performance improvement compared to the original network, with a reduction of 5.8% and 4.2% in the RMSE and MAE, respectively. By conducting transfer learning on few-shot data from different frequency bands, it has been verified that using transfer learning can effectively improve prediction performance to a certain extent when the similarity difference is small.

2) A TCN-KD spectrum prediction method combining knowledge distillation and temporal convolutional network is proposed to address the problems of excessive parameters and large training sample requirements in spectrum prediction models during training. Using pretrained self-transfer temporal convolutional network as the teacher network and two-branch networks as the student network, complex model knowledge is transmitted to the two-branch network through knowledge distillation, reducing the number of model parameters to be trained and improving prediction accuracy. The simulation results show that compared to

中国知网 https://www.cnki.net

long short-term memory, the proposed method enhances accuracy by 19.5% and reduces the number of training parameters by 71.1% when sufficient samples are available. In addition, in the case of scarce historical data, the prediction accuracy improved by 17.9% compared to the gated recurrent unit.

3) A deep reinforcement learning spectrum access method based on prediction is proposed to address the problem of secondary users relying excessively on spectrum perception to detect spectrum holes. The method actively predicts the future spectrum status, encouraging the model to focus on the long-term trend of spectrum usage, helping intelligent agents quickly learn and optimize access strategies, while simultaneously optimizing channel selection and transmission power. These optimizations take into account the transmission rate of secondary users and the interference with primary users. Simulation results demonstrate that the proposed algorithm exhibits significant advantages in transmission rate, fairness, and interference reduction. Compared to system without prediction, the reward increased by 15.5%, and the search frequency decreased by 56.2% for the same return value.

Key words: Electromagnetic spectrum management, Few-shot learning, Spectrum prediction, Dynamic spectrum access

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

随着无线通信技术的飞速发展和人们对无线通信业务需求的不断增长，无线终端设备数量呈现指数型增长。在民用领域，智能手机、平板电脑等移动终端的大量普及使得移动通信产业对频谱需求越来越大。尤其在 5G 移动终端的应用方面，超高速、低时延、超可靠的特性给 5G 用户带来优良视觉和通信体验，进一步刺激了智能制造、车联网、智能物流等行业发展，但随之而来的是频谱资源短缺问题。面对拥挤的频谱资源，运营商只能寻求更高频段的毫米波技术来解决用频问题。在军事领域，一方面，未来战场将配备大量用频设备，例如无人机、智能传感器、无线通信设备以及雷达系统等等，使得未来战场将具有装备数量多、电磁信号密集、电磁环境变化节奏快的特点；另一方面， 电磁频谱作为战场信息和战场态势获取与传输的重要载体，对未来战场塑造态势、掌握信息起着越来越重要作用[1]。在俄乌冲突中，乌军在通信系统受到俄军严重压制情况下，借助“星链”低轨互联网卫星星座进行信息传输，成为乌军保持指挥控制、情报保障和军事打击的重要依托。总之，频谱资源作为一种重要的不可再生资源已经成为支撑无线通信军民领域发展的战略资源。

从频谱分配角度，当前频谱划分主要是工业和信息化部向四大运营商发放频率使用许可，运营商为了提供高质量和高可靠的通信服务，通常以高昂的频段占用费为代价，在授权频段上规范和部署无线通信网络。目前，优质的低频段频谱资源已基本划分完毕。从频谱利用角度，许多相关机构通过对频谱资源的测量发现，只有在很少的地区和时间段内分配的频段得到充分的利用。大部分频段利用率并不高，3GHz 以下频段的利用率不足 30% [2][3]，即使在纽约、芝加哥等大城市频谱资源利用率大部分时间仍依然低于 40%，表明现有已划分频谱资源并未得到充分利用[4]。与授权频段不同，在 2.4GHz 等非授权频段，用户只需在遵守信道占用时间、发射功率等监管要求，确保公平共享频谱资源的前提下便可以免费使用频谱。非授权频段将作为授权频段业务性能的补充，同时 LTE-U 等利用非授权频段的业务模式及其标准化正有序推进[5]。

针对频谱资源匮乏和频谱利用率不高问题，Joesph Mitola 博士提出了认知无线电技术(Cognitive Radio, CR)，即在整个通信过程中，CR 具备学习能力，能够与周围环境

中国知网 https://www.cnki.net

进行交互[6]，在不给主用户带来有害干扰的前提下自适应的占用即时空闲的频谱资源，从而使频谱资源的使用由静态分配转变为动态接入，CR 从功能上可以分类为频谱感知、频谱决策、频谱共享和频谱切换四个部分，最终实现频谱资源的利用。但同时认知无线电网络存在的固有问题还有待优化。例如，对进行宽频带频谱感知时，由于频带范围广泛，需要耗费大量时间和能量。在进行频谱接入时，为了保证分配的准确性，需要较长的处理时延。同时，频谱接入过程较为被动，次用户往往关注瞬时状态，对信道中频谱状态反应相对短视。频谱预测技术的出现可以改善上述问题，通过历史频谱使用信息来预测未来频谱状态从而辅助完成认知无线电的功能，例如在频谱感知阶段，优先感知空闲频谱，减少能量的损耗和降低感知的时延以提高数据吞吐量和频谱利用效率；在频谱接入阶段，认知用户在进行接入时根据预测的结果采取最佳的接入策略，减少频谱切换次数，降低对主用户产生的干扰。频谱预测技术可以有效改善认知无线通信系统吞吐量，降低系统频谱感知的能量消耗，最终提高频谱利用率，缓解目前频谱资源紧张问题。图 1-1 给出了频谱预测在认知无线电中具体作用。

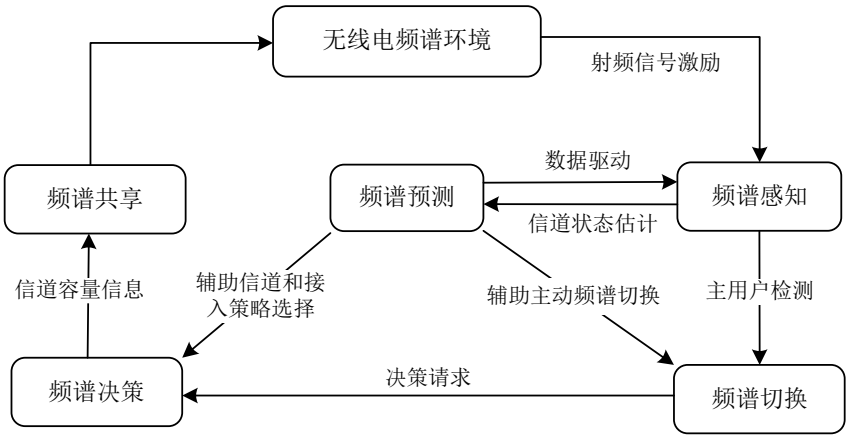

图 1-1 频谱预测在认知无线电中作用

近年来，深度学习技术快速发展并广泛应用。深度神经网络凭借着良好的非线性拟合能力，在复杂任务中具有超越传统计算模型的性能。美国国防部高级研究计划局（Defense Advanced Research Projects Agency, DARPA）于 2019-2023 财年将人工智能技术作为基础研究投入重点之一，反映了其对人工智能在国防和军事领域的重要性和潜在价值的认识，有效推动了人工智能技术发展。为了解决日益拥挤的无线频谱环境下的频谱管理问题，DARPA 发起了频谱协作挑战赛（Spectrum Collaboration Challenge, SC2）[7]，旨在研究如何利用人工智能等先进技术，在频谱拥挤的环境中实现无线设备的动态接入，以满足军方和日益增长的频谱需求。参与者提出了大量创新的频谱协作

中国知网 https://www.cnki.net

算法和技术，并在特定的测试场景下进行了验证和评估。近年来，业界开始探索使用强化学习技术来提高频谱利用率，该类方法与大规模数据驱动的学习方法不同，其以无线通信实体作为研究对象，将其看作智能体，把所处的无线设备通信场景视为环境，通过在与环境的不断交互过程中，自主确定最优信道接入、功率分配、资源分配等策略。同时，强化学习技术也能适应动态变化的用频环境，减少用户之间冲突造成的干扰。通过在频谱管理和无线通信领域积极探索和发展人工智能技术的应用，为解决现实世界中频谱管理问题提供了创新的解决方案。

综上所述，在复杂电磁频谱环境中共享有限的频段，导致日益增长的用频需求和稀缺频谱资源的矛盾愈发显现，深度学习技术的发展为提高频谱资源利用率提供了可能，针对用频行为的智能频谱预测和动态频谱接入具有重要的研究意义。

本论文着眼于电磁频谱管控与人工智能交叉领域，针对频谱预测和频谱接入展开深入研究，重点基于迁移学习和知识蒸馏的小样本频谱预测方法，同时针对基于预测的动态频谱接入作进一步探讨。

1.2 国内外研究现状及发展动态

1.2.1 频谱管理架构演进

电磁频谱管理的起源可追溯到军事领域，在军事行动中，武器装备的协调高度依赖电磁频谱。在现代战争中，电磁频谱是支持各种作战方式的关键媒介，其重要性无法被其他媒体替代。军事强国们深知电磁频谱的重要性，大力发展相关技术和武器装备，他们认为电磁频谱与火力、机械动力等传统战斗力形式同等重要。可以看出，电磁频谱不仅是现代战争的战略资源，也是国家安全的重要保障[8]。加强电磁频谱管理和提高利用效率已成为各国的重要任务。美军的电磁频谱管理以军事行动为指导，重视无线电频谱的战略地位。通过先进的频谱管理技术和手段，确保在战争中占据优势。接下以美国为例，介绍频谱管理架构的演进。

美国联邦通信委员会(Federal Communications Commission, FCC)发布了《关于使用认知无线电促进电磁频谱利用的通知》[9]，该通知对《FCC 规则的第 15 章》进行了修订，规定在设备具备认知无线电功能时，无线终端即便没有无线许可，也可在授权频段内使用无线频带，为认知无线电在法律层面上提供了支撑。 2004 年 11 月，基于认知无线电的无线标准 IEEE802.22 无线区域网的工作组成立，旨在利用空闲的无线频谱

中国知网 https://www.cnki.net

资源，如广播电视频段进行宽带无线接入。

美国国防高级研究计划部署了一项重要通信技术研究项目-XG 计划[11]，该计划致力于推动下一代无线通信技术的发展，又被称作动态频谱接入网络。XG 计划通过深入研究认知无线电的核心系统方法和关键技术，目标是实现动态频谱的高效利用，以支持美军在复杂电磁环境中的通信需求。为此，该计划为无线电通信系统提供一套设备使无线通信电台能在规定范围内动态利用暂时未使用的频谱资源，且不会与正常工作的无线电台产生冲突，可提升目前频谱利用率近 10 倍。XG 网络可工作在多个授权频段和非授权频段，并与工作在相应频段的主网络共存。该网络有集中式、Ad Hoc、授权网络接入三种接入方式。同时 XG 计划还起草了一份建议请求书，用于协调不同无线电厂商和研究院所之间的合作。

国防频谱组织提出了长期计划全球电磁频谱信息系统[10]（Global Electromagnetic Spectrum Information System，GEMSIS），GEMSIS 是一个旨在有效管理和 利用全球电磁频谱资源的倡议，其目的是建立一个集所有频谱管理作业为一体的系统，以此来提高各个政府部门及军队的协同工作能力。通过收集、整理和分享全球范围内的电磁频谱信息，实现频谱管理由静态指配策略向自适应转型。GEMSIS 是一个长期频谱转型战略规划，采用分阶段实施的方法，以配合频谱管理的转型，共分为五个阶段。2006 年-2007 年，此时架构为基础体系架构，各个系统间相对孤立；2007 年-2012 年，该系统建立了标准的数据共享框架，初步构建了频谱管理网络，并开始具备频谱管理作战规划能力；2012 年-2016 年，系统具有有限的自适应频谱管理能力；2016 年-2020 年，系统已能够实现共享频谱态势感知，并全面整合自适应频谱管理的功能。2020 年-2025 年，系统特点是实现认知自同步的频谱利用能力。

无线电环境地图[12]（Radio Environment Map，REM）最早由美国国家电信和信息管理局（NTIA）提出，其以地图形式展示地理位置、频谱信息、无线电监管制度与政策、无线电设备的功能等信息。通过从过去经验和当前结果的学习和推理，使认知无线电网络的性能大幅度改进的同时辅助频谱管理。

1.2.2 频谱预测技术研究现状

1.2.2.1 频谱预测研究现状

频谱预测技术在认知无线电技术中发挥重要作用。在频谱感知阶段，次用户需随时处于监测状态以便及时避让主用户并寻找适合通信的空闲信道。然而，在感知过程

中国知网 https://www.cnki.net

中的信道感知顺序决定了传输容量和通信时延。频谱预测技术的出现可以通过分析空闲频谱特征参数和授权用户使用规律，帮助次级用户做出频谱决策并选择最佳方案，从而减少通信时延，提高频谱利用率。在频谱接入阶段，通过对未来一定时间内频谱使用情况进行预测，帮助优化频谱资源的管理和分配。近年来，科学家和技术学者一直致力于推动频谱预测技术的研究，并取得了许多成果。下面将从时间域、频域和空间域三个角度来介绍频谱预测目前进展。

在时间域中，频谱预测技术利用历史频谱数据的周期性变化推断未来频谱状态。现有预测模型主要分为统计学方法和深度学习方法。文献[13]提出了使用二进制时间序列进行频谱占用表征和预测，选择数学性质较好的 sigmoid 函数将期望值控制在[0,1]之间。然而对于非确定性频谱数据，其预测准确率并不理想，增加模型 d 阶数可以改善此状况，但需以指数倍增加的参数量为代价。文献[14]提出了一种主动式频谱切换算法，使用隐马尔可夫模型（Hidden Markov Model, HMM）来建模和预测许可信道的无线电频谱占用情况，在假设主用户信道状态符合泊松分布的前提下动态的分配许可频段。文献[15]提出了一种基于 HMM 的信道状态预测器，该预测器能够依据过去信道状态信息来预测下一个信道状态。然而，该方法主要针对特定服务场景下的主用户进行仿真实验，在实际动态频谱环境中的适用性受到一定限制。文献[16]在传统门限阈值的基础上，创新地将自动链路技术与频谱预测相结合，提出一种更加精确的高斯混合模型-隐马尔可夫模型门限阈值方法，这种方法能更准确地判断信道空闲或占用状态。同时为了缩短链路建立时间，引入线性预测算法作为预测上下界的补充，并在此基础上探讨了频谱预测算法在缩短链路建立时间方面的上限和下限。近年来，随着人工智能技术的发展，深度学习凭借其强大的计算分析能力在各个领域得到了迅速的发展，在频谱预测领域也取得了一定的成就。文献[17]提出了具有可解释特征的频谱异常检测器，这是一种基于对抗性自动编码器（Adversarial Autoencoder, AAE）的异常检测器，适用于使用功率谱密度（Power Spectral Density, PSD）数据进行无线频谱异常检测。文献[18]将许可射频信号(RF)建模为多元混沌时间序列作为人工神经网络的输入，预测演化 RF 的时间序列来决定未经许可用户是否可以利用该频段。文献[19]构建了基于长短时记忆神经网络（Long Short-Term Memory, LSTM）的预测模型，研究不同深度和宽度对 LSTM 网络预测精度的影响，与反向传播算法（Backpropagation Algorithm，BP）进行对比取得了良好的效果。

在频域中，频谱预测通常通过评估相邻信道间的频谱占用相关性来预测未感知信

中国知网 https://www.cnki.net

道的频谱状态，这种相关性在同一服务的不同信道间扮演重要角色。具体而言，两通道之间的相关性越强，频谱预测的准确性就越高。文献[20]创新性的提出了信道可用性向量的概念，利用频谱相关性来推断其他信道的可用性，通过将吞吐量优化问题转换为马尔可夫决策过程来提高频谱利用率。文献[21]将相邻频带一起建模，不仅考虑了频域的相关性，而且采用不需要通信环境先验知识的经典自回归模型来降低模型的复杂度，该算法对于确定性使用模式表现良好。文献[22]提出频谱预测碰撞避免算法，使用卷积神经网络（Convolutional Neural Network，CNN）来预测相邻频谱使用情况，通过调整自身行为增加多频时分多址网络以及其他周围网络的整体吞吐量。文献[23]考虑频谱数据异常和频谱数据缺失两种情况，提出时间频谱预测框架并开发矩阵补全优化算法。随后，学者们进一步研究并丰富矩阵补全算法[24][25]。文献[26]针对现有频谱预测算法逐时隙预测导致时效性不足问题，提出了一种新的预测方法，该方法能同时预测一段时间内多个频谱点超前状态。构建多个残差网络模块，每个模块专注于从不同时间尺度数据中提取关键特征，再利用卷积神经网络融合残差模块的输出进行时频预测。文献[27]通过 2D-LSTM 模型利用时频相关性进行预测，相比于只用时间域模型，该方法在精度和计算复杂度方面都有所提高。在此基础之上，文献[28]替换了预测模型，首次在频谱预测领域采用深度强化学习算法，通过定义深度强化学习的奖励函数、状态以及动作空间，使其在现实世界中以在线方式动态地执行频谱预测任务。

在空间域中，需要考虑次要用户的位置和运动预测频谱状态。文献[29]在静态频谱环境中，利用干扰空间的变化来推断不同次要用户节点所经历的干扰功率。文献[30]将静态模型扩展到动态移动模型，考虑节点的移动性和主用户的活动，克服传统模型的静态缺点，采用贪心算法（Greedy Algorithm, GA）和公平算法（Fair Algorithm, FA）两种频谱分配算法，来提高频谱利用率和公平性。文献[31]使用预训练递归神经网络来捕获频谱数据的时-空-频的相关性，从时间接近、日周期和周趋势三个组件建模，采用参数矩阵的融合方法执行最终预测。

1.2.2.2 于小样本学习频谱预测研究现状

现有研究大多数假设模型具有理想的、完备的训练样本，然而在实际应用中，当认知无线电设备频繁切换目标频率或复杂的电磁环境发生变化时，期望历史数据的相对缺乏难以保证模型依然具有良好的性能。同时，现有网络为了提高模型精度，往往复杂度较高，有限的存储和计算资源使得模型难以落实到实际部署。面对数据采集设备的不确定性以及无线电磁频谱空间的开放性带来的挑战，研究人员也开始关注样本

中国知网 https://www.cnki.net

不完备及样本不充足的情况。

小样本频谱预测结合了传统频谱预测技术和小样本学习的方法，旨在通过少量的样本学习到具有良好泛化性能的预测模型。对于解决实际应用中频谱预测中数据不足问题起到重要作用，在资源受限环境中展现巨大潜力。如图 1-2 所示，针对目前小样本学习技术的研究本文从数据增强、元学习、迁移学习角度进行阐述。

从数据增强角度，文献[32]使用生成对抗网络（Generative Adversarial Network, GAN）进行数据增强，该方法利用与目标频段相似的历史频谱数据对 GAN 网络进行预训练，将少量目标数据输入预训练网络进行数据增强，并使用基于深度迁移学习和 GAN 网络生成的相似数据对时-频残差网络进一步训练。然而，该方法构造的网络结构复杂且难以训练，需要更多的计算资源和时间来确保网络的性能。文献[33]考虑到实际监测数据不足对深度学习模型性能的影响，提出基于迁移学习的频谱数据扩充的知识共享框架，该框架通过利用来自多个基站或者频谱数据来增强模型性能。

从元学习角度，文献[34]将元学习方法和迁移学习结合进行频谱预测。采用预训练 VGG16（Visual Geometry Group 16-layer）模型对不同频段的数据进行分析，明确频段之间的差异，构造元学习数据集以找到模型参数最优分布。实验表明，基于元学习和迁移学习的方法可以在少量频谱数据的情况下有效地预测目标频段。

从迁移学习角度，其基本思想是在包含大量样本的数据集上训练模型，将已经训练好的模型迁移到含有少量样本的目标域中进行训练。从源域中学习到的知识和特征可以帮助目标域中训练模型的预测和分类。迁移学习可以有效减少模型对大规模数据再训练的时间消耗和对计算能力的要求。同时，它可以有效解决频谱预测模型冷启动问题，弥补模型训练初期数据不足的情况。由于不同时间序列的频谱状态之间的相关性是不同的，随意选择频谱数据进行预训练可能会导致模型负迁移，影响预测或分类效果。为了减小源域数据和目标域数据之间的差异，在迁移学习中通常采用多种策略描述这两个域之间的不相似性，以便在保持源域知识的同时，更好适应目标域的特点。具体而言，文献[34]通过分析频带业务活动和基于动态时间规整的频率点间的距离，计算频谱之间的相似性，并利用迁移成分分析（Transfer Component Analysis, TCA）来探索对跨频带预测中迁移学习性能的主要影响因素。文献[35]使用预训练 VGG 模型对不同频段的数据进行分析，明确不同频段之间的差异性和相似性。此外，文献[36]提出了一种基于元学习和迁移学习的小样本学习方法，旨在提高太阳射电频谱图像的分类性能。该方法使用太阳射电频谱数据集，其中频谱图像来自中国太阳射电宽带动态频谱

中国知网 https://www.cnki.net

仪（Solar Broadband Radio Spectrometer，SBRS）。该方法将 SBRS 采集的数据转换为灰度图像，图像的横轴表示采样时间，纵轴表示采样频率，而图像的灰度值代表太阳射电的辐射强度。

知识蒸馏也是一种迁移学习方法，其核心在于将复杂且精确度性较高的教师模型的知识传递给结构简单的学生模型，学生模型能吸收并利用教师模型的丰富经验，从而提高自身性能。教师模型是一个结构复杂，性能较好的神经网络，能够捕捉学生模型难以捕获的特征，学生模型通过学习教师模型的知识，在保持相对较高的性能情况下，减少模型的复杂性和对计算资源的需求。文献[37]提出一种从无标签小样本知识提取方法，旨在保持模型轻量化的同时提高训练效率，将原始网络称为教师网络，压缩后的网络称为学生网络。在学生网络的每层末端增加 1×1 的卷积层，并通过估计这些层的参数，使学生网络输出和教师网络相匹配。通过知识蒸馏，学生模型可以更好地泛化和适应少量样本，提高模型在小样本任务上的性能。未来随着教师模型的改进以及设计更加有效的知识蒸馏策略，基于知识蒸馏的小样本学习将有很大的发展空间。

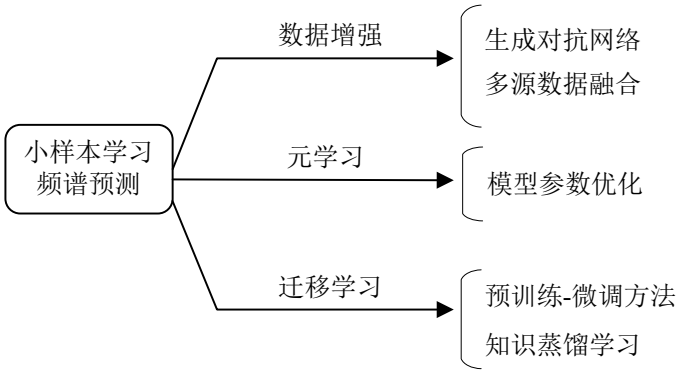

图 1-2 小样本学习频谱预测概览

1.2.3 频谱接入技术研究现状

频谱接入模型可以广泛定义为两类，分别是静态模型和动态模型。静态模型主要是政府机构通过的拍卖方式向运营商分配长期持续的频谱使用许可，运营商划定的用户被称为许可用户或主用户（Primary User, PU）。PU 在任何时间都有所分配频谱的独占权，然而这种分配策略不够灵活应对不同场景的用频需求，且频谱利用率不高，促使次用户（Secondary User，SU）与主用户共享未充分利用的许可频段来解决此类问题。

随着动态频谱接入的概念被提出，国内外学者开始相关领域的理论研究。如图 1-3 所示，早期研究主要侧重使用马尔可夫算法、博弈论算法、遗传算法等传统算法。文献[38]提出一种基于连续时间马尔可夫链的主次用户动态频谱接入的通用框架，旨在获

中国知网 https://www.cnki.net

得次用户最优频谱接入概率。文献[39]提出了一种基于马尔可夫链和频谱调制频谱编码模型（MC-SMSE）的频谱接入框架，该框架利用马尔可夫预测未来频谱状态，然后根据预测结果，应用频谱调制频谱编码模型（SMSE）来产生用于频谱接入的叠加和下层波形，显著降低了频谱感知的时间和能量消耗。文献[40]考虑信道质量对频谱接入性能的影响，综合主用户信道占用信息和次用户信道质量信息提出一种基于信道质量门限的策略，提高了用户的吞吐率。文献[41]提出了一种基于博弈论的动态频谱接入算法，该算法在 SU 之间联合执行频谱租赁和干扰缓解，使 SU 能够在动态环境中有效地利用与 PU 共享的许可频谱。文献[42]考虑用户之间的协调，研究了多用户场景中的干扰防御问题，基于马尔可夫博弈框架提出一种多智能体协作抗干扰算法，仿真结果优于基于感知的方法和独立的 Q-learning 方法。

近年来，随着人工智能技术兴起，研究重心开始偏向以强化学习为首的深度学习算法。强化学习（Reinforcement Learning，RL）因其具有良好的环境适应能力被认为是非授权频段动态频谱接入的有效途径。文献[43,44]提出使用 Q-learning 的接入方案，通过次用户与环境的交互获取数据并进行学习，但由于 Q 表固有的局限，难以处理具有较大状态空间的问题。随后，深度强化学习（Deep Reinforcement Learning，DRL）结合深度学习与强化学习，使用神经网络拟合 Q 值，解决了 Q 表占用内存大且搜索困难的问题。文献[45,46]提出使用深度 Q 网络（Deep Q-Network，DQN）进行集中式频谱接入算法，相比于 Q-learning 其状态空间和动作空间进一步完善。然而在集中式接入中，中央控制器需要执行所有运算，一旦单点故障，整个系统可能都无法正常运行，且中央控制器容易成为攻击者目标，安全性和隐私问题难以保障。为此，文献[47]提出分布式深度强化学习来解决多信道、多用户场景下频谱接入问题，各次用户独立且并行的与环境进行交互。文献[48]提出一种基于双深度 Q 网络的分布式频谱接入算法，将主用户行为建模为空闲或繁忙的二进制模型，双深度 Q 网络根据感知结果输出接入信道。文献[49]重点研究博弈论模型下的频谱接入问题，但该方法过度依赖环境知识，当先验知识不足时，模型性能会受到约束。文献[50]首次在频谱接入优化方面引入先验知识，围绕未来快速变化通信网络中的严重干扰问题，对动态频谱接入的先验知识进行建模。提出一种可靠性量化方案指导先验知识在强化学习中的使用，该方法提高了学习效率，为用户更好的适应快速变化的电磁频谱环境提供了解决方案。

综上所述，国内外学者对频谱接入技术的研究取得了大量成果，表明在频谱接入领域中应用强化学习可以有效提高认知无线电网络的适应能力，有效提高用户吞吐量。

中国知网 https://www.cnki.net

考虑到上述研究方法主要依赖频谱感知来检测频谱空洞，在次用户执行感知操作会消耗大量能量，同时感知时间过长会导致频谱利用效率降低、占用系统处理能力等一系列问题。本文提出了一种基于预测的深度强化学习频谱接入方法，通过主动预测未来频谱状态，使模型更关注频谱使用长期趋势，帮助智能体快速地学习和优化接入策略，已达到降低次用户之间干扰、提高系统传输效率等目标。

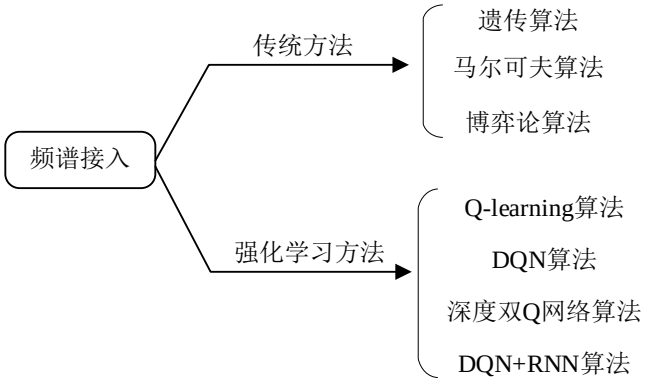

图 1-3 频谱接入的分类概览

1.3 论文结构安排

1.3.1 主要研究内容

本论文主要研究小样本场景下频谱管控关键技术，针对频谱数据时间关联挖掘、现有频谱预测模型待训练参数多、样本需求量大以及频谱接入过度依赖频谱感知检测频谱空洞等挑战。为了解决这些问题，本研究运用迁移学习、知识蒸馏学习、深度强化学习等理论进行算法设计，具体而言，研究了基于时间卷积网络（Temporal Convolutional Network，TCN）的迁移学习频谱预测和基于知识蒸馏的频谱预测，并在此基础上进一步探讨智能频谱接入技术。

首先，根据实测频谱数据的时间上相关性特征，构建一种自迁移时间卷积网络的预测模型，在充分利用历史频谱数据的时间相关性的基础上，通过冻结网络某些层数，只更新部分权重，从而避免因扩张因子过高造成的隐藏层信息遗漏问题，提升频谱预测性能。通过动态时间规整分析不同频段的相似性并讨论迁移学习对预测性能的影响。然后，针对现有复杂模型在训练时参数过多和对样本需求量较大问题，基于自迁移时间卷积网络构造了一个轻量化频谱预测模型。该模型将自迁移时间卷积网络作为教师网络，同时构造了轻量化的双分支神经网络作为学生网络，通过引入知识蒸馏的技术，

中国知网 https://www.cnki.net

将教师网络的知识传递给学生网络，实现对模型参数的压缩。在保持模型性能的同时，降低对训练样本数量的依赖，特别是在样本数量有限的情况下，所提方法依然有优良的性能表现。最后，针对在动态频谱接入场景中可用频谱的动态变化特性，次用户主要依赖频谱感知检测频谱空洞问题，提出一种基于预测的深度强化学习频谱接入模型，通过引入对主用户行为的预测，主动获取未来信道状态，帮助智能体更快的学习和优化接入策略，并根据次用户传输速率和主用户受干扰情况做出信道接入和功率分配的决策，在降低对主用户干扰的同时提升传输速率。论文的研究内容及相互关系如图 1-4 所示。

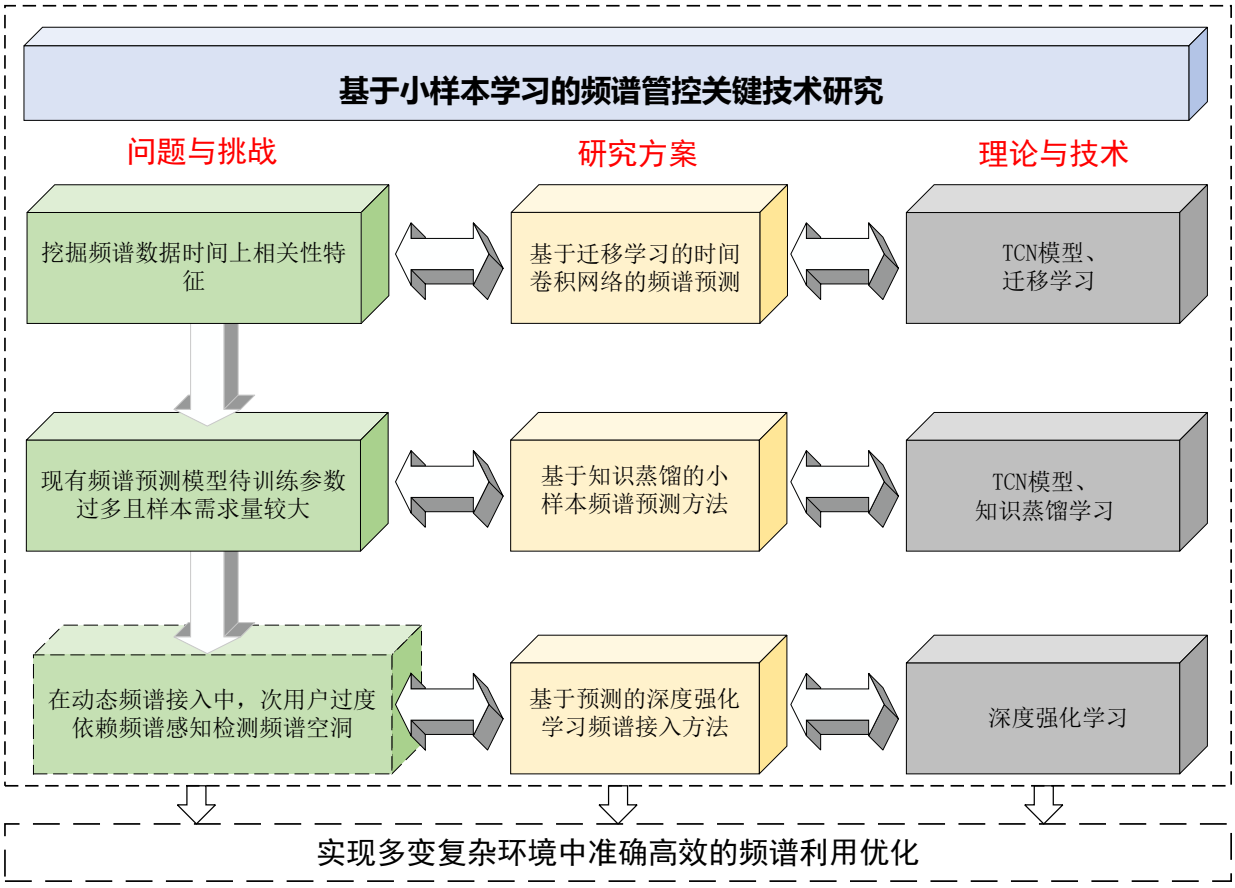

图 1-4 关键技术研究

论文的具体章节安排如下：

第一章主要论述本课题的研究背景与意义，在充分梳理频谱管理架构演变、频谱预测和频谱接入的国内外现状的基础上，对本文的研究内容和论文的组织框架进行归纳总结。

第二章研究了实测频谱数据中时间相关性挖掘问题。首先，对实测频谱数据进行可视化和时间相关性分析。然后，基于时间卷积网络构造频谱预测模型，并在此基础

中国知网 https://www.cnki.net

上利用自迁移技术重新训练部分参数来克服扩张因子过高造成的隐藏层信息遗漏问题。最后，通过动态时间规整技术分析了不同频段之间的相似性，并讨论在小样本情况下使用迁移学习对各频段预测性能的影响。

第三章研究了小样本场景下频谱预测问题。首先，在第二章频谱预测模型的基础上，将预训练的自迁移时间卷积网络作为知识蒸馏模型的教师网络。其次，构造轻量化的双分支神经网络来更高效提取频谱数据特征，并利用知识蒸馏技术将复杂模型知识传递给双分支神经网络，最后在样本充足和历史数据稀缺情况下对模型的性能做进一步探讨。

第四章研究了基于预测的动态频谱接入方法，首先，介绍多用户多信道场景下动态频谱接入系统模型，然后，在前两章关于频谱预测研究的基础上，针对当前频谱接入多采用被动式接入，过度依赖频谱感知检测频谱空洞现状，提出基于预测的深度强化学习频谱接入模型，并综合考虑次用户传输效率和主用户干扰水平。最后，通过实验仿真分析深度强化学习模型的奖励、传输速率、公平性、干扰等性能指标。

第五章总结了全文的研究工作，并对下一步工作进行展望。

1.3.2 主要创新点

本文综合利用时间卷积网络、迁移学习、知识蒸馏、深度强化学习等人工智能前沿技术，论文提出的模型与方法在研究中具有一定的创新与前瞻性。论文的主要创新点如下：

1）针对实测频谱数据中时间相关性挖掘问题，构建了基于时间卷积网络的自迁移频谱预测模型，在充分利用历史频谱数据时间相关性的基础上，避免了因扩张因子过高造成隐藏层遗漏问题，提升了频谱预测性能。通过动态时间规整分析不同频段的相似性并讨论迁移学习对预测性能的影响，验证了在相似性差距较小情况下，使用迁移学习在一定程度上能提高预测性能。

2）针对现有频谱预测模型在训练时参数过多、训练样本量需求较大问题，提出了结合知识蒸馏和时间卷积网络的 TCN-KD 频谱预测方法。以预训练自迁移时间卷积网络为教师网络，以双分支神经网络为教师网络，通过知识蒸馏将复杂模型知识传递给双分支神经网络。实验在样本充足和样本稀缺情况下，均能减少模型待训练参数，提升预测精度。

3）针对可用频谱动态变化，次用户主要依赖频谱感知检测频谱空洞问题，提出了

中国知网 https://www.cnki.net

基于预测的深度强化学习频谱接入模型。通过将主用户未来频谱状态纳入深度强化学习的状态空间，主动获取信道未来状态，提升决策质量和效果。综合考虑次用户传输效率和对主用户干扰水平，同步优化信道选择和功率传输决策，最后通过仿真分析和对比评估了该算法的性能。

中国知网 https://www.cnki.net

第二章 基于迁移学习的时间卷积网络频谱预测方法

在频谱预测中，模型的训练往往需要大量的样本，然而实际应用中，数据收集设备的不确定性、频谱环境的动态变换性、数据收集成本的增加等因素导致模型面临小样本难题。本章在挖掘历史频谱数据时间相关性的基础上，构建一种基于时间卷积网络的频谱预测模型，采用自迁移方法更充分考虑时间域信息在频谱数据中的演变进一步提升预测精度。在样本受限的情况下，利用动态时间规整验证频谱之间的相似性，并讨论迁移学习在不同业务历史频谱数据的频谱预测性能表现。

2.1 引言

频谱预测技术在认知无线电技术中发挥重要作用。在频谱感知阶段，次用户需要检测使用频段以便及时避让主用户并寻找适合通信的空闲频谱。然而，在感知过程中的信道感知顺序决定了传输容量和通信时延。因此，频谱预测技术的出现可以在主动分析空闲频谱特征参数和授权用户使用规律的基础上，帮助次级用户做出频谱决策并选择最优方案，从而降低通信时延，提高频谱利用率。尽管频谱预测技术在近年来仍处于发展阶段，但已经取得了一系列显著成果，包括移动平均自回归模型、隐马尔可夫模型、最小贝叶斯风险、多层感知机、循环神经网络、卷积长短时记忆神经网络等。如文献[51]提出与低通滤波器结合的自回归移动平均模型，从测量数据中提取平均接收功率和断态概率。文献[52]提出一种基于最小贝叶斯的频谱预测策略，以解决感知错误累积导致的频谱预测性能下降问题。文献[53]提出了一种基于自回归模型的简化频谱预测方案，称为前后项自回归模型，旨在提高认知无线电系统中频谱预测的精度和次要用户吞吐量。文献[54]提出基于多层感知机的使用频谱行为学习方法，通过监督学习可以预测未来时隙中不同信道空闲或繁忙状态，是认知无线电节点可以提前创建切换信道列表，而不会中断其正在传输的任务。文献[55]对真实采集的 Wi-Fi 数据进行数据分析和特征挖掘，根据 Wi-Fi 数据特点，开发基于 LSTM 模型的分类预测框架，该框架可以根据 Wi-Fi 数据挖掘的特点和有效的分类算法建立多种分类预测器，根据历史数据特点动态选择相应预测器。这些方法为频谱预测提供了多样化的工具和技术，为实现认知无线电系统中的智能频谱管控和优化奠定了坚实的基础。

上述关于频谱预测的研究都是基于理想化假设进行的，即假定训练样本是充足且完备的。然而，在实际应用中，当认知无线电设备频繁切换目标频率或电磁环境发生

中国知网 https://www.cnki.net

变化时，期望历史数据的相对缺乏难以保证模型具有良好性能。因此，有必要针对稀疏样本情况下频谱预测展开更深入研究，以提高在动态环境下的准确性和鲁棒性。

本章首先分析了实测频谱数据状态演变和时域相关性等频谱特征，在此基础之上对频谱预测相关理论进行探讨。针对实测频谱数据在时间上的相关性，提出了结合时间卷积网络和自迁移技术的频谱预测框架。通过时间卷积网络捕捉频谱数据中时序信息，充分考虑频谱数据在时间维度的动态变化，引入自迁移方法克服时间卷积网络中扩张因子过高造成的隐藏层信息遗漏问题。同时，为了分析不同频段频谱状态演化规律特征，本章利用时间序列分析技术动态时间规整计算各个频段之间的相似性，探讨在样本稀疏情况下迁移学习方法在不同业务频段的频谱预测性能。

2.2 系统模型

2.2.1 问题建模

在典型的集中式认知无线电网络（Cognitive Radio, CR）中，通常由一个融合中心（Fusion Center, FC）和 K 个稀疏分布的次级用户组成。如图 2-1 所示，这些次级用户负责持续检测 N 个频点，并将接收到的信号强度（Received Signal Strength, RSS）发送到融合中心[31,56]，融合中心对收集的数据进行处理得到 N 维频点数据 $\mathbf{D}=\{\mathbf{f}_1,\mathbf{f}_2,...,\mathbf{f}_n,...,\mathbf{f}_N\}$。

为了进行频谱数据的时序预测，需要将原始数据变换为符合模型输入的形式[57]。本章采用长度为 $c+1$ 的滑动窗口对收集的频谱数据 $\mathbf{f}_n$ 进行划分，其中 $c+1$ 为滑动窗口大小。具体地，将前将前 c 个数据 $\mathbf{s}_t=\{x_{t-c+1},x_{t-c+2},...,x_t\}$ 作为输入数据，第 $c+1$ 个数据作为待预测数据 $y_t=x_{t+1}$，因此第 n 个频点的数据可以变换为 $\mathbf{f}_n=\{(\mathbf{s}_t,y_t)\}_{t=1}^{m}$，其中 $m=T-c$。

频谱预测的目标是对于给定的频谱数据 $\mathbf{D}$ 训练一个预测模型，使模型的的预测值 $\hat{y}_t$ 与目标值尽可能接近。频谱预测的目标可以表述为

$$\hat{y}_t=\arg\max p(y_t\,|\,\mathbf{s}_t) \tag{2.1}$$

其中 $\hat{y}_t$ 是期望输出，y_t 是目标输出。预测模型的目标是使预测值 $\hat{y}_t$ 要无限接近目标值 y_t，以实现频谱数据的准确预测。

中国知网 https://www.cnki.net

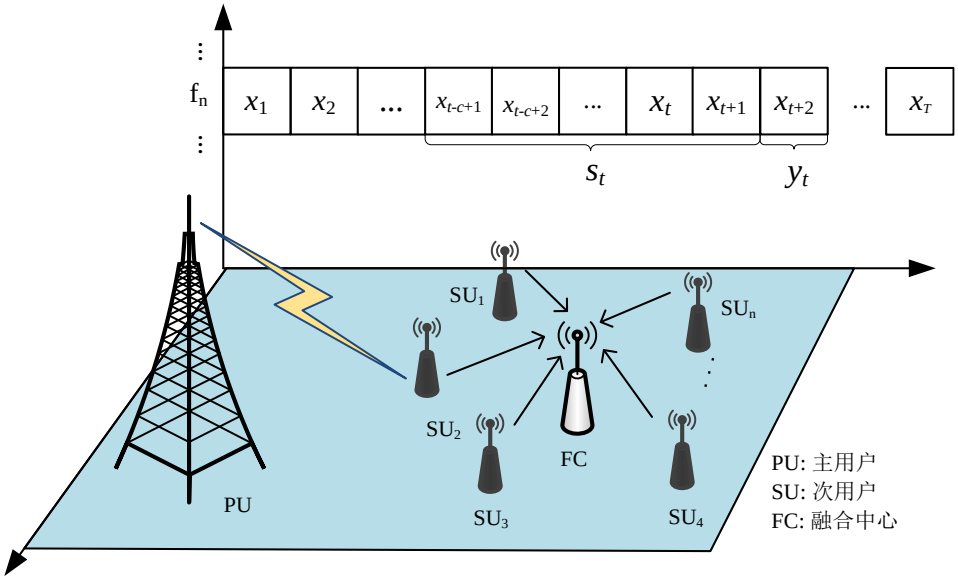

图 2-1 数据来源及划分

2.2.2 数据集

仿真采用的数据来自于德国亚琛工业大学的公开频谱监测数据集[58]，该实测数据集连续不间断测量时间超过一周，包含了从 20MHz 到 6GHz 的所有频段。考虑到数据集的规模较大，选用位于荷兰马斯特里赫特居民区屋顶处的数据中其中与大众生活密切相关的四个子频带，中心频率分别为 770MHz、2250MHz、3750MHz、5150MHz，每个子带的带宽都为 1500MHz，频率分辨率为 200kHz，时间分辨率为 1.8s。

对于该数据集，每半个小时有 1000 个时隙的待处理功率谱密度值，普通计算机的内存和计算能力难以满足处理需求。基于这一考虑，本章取数据集中连续 100 个样本进行处理，又因为数据中功率谱密度的单位是 dBm/200kHz，无法简单的加权平均，所以根据公式 $mW = 10^{\frac{dBm}{10}}$ 将单位换算为 mW，然后在时间维度上连续取 100 个数据做加权平均，利用反向公式 $DBm = 10\log_{10}(mW)$ 得到最终结果。本章选取四个流行业务频段作为实验数据，分别是 GSM 1800 上行频带，GSM 1800 下行频带，GSM 900 上行频带，GSM 900 下行频带，所有数据时间跨度均为 7 天。

图 2-2 展示不同业务频段上实测频谱数据的三维立体图，图 2-3 展示不同业务频段上实测频谱数据的瀑布图。图中清晰地展示了不同业务频段频谱状态演化趋势，在宏观层面上，各个频段业务的频谱状态演化存在显著差异，但在微观上，又呈现出一定的规律性。比如，相比于其他频段，GSM1800 下行频段可以观察到非常强的信号，这是由于该频段在移动通信中用于从基站向移动台发送信号。同时，GSM1800 上/下行频

中国知网 https://www.cnki.net

段呈现出明显的潮汐效应，在图中表现为时间轴上的周期性变化，这是由于白天通信业务量较晚上更大。

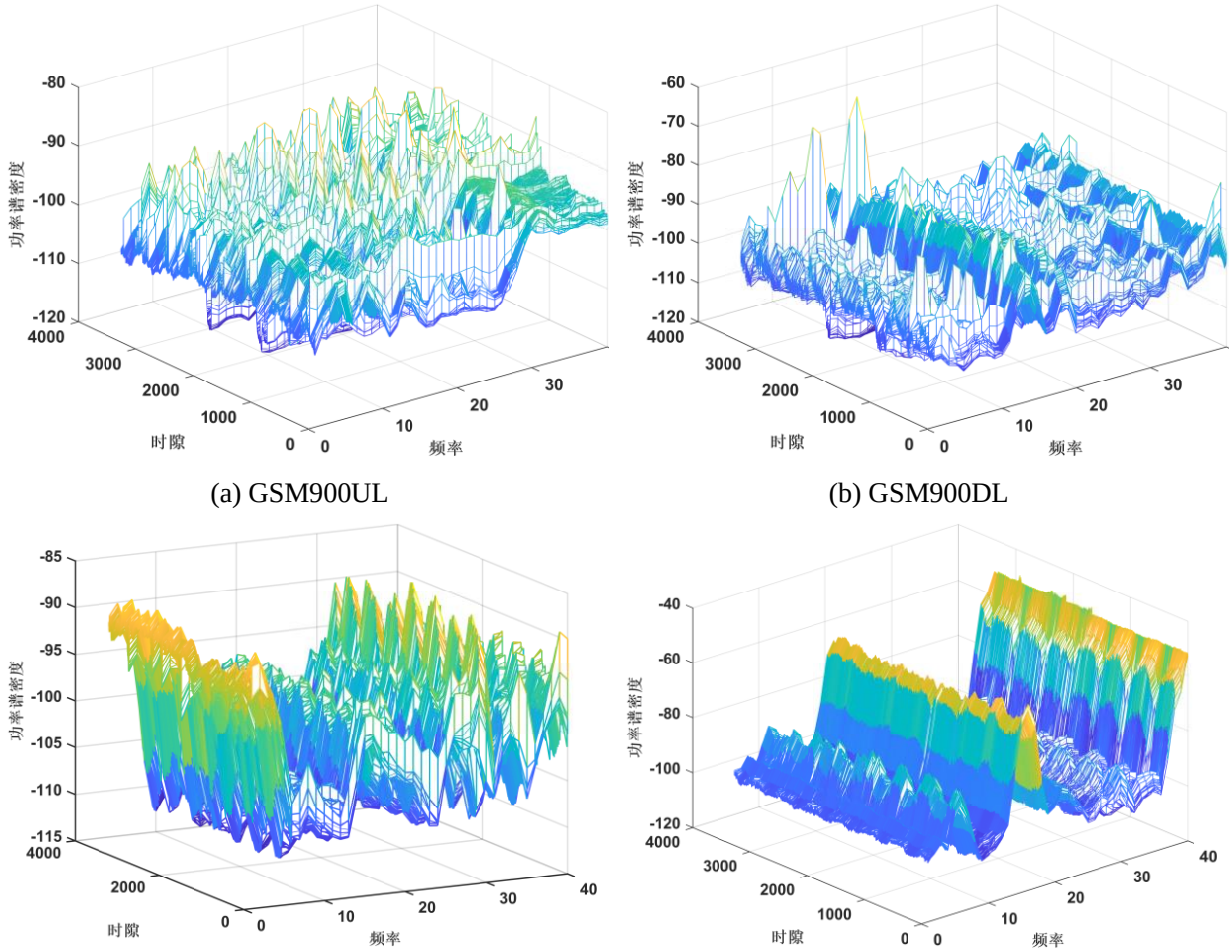

(a) GSM900UL (b) GSM900DL

(c) GSM1800UL (d) GSM1800DL

图 2-2 不同业务频段上实测频谱数据的三维立体图

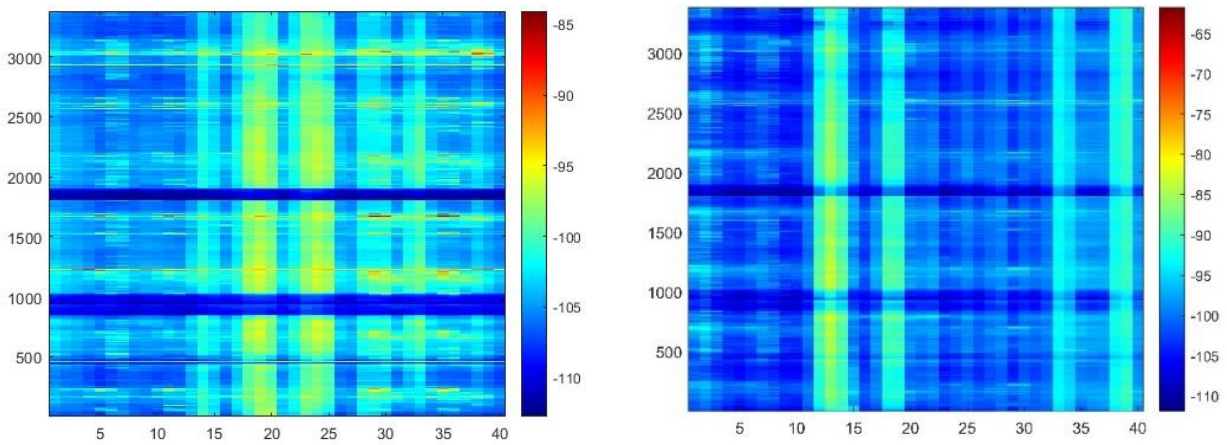

(a) GSM900UL (b) GSM900DL

中国知网 https://www.cnki.net

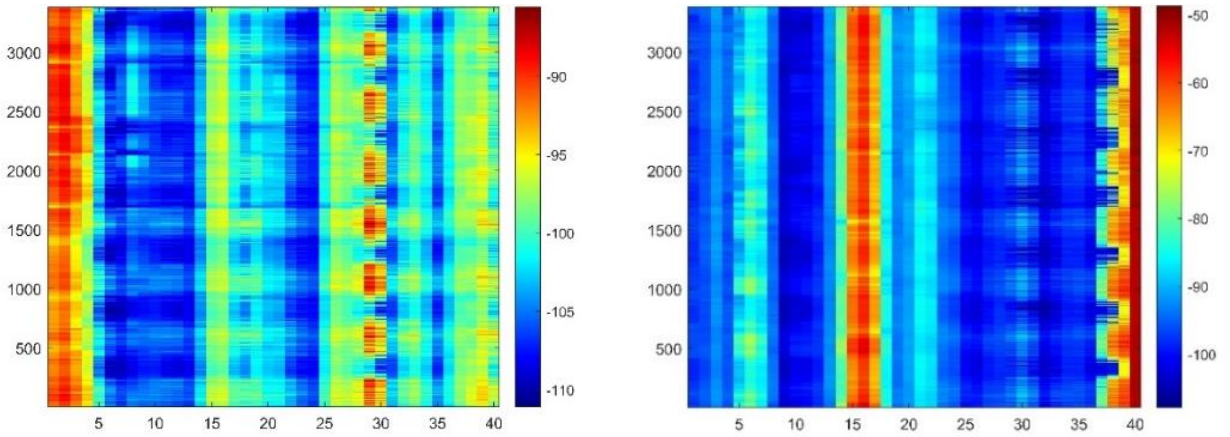

(c) GSM1800UL (d) GSM1800DL

图 2-3 不同业务频段上实测频谱数据的瀑布图

2.2.3 相关性分析

利用相关性系数来分析实测频谱数据的时域相关性是一种常见的方法。对于任意两个随机变量 x_t 和 $x_{t+\Delta t}$，两者的相关性可以通过相关性系数 $\rho_{t,t+\Delta t}$ 表示。相关性系数计算公式为

$$\rho_{t,t+\Delta t} = \frac{\mathrm{cov}(x_t, x_{t+\Delta t})}{\sigma x_t \sigma x_{t+\Delta t}} \tag{2.2}$$

其中，$\mathrm{cov}(\cdot)$ 是协方差函数，表示两个变量联合变化趋势。$\sigma(\cdot)$ 表示样本标准差，表示两变量各自的变换幅度。通常 $\rho_{t,t+\Delta t}$ 的值越大，随机变量 x_t 和 $x_{t+\Delta t}$ 的相关性越大，意味着越有可能通过历史时隙的频谱数据进行频谱预测[59]。图 2-4 给出不同业务上任意两个时隙的频谱状态之间的时间相关性分布情况。对于图中四个业务来讲，时域自相关系数的数值普遍较高，在 GSM1800 上/下行可以比较明确观察到潮汐效应，说明频谱数据在时间维度演变规律具有一定规律性并且和人类活动密切相关。

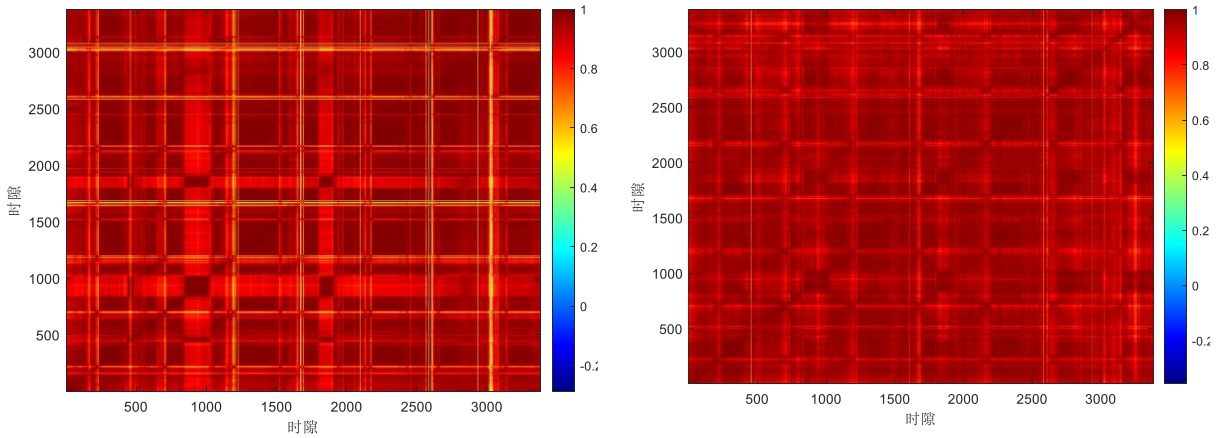

(a) GSM900UL (b) GSM900DL

中国知网 https://www.cnki.net

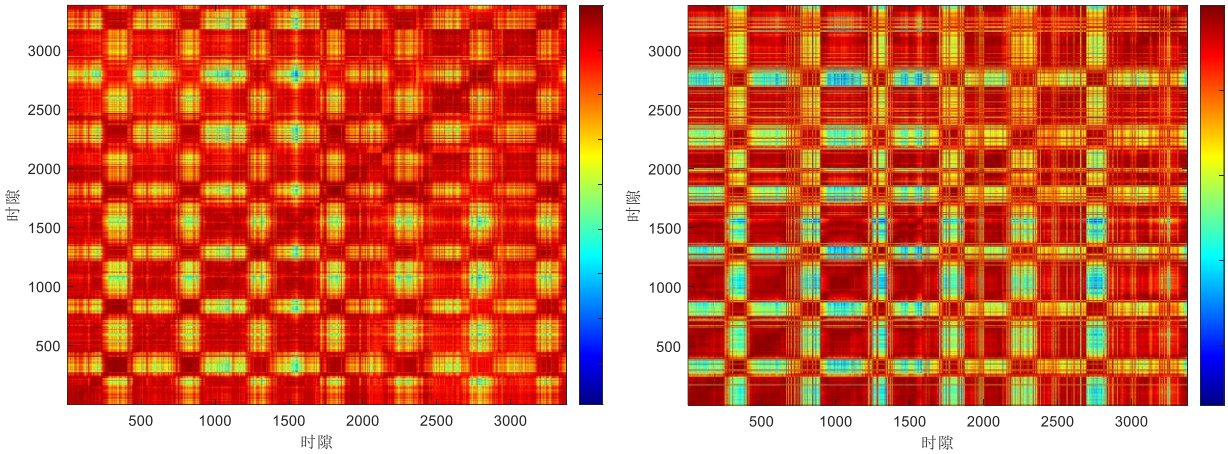

(c) GSM1800UL (d) GSM1800DL

图 2-4 不同业务频段上实测频谱数据的时域相关性图

2.2.4 时间卷积网络

在处理时间序列问题时，传统的循环神经网络（Recurrent Neural Network，RNN）因其具有记忆性在时间序列预测时有良好表现。然而在实际应用中，RNN 在内部设计存在局限性，即一次只能处理一个时间步长，这种串行计算的设计，会导致训练时内存消耗较大。时间卷积网络允许并行计算输出，可以加快模型训练的速度。因此，本章选取时间卷积网络作为预测模型。

传统的卷积神经网络由于卷积核的限制更适用于捕捉图像等局部信息，难以处理时序数据中的长时依赖关系。然而，时间卷积网络是一种结合了卷积操作和长时依赖关系建模的网络结构，可以有效处理时序数据。时间卷积网络主要由因果卷积、扩张卷积以及残差块构成。因果卷积是一个严格的时间约束模型，其单向性保证了只根据历史时刻频谱数据来预测未来频谱值。对于卷积滤波器 $K=\{k_1,k_2,...k_m,...,k_M\}$ 和时序数据 $\mathbf{f}_n=\{x_1,x_2,...,x_t,...x_T\}$，在 x_t 处的因果卷积为

$$(K*D)(x_t)=\sum_{m=1}^{M}k_m\cdot x_{t-M+m} \tag{2.3}$$

受卷积核尺寸的影响，单纯使用因果卷积需要堆叠很多层，为了更好捕捉长期依赖关系，时间卷积网络提出了扩张卷积。图 2-5 展示了扩张卷积的特性，它允许在执行卷积操作时对输入进行间隔采样，采样的速率由扩张因子 d 来控制。最底下一层中，d 的值为 1，表示在输入时对每个点都进行了采样。而在倒数第二层，d 的值为 2，意味着在输入时每隔两点为一个输入单位。通过引入扩张因子控制卷积核中间间隔大小，每层的扩张率以 2 的指数倍增长，可以在不增加参数量的情况下，增加卷积层的感受

中国知网 https://www.cnki.net

野，从而提高对远距离依赖关系的建模能力。高层的卷积核感受野较大，更能够捕捉更长时间的依赖关系。在 x_t 处的扩张因子为 d 的扩张卷积为

$$(K*D)(x_t)=\sum_{m=1}^{M}k_m\cdot x_{t-(M+m)d} \tag{2.4}$$

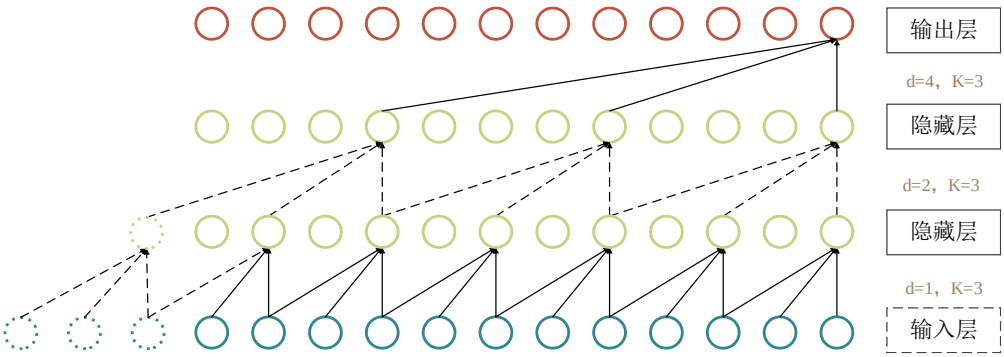

图 2-5 扩张卷积

如图 2-6 所示，典型的残差块包含两个卷积层、一个非线性映射层和跳跃连接。这种设计有助于网络更好的捕捉时间序列中长期依关系，并有效地缓解随着层数增加而产生的梯度消失问题。此外，为了增强网络的正则化能力，常常采用权重归一化和 Dropout 技术。

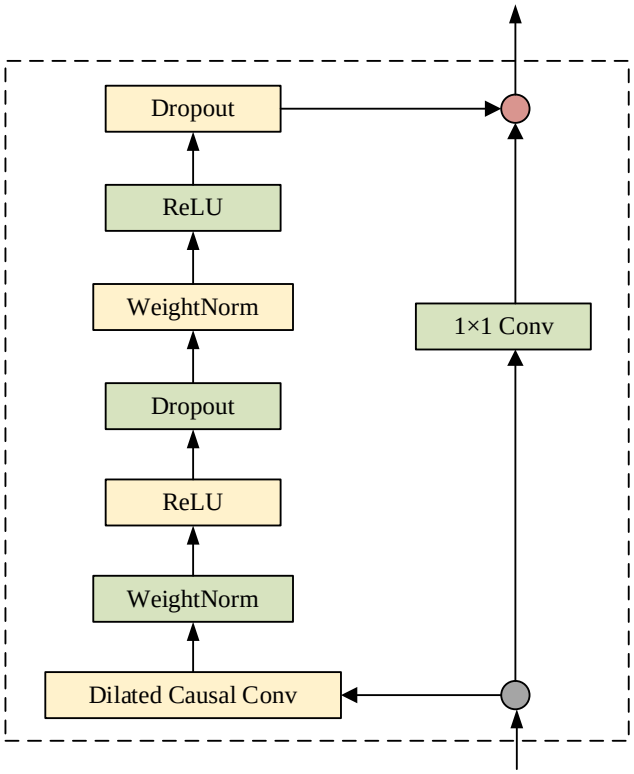

图 2-6 残差模块

中国知网 https://www.cnki.net

2.3 提出的预测模型

2.3.1 基于自迁移时间卷积网络的频谱预测模型

由于 TCN 的每一层都会对输入序列进行降采样，将原始序列压缩成较短的表示。所以随着 TCN 层数的增加，其扩张因子也会越来越高，导致一些重要的信息在隐藏层中被遗漏[60]。为了更好的捕捉序列中长期的依赖关系，进一步提高 TCN 预测精度[61]，可以采取冻结浅层权重，再次训练更新未被冻结的权重的方法。如图 2-7 所示，历史频谱数据输入原始 TCN 模型进行训练得到预训练 TCN 模型，然后通过冻结部分 TCN 网络层数，再次训练并更新剩余层的权重，得到精确度较高的预测模型 TCN-ST。关于训练过程使用超参数的更多细节将在第 2.4.1 节中描述。

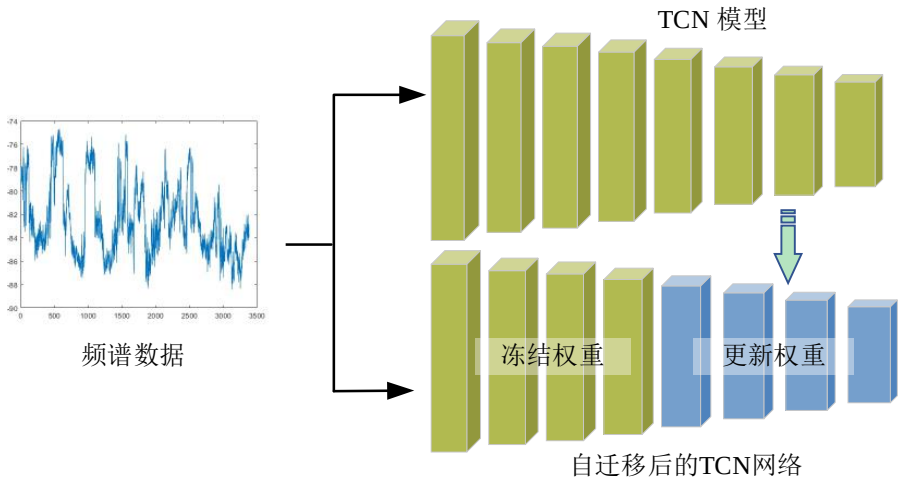

图 2-7 自迁移 TCN 参数优化过程

2.3.2 基于迁移的小样本学习频谱预测模型

深度神经网络的训练往往需要大量样本作为支持，当训练数据较少时，模型会出现过拟合现象。迁移学习是将已学到的知识和经验从一个任务或领域应用到另一个任务或领域，从而加速学习过程或提高模型性能。

在迁移学习中，域$\mathcal{D}$是由一个特征空间$\mathcal{X}$和特征空间上的编辑概率分布$P(X)$组成，即$\mathcal{D}=\{\mathcal{X},P(X)\}$。源域通常包含已经获得的相关知识，用符号$\mathcal{D}_S$表示。目标域包含少量样本，用符号$\mathcal{D}_T$表示。在频谱预测的实际应用中，用频设备的不确定性以及复杂的用频环境导致样本稀疏，无法满足大量样本需求；不同频段的频谱状态演化规律的不同，模型无法学习到其他频段用频规律。而迁移学习可以在一个或多个源域中进行学

中国知网 https://www.cnki.net

习，将学习到的有效知识应用于新的目标域中，为目标域提供良好的初始条件。通常源域和目标域具有一定的关联性或是存在些许差异，源域往往作为目标域样本稀缺的补充。根据迁移内容的不同，迁移学习一般可以分为基于样本的迁移、基于特征的迁移、基于模型的迁移和基于关系的迁移。

预训练-微调是迁移学习常见方法之一，属于基于模型的迁移学习，其主要思想是通过使用源域大规模数据集训练一个成熟的模型，将模型参数导入目标深度神经网络进一步训练，通过微调使目标域神经网络参数拟合到目标域任务。预训练需基于大规模数据集且性能良好的训练模型，微调需要适当降低学习率，避免破坏预训练获得的特征提取能力以及预测性能。迁移学习可以解决目标域数据集较小、计算能力有限、模型训练时间长、模型泛化能力低的问题。

预训练-微调方法如图 2-8 所示，其基本结构与图 2-7 类似，首先利用源域大量样本进行预训练，然后将模型参数迁移到新构建的目标模型上，通过冻结目标模型的特征提取层的参数进行更新，模型学习到新的目标域特征。然而，盲目的进行迁移学习并不能保证模型有正向迁移效果，为了衡量不同频段之间的相似性，本章采用动态时间规整（Dynamic time warping，DTW）。DTW 是一种广泛用于时间序列分析的方法，通过拉伸或压缩比较两个时间序列之间的距离，以此提供一个量化的相似性度量指标。当计算出两个序列的距离越小，表明两序列相似度越高，因此，源域和目标域之间应选择最相似的数据进行迁移。

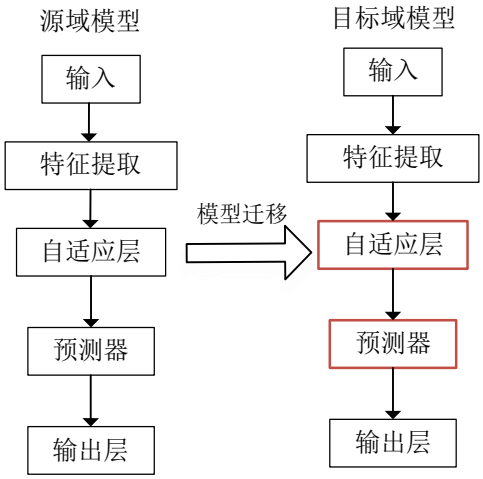

图 2-8 预训练-微调方法示意图

中国知网 https://www.cnki.net

2.3.3 算法复杂度分析

本章模型的时间复杂度分析需考虑两个阶段，分别是预训练阶段和微调阶段。在预训练阶段，所有网络都参与训练，因此需要考虑整个网络的时间复杂度，假设预训练阶段的数据集包含 N 个样本，每个样本的长度为 T，网络的深度为 L，卷积核大小为 k，则预训练阶段的时间复杂度就可以表示为 O（$N\times T\times L\times k$）；在微调阶段，因为冻结了部分层数，所以只需要考虑未冻结层重新训练，假设微调阶段需进行 M 次迭代，每次迭代需要计算网络的前向传播和反向传播以及参数更新等操作。未冻结层重新训练复杂度可以表示为 O（$M\times N\times \mathrm{T}\times L'\times k$），其中 L'是未冻结的层数。

2.4 仿真与结果分析

2.4.1 仿真设置与评估指标

仿真基于 Python 环境下的 Tensorflow 框架实现，所提出的时间卷积网络架构包括输入层、一维卷积层、残差块、全连接层和最终的回归输出层。网络中的每个一维卷积层都配置了具有 64 个卷积核，这些卷积核的大小被设置为 3，为了引入空间丢失，每个卷积层都采用了数值为 0.05 的丢失因子。为了进行高效反向传播，选择 RMSprop 优化器。在模型的训练过程中，本章将最大训练轮次的值设置为 50，学习率从 0.01 逐步减少下降到 0.001，损失函数选择均方误差（Root Mean Square Error，RMSE）。将训练集与验证集按照 8:2 进行划分，同时为了防止过拟合，在训练集的损失函数上设置了早停门限，当损失值降低到一定值后模型停止训练。

本章采用以下两种性能指标，分别是均方根误差、平均绝对误差（Mean Absolute Error，MAE）。

均方根误差是一种用于度量预测值与真实值之间偏差的指标，它将是两者平方差与预测次数 m 比值取平方根，RMSE 公式表达式如下：

$$RMSE=\sqrt{\frac{1}{m}\sum_{i=1}^{m}\left(y_i-\hat{y}_i\right)^2} \tag{2.5}$$

其中，m 是预测总次数，y 是真实值，$\hat{y}$ 是预测值，RMSE 的值越小，表示模型的预测结果与真实值之间的偏差越小，模型的性能越高。

平均绝对误差是通过计算预测值与真实值之间的绝对误差的平均值来衡量模型性能，MAE 公式表达式如下：

中国知网 https://www.cnki.net

$$MAE = \frac{1}{m}\sum_{i=1}^{m}\left|y_i - \hat{y}_i\right| \tag{2.6}$$

MAE 的优势在于其对误差的绝对值进行平均，有助于避免误差相互抵消的问题。

2.4.2 仿真结果分析

为了满足时间卷积网络对输入数据的特定需求，需要对数据实施归一化处理，并将其划分为适当的时间窗口。归一化的作用是将原始数据缩放到[0,1]范围内，以便在训练时提高模型的收敛速度和稳定性。滑动窗口大小根据原始数据的自相关系数确定，自相关系数反应时间序列在不同时刻t_1, t_2之间的相关程度[31]，如果自相关系数大于 0，表示在这个时间点上观察到的值可能会在以后的时间点上观察到。

计算结果如图 2-9 所示，随着滞后时间步长的增加，自相关系数逐渐减小。表 2-1 评估了不同滑动窗口大小对预测性能的影响，采用相同数据集和模型，并使用 RMSE 来衡量误差，从表中看出，当滑动窗口设置为 20 时，RMSE 最小且满足自相关系数大于 0.8 的要求。因此，为了在计算量和预测效果上取得平衡，本章将滑动窗口大小设定为 20，所以 TCN 的扩张因子设置为$\mathrm{d} = [1,\ 2,\ 4,\ 8,\ 16]$。

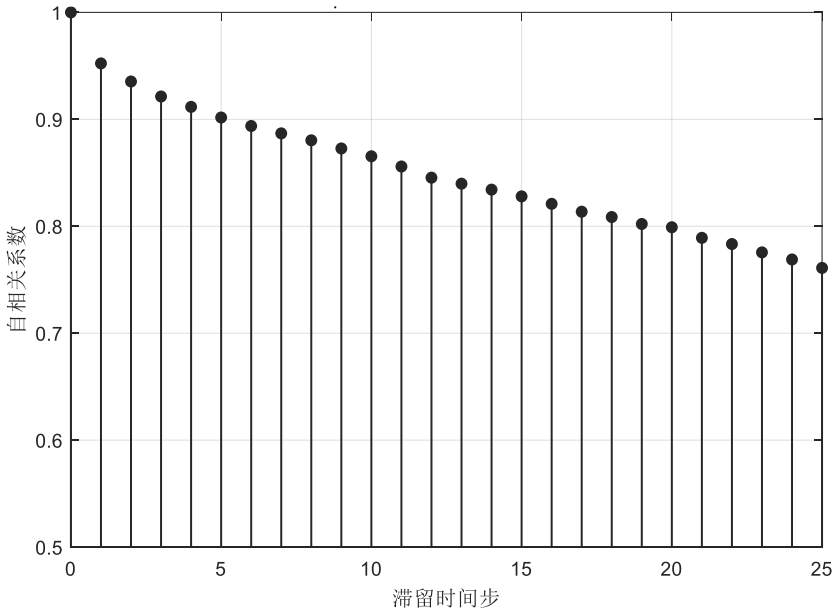

图 2-9 自相关系数

表 2-1 不同尺寸滑动窗口的均方根误差

滑动窗口大小	5	10	15	20	25
RMSE	0.85775	0.8553	0.8206	**0.8119**	0.8224

中国知网 https://www.cnki.net

经过多次实验与对比分析，发现冻结前 27 层的操作下，TCN 模型的 RMSE 值达到了最小值，因此，选择这个模型作为仿真的基础模型。图 2-10 是优化后的 TCN 同经典时间序列预测模型的性能对比。使用 LSTM、支持向量回归（Support Vector Regression，SVR）、CNN-LSTM 以及原始 TCN 作为对比算法。根据公式(2.5)-(2.6)，性能较好的预测模型将具有相对较小的 RMSE 和 MAE。

从图中可以看出，基于自迁移的 TCN-ST 网络相比原始 TCN 网络有一定性能上的提升，在评价指标 RMSE 和 MAE 上分别降低了 5.8%、4.2%。同时，也可以发现 TCN 网络在处理频谱数据预测问题方面表现出明显的优势，优化后的 TCN 相比于 LSTM 和 CNN-LSTM 在 RMSE 上分别减少了 19.5%和 18.8%，和 LSTM 和 SVR 相比在 MAE 上也减少了 14.6%和 11.5%。这表明 TCN 网络适合处理频谱预测问题，而基于自迁移 TCN-ST 网络模型可以进一步提高网络预测精度。

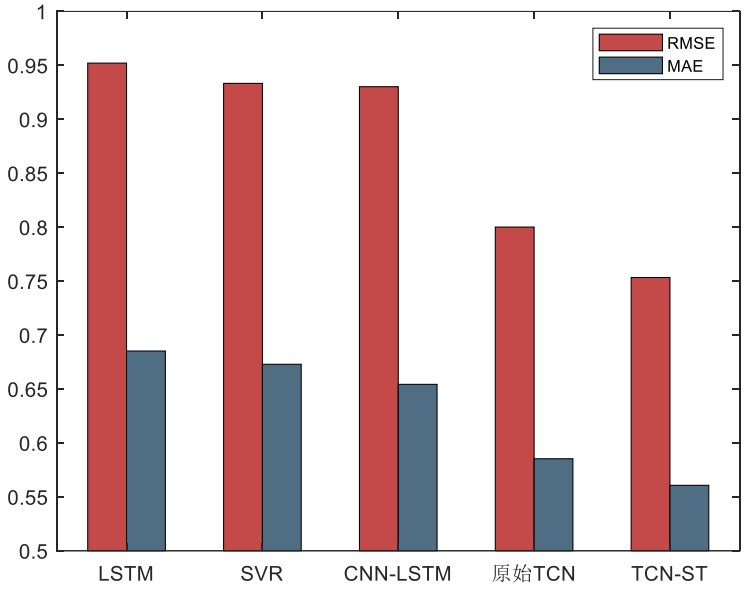

图 2-10 优化后 TCN 性能对比

使用四个频段的数据集，分别是 GSM1800 下行频带，GSM1800 上行频带、GSM900 下行频带和 GSM900 上行频带。表 2-2 显示了各频段之间 DTW 相似度分析结果。可以发现，不同频段之间的相似性存在显著差异，与其他频段相比，GSM1800 上行频段相似度差异较大，其迁移效果难以保障。GSM1800 下行频带与 GSM900 上行频带之间相似度差异在 2 以下，相似度越小，迁移学习的效果越好，可以更好的事项正向迁移。

中国知网 https://www.cnki.net

表 2-2 不同频段间的 DTW

DTW	GSM900UL	GSM900DL	GSM1800UL	GSM1800DL
GSM900UL	0	1.31	5.40	1.31
GSM900DL	1.31	0	4.67	1.45
GSM1800UL	5.40	4.67	0	5.00
GSM1800DL	1.31	1.45	5.00	0

TCN-ST 是基于当前频段小样本数据训练的预测模型；Transfer-max 是使用相似度差异最大的频带作为预训练频带的一种迁移学习方法；Transfer-min 是使用相似度差别最小的频带作为预训练频带的一种迁移方法。表 2-3 显示了四个频段三种方法的 RMSE，可以发现当目标域样本稀缺时，使用相似度差异较小的频段更容易迁移到目标频段，可以弥补因样本量少造成的训练效果不佳问题。如 GSM900 上行频段，在使用相似度差异最小的源域进行迁移后，在 RMSE 上减少了 32.3%。而当源域与目标域差异较大，一定程度上会导致模型的负迁移，甚至无法进行有效预测。如在 GSM1800 下行频段和 GSM1800 上行频段，由于数据分布的差异性，模型在 RMSE 上反而增加了 17.3%。因此在规划迁移策略时，需要对目标频段数据分布进行全面评估，以确保迁移后模型性能得到改善。

表 2-3 深度迁移学习在各个频段的 RMSE 性能对比

RMSE	GSM900UL	GSM900DL	GSM1800UL	GSM1800DL
TCN-ST	1.67	2.69	1.21	1.38
Transfer-max	1.32	1.32	1.43	1.59
Transfer-min	1.13	0.96	1.24	1.32

2.5 本章小结

本章根据实测频谱数据的时间相关性，建立一种基于时间卷积网络的频谱预测模型，为了进一步提升预测精度，采用自迁移方法，更全面考虑时间信息在频谱数据中的演变。为了验证不同服务活动在迁移学习下的模型性能，采用动态时间规整计算各频段之间相似度并进行实验仿真。结果表明，TCN 网络在处理频谱预测问题时表现出色，而通过基于自迁移的 TCN 网络模型进一步提高了预测精度，经过优化的 TCN 在 RMSE 方面相较于 LSTM 和 CNN-LSTM 分别减少了 19.5%和 18.8%，相对于 LSTM，

中国知网 https://www.cnki.net

TCN 在 MAE 上也降低了 14.6%。同时迁移学习在一定程度上可以弥补因样本数据量不足造成的训练效果不佳问题。

中国知网 https://www.cnki.net

第三章 基于知识蒸馏的小样本频谱预测方法

现有网络为提高模型精度往往复杂度较高，有限的存储和计算资源使得模型难以落实到实际部署。本章针对现有复杂模型在训练过程中普遍存在模型参数过多和对样本需求量较大的问题，以时间卷积网络和知识蒸馏技术为基础，将自迁移时间卷积网络作为学生网络，将双分支神经网络作为预测网络，通过知识蒸馏技术实现一个面向小样本场景的轻量化频谱预测模型。

3.1 引言

面对数据采集设备的不确定性以及无线电的开放性带来复杂的用频环境，研究人员开始关注样本不完备以及样本量不充足情况。文献[25]考虑历史数据的不完整情况，将二维频谱预测问题转换为矩阵完备问题。文献[23]分析频谱数据中异常数据对频谱矩阵秩分布的影响，从矩阵恢复角度，开发了一种有效解决该问题的优化方法。文献[62]在此基础之上开发一个鲁棒的在线频谱预测框架（ROSP），采用矩阵完备和矩阵恢复的联合优化算法，在真实频谱数据上有不错的效果。文献[34]提出一种基于迁移学习的跨频带频谱预测模型解决稀疏频谱数据问题。此外，还通过对频谱数据的相似性度量将单频点训练模型的适用性扩展到其他频带上，这为电磁对抗环境下频谱预测问题的解决带来一种新的思路。文献[32]结合生成对抗网络（Generative Adversarial Network，GAN）和深度迁移学习构建一种适用不同频段的频谱预测模型，然而该网络需要寻找大量和目标域相似数据而且网络结构复杂难以训练。因此，文献[35]将元学习和迁移学习结合起来，通过构造元学习数据集，寻找模型参数最优分布，在跨频段预测方面相比于文献[32]中的方法具有更好的适应性。在频谱预测领域，以上方法可以保证在数据量较少情况下模型有良好表现，但未考虑模型复杂度以及实际部署的难度，因此本章考虑结合知识蒸馏方法，构建轻量化预测模型来解决此类问题。

知识蒸馏于 2015 年被 Hinton[63]等人创造性的提出，旨在将知识从大型且复杂的教师模型向结构简单的学生模型迁移，以此达到减少模型参数、提高分类性能的目的。随后又演化出丰富的变体和网络架构[64]。文献[65]提出了一种基于迁移学习和知识蒸馏的炉温预测模型，利用生成对抗损失促进迁移过程，建立基于多任务学习的蒸馏网络解决深度迁移网络延迟高缺点。文献[66]提出一种混合模型来预测航空发动机剩余使用寿命，该模型设计了两次知识蒸馏。第一次蒸馏为异构蒸馏，目的是压缩模型并加快

中国知网 https://www.cnki.net

训练速度。第二次蒸馏为同构蒸馏，目的是在不改变模型结构的前提下，提高模型预测精度。文献[67]在时间序列分类的背景下探讨了知识蒸馏技术，通过多个数据集验证知识蒸馏可以提高小型卷积神经网络在该任务的性能，同时可以降低模型的计算成本和存储需求。上述方法说明了知识蒸馏在降低模型复杂度方面有很大优势。

针对期望历史数据的相对缺乏、模型复杂度较高的问题。本章构建基于知识蒸馏的轻量化频谱预测模型，目的是使用轻量化网络实现充足样本和小样本情况下的频谱预测。本章的主要贡献概括如下：

1) 在频谱预测领域提出了一个新颖的预测模型，该模型采用知识蒸馏技术将大模型学习到的知识传递给轻量化模型，在保证模型预测性能同时提高模型运算速度。

2)以自迁移时间卷积网络为教师网络，以构造的双分支神经网络为学生网络。学生网络将数据的低维表示同时用于编码重构和编码预测，通过利用数据的内在表示，实现所提出模型更高效的预测。

3) 利用实测数据进行大量实验，实验结果表明，在历史数据充足和稀缺情况下均有良好性能。此外，本章方法在模型参数量上显著减少，即使是在资源受限的环境中也易于实施和部署。

3.2 知识蒸馏频谱预测模型构建

3.2.1 知识蒸馏学习

知识蒸馏是一种深度学习技术，它可以将结构复杂、精度较高的教师模型知识转移到参数量少、结构简单的学生模型中[66]。教师模型一般是单个复杂网络或者是多个网络组合而成，包含从历史频谱数据中提取的知识，且学习能力强大，能够捕获学生模型无法学习的特征，拥有良好的性能和泛化能力。相较于教师模型，学生模型的网络规模通常较小，其表达能力也相应受限。为了提升学生的性能，可以借鉴教师模型积累的知识来指导训练过程，最终能够达到与教师模型相近的性能水平。

如图 3-1 所示，知识蒸馏首先根据数据集预训练一个性能良好的复杂教师模型，然后提取复杂模型对输入数据的软标签来帮助简单学生模型进行训练和收敛。当教师模型和学生模型首次处理同一项任务时，教师模型因结构复杂、参数量大的特点对任务拟合较好，相比之下，学生模型很难达到良好的性能效果。通过知识蒸馏。学生模型可以在教师模型的基础上学习，提高预测效果和学习效率。

中国知网 https://www.cnki.net

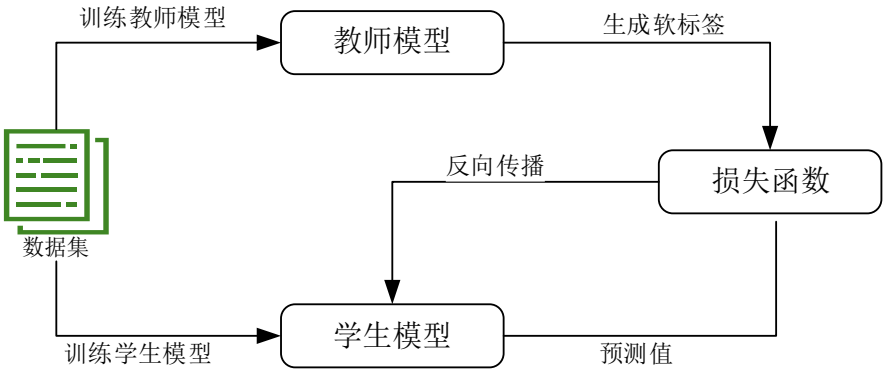

图 3-1 知识蒸馏过程

在本章中，将教师模型的中间层输出记作 $s_t^{'}$ 作为学生模型的输入，通过提取更高级别的特征，帮助学生模型更好学习。通过最小化软目标损失和硬目标损失两个损失函数, 可以帮助学生模型学习教师模型的知识，实现模型待训练参数的压缩与训练加速。

传统神经网络的训练过程包括定义一个损失函数，并通过反向传播计算损失函数的梯度，从而进行参数更新。这个过程的目标是通过不断调整模型参数，使其预测值尽可能地接近实际观测值。在知识蒸馏中，软目标损失用于度量学生模型的输出和教师模型输出之间的差异，旨在保留教师模型的知识。将教师模型 $f^T(\cdot)$ 输出结果 $f^T(\mathbf{s}_t)$ 称为软目标，作为学生模型 $f^S(\cdot)$ 的目标变量。软目标损失公式表达为：

$$L_{soft} = \frac{1}{m}\sum_{t=1}^{m}(f^S(\mathbf{s}_t^{'}) - f^T(\mathbf{s}_t))^2 \tag{3.1}$$

硬目标损失用于度量学生模型的输出和真实标签之间的差异，旨在提高学生模型的预测准确度。将真实数据 y_t 称为硬目标，作为学生模型 $f^S(\cdot)$ 的目标变量。硬目标损失公式表达为：

$$L_{hard} = \frac{1}{m}\sum_{t=1}^{m}(f^S(\mathbf{s}_t^{'}) - y_t)^2 \tag{3.2}$$

通过最小化这两个损失函数可以帮助学生模型保持较高的预测精度，从而减小模型的计算量和提高运行效率，更好地适应资源有限的环境。

3.2.2 双分支学生网络

为了更充分提取频谱数据特征，本文构建了双分支神经网络。如图 3-2 所示，该网

中国知网 https://www.cnki.net

络由两条分支组成，分别是编码-重构分支 f_{rec} 和编码-预测分支 f_{pre}。

编码-重构分支将数据压缩成编码形式，然后将其重构为与原始数据接近的输出，让模型学习到数据的低维表示。其包含参数为 θ_1 的编码器，参数为 θ_2 的重构器。该分支接收数据 $s_t^{'}$ 并输出 $f_{rec}(s_t^{'};\theta_1,\theta_2)$，将重建损失定义为：

$$L_{rec}=\frac{1}{m}\sum_{t=1}^{m}(f_{rec}(s_t^{'};\theta_1,\theta_2)-s_t)^2 \tag{3.3}$$

编码-预测分支共享编码-重构的编码器并输出预测值，其包含参数为 θ_1 的编码器，参数为 θ_3 的预测器。该分支接收数据 x_t 并预测未来频谱值 $f_{pred}(s_t;\theta_1,\theta_3)$。将预测损失定义为

$$L_{pre}=\frac{1}{m}\sum_{t=1}^{m}(f_{pre}(s_t^{'};\theta_1,\theta_3)-y_t)^2 \tag{3.4}$$

因为构造的模型包含两个分支，公式(3.2)可以改写为

$$L_{hard}=L_{rec}+L_{pre} \tag{3.5}$$

编码重构分支可以帮助模型学习到数据的内在表示，并降低输入数据的噪声和冗余。通过共享编码器输出，重构器和预测器可以同时使用数据的低维表示，从而提高模型的训练效率和泛化性能。

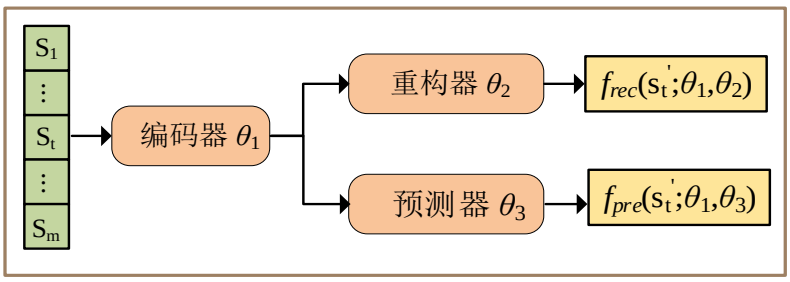

图 3-2 双分支学生网络

3.3 提出的小样本预测方法

3.3.1 所提预测模型

为了实现知识的转移，知识蒸馏技术将教师模型的中间层输出作为学生模型的输入，以提供更关键的数据特征。同时，知识蒸馏通过构建损失函数，从软目标损失和硬目标损失两个方面对学生模型的输出进行约束，以提高学生模型的预测性能。为了

中国知网 https://www.cnki.net

在学习新数据的泛化能力和对已有知识的保留保持平衡，使用了平衡因子α。当教师模型性能优于学生模型性能，选择较大的平衡因子，以确保学生模型能充分学习并吸收更多已有知识。相反，当教师模型和学生模型性能相差不大，可以选择较小的平衡因子。通过最小化目标函数来更新所提模型参数：

$$L_{total} = \alpha L_{\text{soft}} + (1-\alpha) L_{\text{hard}} \tag{3.6}$$

其中平衡因子$\alpha \in [0,1]$，用于调节硬目标损失和软目标损失的相对比重，由于教师模型比学生模型复杂度和准确性更高，因此设置$\alpha = 0.6$。

知识蒸馏框架如图 3-3 所示。首先将频谱数据输入预训练 TCN 教师网络，教师网络生成精度较高的软目标 $f^T(\mathbf{s}_t)$ 和作为学生网络输入的中间层输出 $s_t^{'}$，学生网络接收特征表示 $s_t^{'}$ 后，经过编码器模块提取隐藏特征，这些特征被输入重构模块生成重构数据 $f_{rec}(s_t^{'};\theta_1,\theta_2)$，同时，也被输入预测模块生成预测频谱数据 $f_{pre}(s_t^{'};\theta_1,\theta_3)$。通过式（3.3）和式（3.4）计算总目标损失。

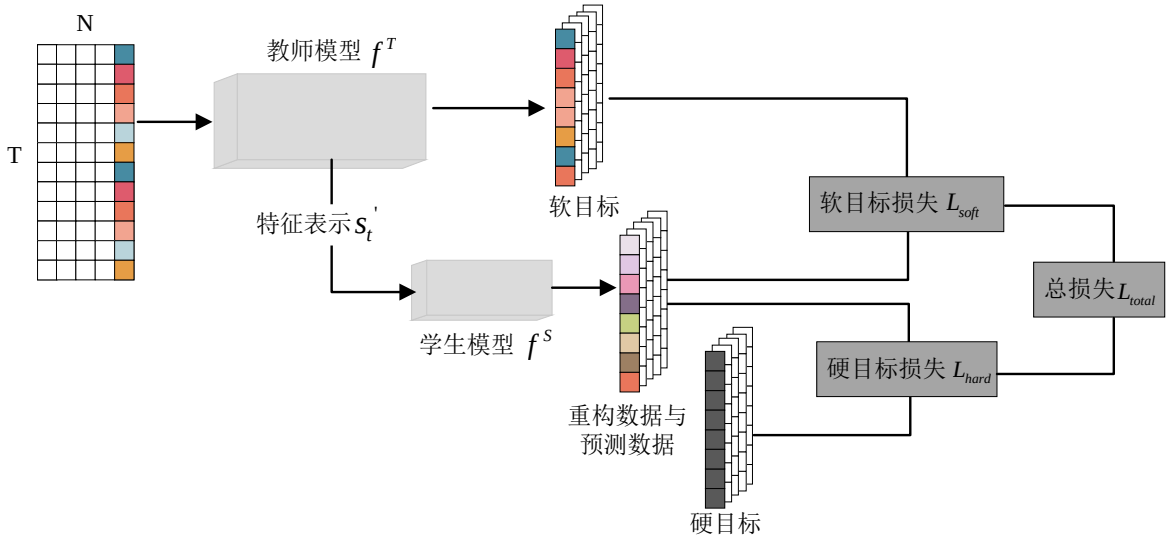

图 3-3　所提模型框架

3.3.2 TCN-KD 算法流程

将优化后师生模型的知识蒸馏网络称为 TCN-KD，TCN-KD 的整个训练过程总结于算法 3.1，教师模型接收归一化固定长度的频谱数据，生成中间层特征和软标签。学生模型利用中间层特征生成预测值，通过最小化软目标损失和硬目标损失，逐渐减少与教师模型差距。在 TCN-KD 的测试阶段，输入数据经过已训练模型的编码-预测分支，

中国知网　https://www.cnki.net

得到预测结果。

算法 3.1：TCN-KD 训练过程

输入： 频谱数据 $D=\{\mathrm{f}_n\}_{n=1}^{N}$ ， 其中 $\mathrm{f}_n=\{(s_t^{'},y_t)\}_{t=1}^{m}$

输出： 学生模型 f^S 的参数 $\hat{\theta}_1,\hat{\theta}_2$ 和 $\hat{\theta}_3$

初始化参数 θ_1,θ_2 和 θ_3
for $n\in\{1,2,...,N\}$ **do**
  for $t\in\{1,2,...,m\}$ **do**
    从 D 中取训练数据 s_t,y_t
    教师网络 f^T 输入 s_t 得 $s_t^{'},f^T(s_t)$
    学生网络 f^S 输入 $s_t^{'}$ 得 $f_{rec}(s_t^{'};\theta_1,\theta_2),f_{pre}(s_t^{'};\theta_1,\theta_3)$
    根据公式(3.1)计算 L_{soft}
    根据公式(3.5)计算 L_{hard}
    根据公式(3.6)计算 L_{total}
  end for
  通过最小化 L_{total} 更新参数 θ_1,θ_2 和 θ_3
end for
return $\hat{\theta}_1,\hat{\theta}_2$ 和 $\hat{\theta}_3$

图 3-4 为所提知识蒸馏频谱预测算法 TCN-KD 的算法流程示意图。

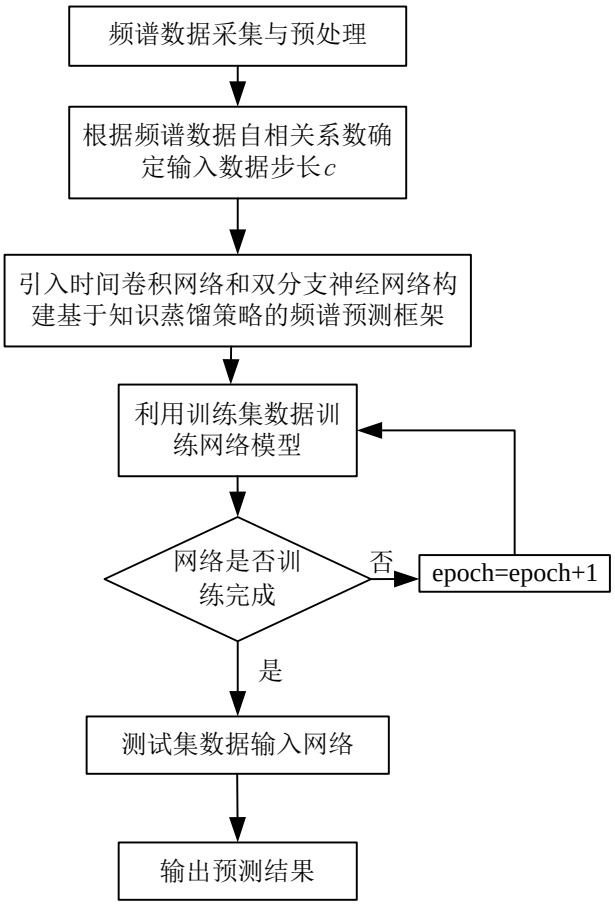

图 3-4 TCN-KD 算法流程示意图

中国知网 https://www.cnki.net

3.3.3 算法复杂度分析

计算复杂度对算法的实用性至关重要，在 2.3.3 节已讨论了 TCN 算法的计算复杂度。若数据集包含 N 个样本，每个样本的长度为 T，网络的深度为 L，卷积核大小为 k，则预训练阶段的时间复杂度就可以表示为 $O(N\times T\times L\times k)$，由于在实验中使用的是预训练模型，计算成本较高的操作主要是离线训练阶段进行。双分支网络是一个全连接网络，假设 l 代表全连接层节点数，n 为输入维度，m 为输出维度，则其计算复杂度可被描述为 $O(l\times n\times m)$。

综上所述，所提算法的计算复杂度取决于 TCN 网络和双分支网络。在已有预训练网络的前提下只需要更新学生模型参数，因此所提出网络可以保持较低的计算复杂度。

3.4 仿真与结果分析

3.4.1 仿真设置与评估指标

本章采用自迁移 TCN 作为教师模型，通过知识蒸馏训练轻量级学生模型。对于学生模型，构造了一个双分支神经网络，其参数设置如下：编码器由三个不同维度隐藏层构成，维度设置分别是 20、64、32，每个隐藏层后都连着 ReLU 激活函数。重构器具有两个线性层，维度为 32、20。预测器同样有两个线性层分别为 16、1。为了便于表述，将所提出的知识蒸馏模型称为 TCN-KD。

本章考虑从两个角度对当前算法进行性能分析：均方根误差、平均绝对误差。

3.4.2 仿真结果分析

为了评估 TCN-KD 的性能，本章实验在 GSM 1800 上行频带，GSM 1800 下行频带，GSM 900 上行频带，GSM 900 下行频带共四个频带，分别使用了 LSTM、GRU、CNN-LSTM、双分支神经网络、TCN-KD 等算法，其中双分支神经网络是无教师帮助的学生模型。实验结果如表 3-2 和表 3-3 所示，展示了实验中各个算法的 RMSE 和 MAE 结果。从表中可以看出，TCN 模型在四个频段中拥有最低的 RMSE 和 MAE，并且相较于其他算法，TCN-KD 的待训练参数显著降低，最多减少了 133,132 个参数，最少减少了 22,200 个参数。相较于双分支神经网络，该模型仅增加了 2816 个待训练参数，但预测性能却有显著提升。这表明在教师网络的帮助下，学生网络可以以较小的代价获得较

中国知网 https://www.cnki.net

高的预测精度。

为了更直观的展示不同模型的性能，本章将各模型对应的 RMSE 和 MAE 可视化为图 3-5。值得注意的是，虽然本章提出双分支网络在 RMSE 上取得了相对较低的表现，但 MAE 值却较高，这主要因为 MAE 对异常值有较强的敏感性，当预测值和实际值之间存在极端的异常值时，MAE 的值就会偏大。然而，一旦知识蒸馏技术引入双分支网络后，模型表现出更高的准确性和更稳定的性能，这充分证明了知识蒸馏对模型性能有积极影响。尽管 TCN-KD 在预测效果方面略逊于教师模型 TCN-SF，但两者之间的预测误差差距较小，几乎可以忽略不计。更重要的是，所提模型待训练参数量明显减少，说明利用知识蒸馏技术可以帮助 TCN-KD 在保持模型轻量化的同时提高模型预测性能。

表 3-2 各频段的 RMSE 及参数量

RMSE	1800UL	1800DL	900UL	900DL	Params
LSTM	0.3752	0.9539	1.4313	0.9378	40 901
GRU	0.3647	0.9474	1.3551	0.8991	30 701
CNN-LSTM	0.3642	0.9412	1.4124	0.9036	53 493
TCN-SF	0.3222	0.7448	1.1960	0.7917	141 633
Two-Branch	0.3546	0.9045	1.3551	0.8805	5685
TCN-KD	**0.3199**	**0.7542**	**1.1983**	**0.7994**	**8501**

表 3-3 各频段的 MAE 及参数量

MAE	1800UL	1800DL	900UL	900DL	Params
LSTM	0.2734	0.6613	0.6673	0.4827	40 901
GRU	0.2668	0.6591	0.6259	0.4467	30 701
CNN-LSTM	0.2654	0.6534	0.6300	0.4347	53 493
TCN-SF	0.2357	0.5507	0.5309	0.3636	141 633
Two-Branch	0.2628	0.6796	0.6549	0.4566	5685
TCN-KD	**0.2344**	**0.5607**	**0.5413**	**0.3699**	**8501**

中国知网 https://www.cnki.net

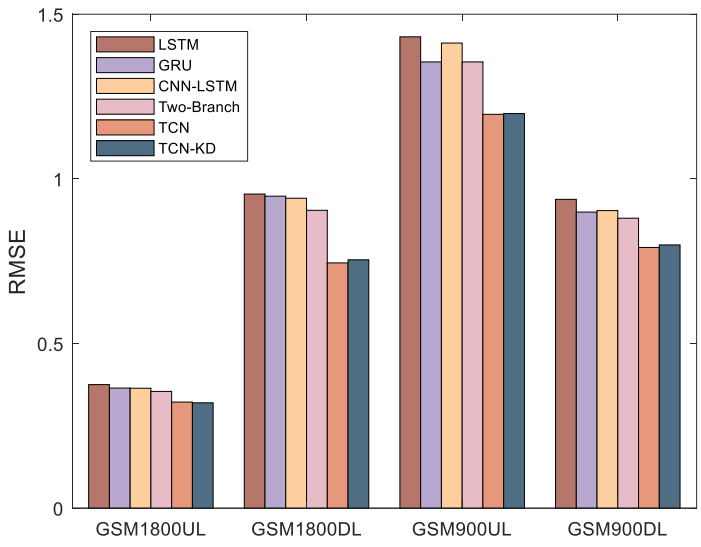

(a) 不同模型的 RMSE

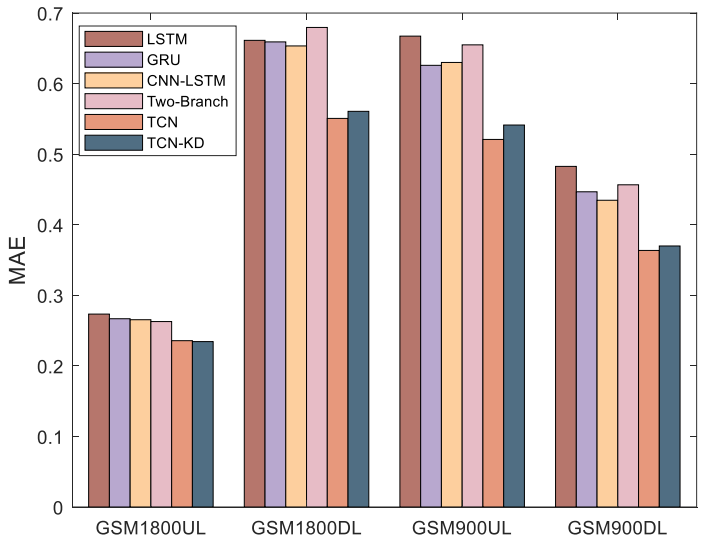

(b) 不同模型的 MAE

图 3-5 知识蒸馏性能对比

为了验证提出模型的预测时效性，本实验统计各模型从训练到预测的总共耗时，旨在评估模型的实际效率和可应用性。实验使用型号为 RTX 2050 的 GPU 进行训练，对于各个模型，本章采用了统一的设置，包括批处理大小为 12，训练轮数为 50，优化器为 RMSprop，学习率设置为 0.01，并设置了早停机制。根据表 3-4 的分析结果，可以发现模型的训练时间通常与训练参数量成正比。由于 TCN 的模型参数量非常庞大，所以需要更长的训练时间，但是它也具有更高的预测精度。在 TCN 的帮助下，TCN-KD 相对于 LSTM 和 GRU 在训练精度和训练时间方面都具有一定的优势。考虑到资源受限的情况下，TCN-KD 更适合实际部署。

中国知网 https://www.cnki.net

表 3-4 训练耗费时长

Model	LSTM	GRU	CNN-LSTM	TCN	TCN-KD
Times [s]	44.05	31.46	28.49	39.06	19.56

为了进一步分析，图 3-6 比较了 MLP、双分支网络、所提出 TCN-KD 三种模型性能。MLP 是无重构分支的双分支网络，双分支网络是无教师网络帮助的 TCN-KD。实验中，MLP 的性能最差，但借助重构损失，模型预测精度得到很大提高。同时，在预训练教师网络的帮助下，进一步提高了双分支神经网络的预测精度。

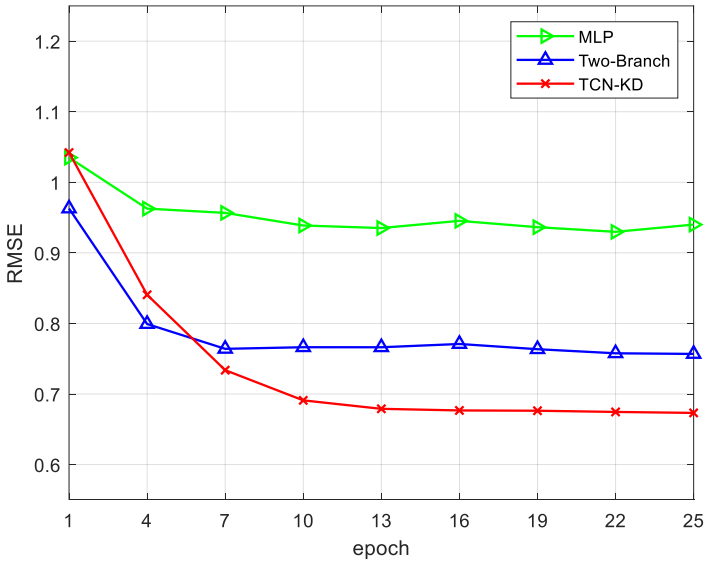

图 3-6 涉及预测网络性能比较

通过 TCN-KD 与其他网络的对比实验，发现在目标数据充足的情况下，所提出的基于知识蒸馏的频谱预测框架在预测时间和预测精度方面都有一定优势。但是在少量样本情况下，TCN-KD 能否具有良好的预测性能，还需要进一步的实验验证。本实验将输入数据的时间跨度由 7 天改为 2 天训练网络，依然在四个频段上测试各种网络性能，使用 RMSE 比较模型预测精度。如图 3-7 所示，通过分析各频段误差，结果表明在少量样本的情况下，TCN-KD 仍然表现出较为出色的性能，例如在 GSM900UL 频段，所提出算法相比于 CNN-LSTM 在 RMSE 上减少了 24.2%，相比于双分支神经网络减少了 12.3%。这是因为知识蒸馏可以帮助学生模型学习到教师模型丰富的知识，从而使得学生模型在有限的数据中展现出更佳的泛化性能，提高模型的预测准确性和鲁棒性。此外，还发现 CNN-LSTM 在少量样本情况下表现不佳，原因是由于 CNN-LSTM 模型结构的复杂性和参数量较大，当训练集样本数量较少时，模型难以有效地利用有限的数据进行训练，从而导致模型的泛化能力下降，容易出现过拟合的现象。

中国知网 https://www.cnki.net

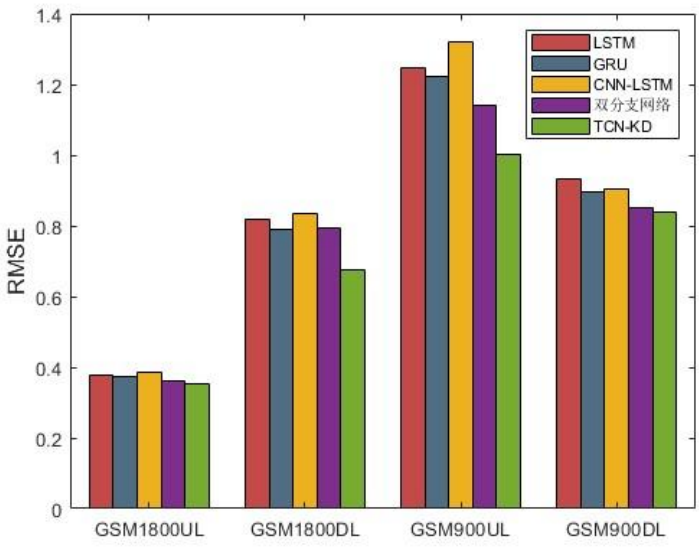

图 3-7 小样本情况各个频段对比

为了进行可视化展示，图 3-8 绘制了实验中 200 个时隙的预测值，其中包括了真实值、GRU 模型和 TCN-KD 模型的预测值。为了进行更清晰的比较，选择了在算法比较中表现较好的 GRU 模型。实验结果表明，在知识蒸馏的帮助下，TCN-KD 模型能够更有效地捕捉频谱数据中的复杂细节，相比之下，GRU 模型对实际值的拟合较差。

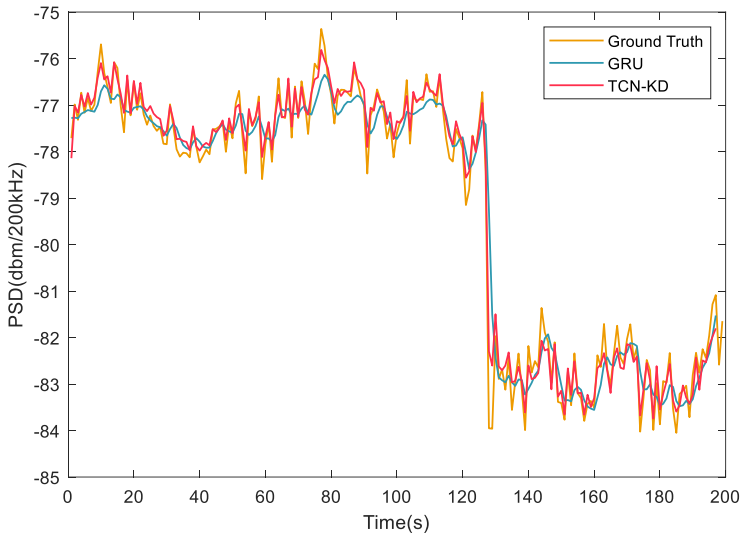

图 3-8 频谱预测结果对比

3.5 本章小结

在本研究中，提出了一种 TCN-KD 的轻量化频谱预测模型，用于解决在样本受限的真实频谱环境中的频谱预测问题。从教师模型中蒸馏的知识被用来指导学生模型的训练过程，使学生模型能够更加高效和快速地学习。模型在训练过程中的复杂性和样

中国知网 https://www.cnki.net

本需求被降低，使其适用于小样本频谱预测任务。实验结果表明，TCN-KD 在充足和有限历史数据的情况下，相较于 LSTM 预测，能够提高预测准确度 19.5%，同时减少了 71.1%的需要训练的参数。此外，在历史数据稀缺的情况下，与 GRU 相比，准确度提高了 17.9%

中国知网 https://www.cnki.net

第四章 基于预测的深度强化学习频谱接入方法

在动态频谱接入场景中，可用频谱是动态变化的，若次用户不能实时掌握空闲信道分布状态，必然会导致频谱资源分配的不合理。本章针对这一问题，提出一种基于预测的深度强化学习频谱接入方法，通过引入对主用户行为的预测，帮助智能体更快的学习和优化接入策略，并根据次用户传输速率和主用户受干扰情况做出信道接入和功率分配的决策。

4.1 引言

传统的认知无线通信系统在频谱利用上存在很多不足，因为大部分频段在大部分时间处于空闲状态，却被以独占的形式分配给特定的系统或服务。认知无线电作为动态频谱接入的重要手段之一，其核心思想是使无线终端设备在不干扰已有用户的前提下，能够智能探测并利用空闲频谱，实现频谱资源的动态共享和高效利用[68]。由于可用频谱是动态变化的，若不能实时掌握空闲信道分布状态，必然导致频谱资源的不合理利用。当前主流的频谱接入方案大多属于被动式接入方法，对于信道中频谱状态反应相对短视。因此，在进行频谱接入之前，通过预测未来频谱状态，更全面了解频谱资源利用情况是十分必要的。通过预测未来可用频谱而主动进行频谱接入，使模型更关注长期状态，将有助于提高决策的质量和效果。文献[69]首次将频谱预测机制应用于认知无线电，提出一种具有前瞻性的主动频谱接入方法。该方法通过建立简单的统计模型预测未来各信道的可用性，从整体上降低了对授权用户的干扰率。在此基础上，文献[70]丰富了预测模型的参变量，以主用户出现概率为主导因素，主用户所在信道条件、信道稳定性为关联因素提出基于灰色系统的频谱预测机制，该方法降低了频谱切换次数，提高了频谱接入的成功率。近年来，随着神经网络的蓬勃发展，深度学习在频谱预测方面涌现了许多引人注目的成功案例。文献[23,55,63]已经证明了可以利用频谱数据的时频相关性对主用户的未来频谱活动进行预测。然而，在深度学习领域，很少有研究将频谱预测与频谱接入两种技术相结合。文献[71]采用 LSTM 和 ResNet 组成的神经网络作为拟合 Q 网络，其中 LSTM 的任务是提取历史频谱数据的时间特征，以提高频谱预测的准确性。然而，该模型结构将频谱预测和频谱接入问题融为一体，若改进频谱预测模型，必然会对强化学习的主要任务造成干扰。因此，需将频谱预测从深度强化学习中解耦，以便更灵活的进行模型更新和改进。

中国知网 https://www.cnki.net

基于以上分析，针对动态频谱接入中存在的问题，提出一种基于预测的深度强化学习频谱接入方法，本章的主要贡献总结如下：

1) 构建了一种基于预测的动态频谱接入模型，克服频谱接入中过度依赖频谱感知检测频谱空洞现状。通过主动预测未来频谱状态，使模型更关注频谱使用长期趋势，提高决策质量和效果。

2) 设计了多用户多信道频谱接入模型，综合考虑次用户传输效率和对主用户干扰水平，学习过程同步优化信道选择和传输功率，以在有效降低对主用户干扰的同时提升频谱利用率。

3) 智能体不断地与环境交互获取信息实现奖励值的最大化从而获得最优控制动作策略。通过仿真评估不同环境下所提方案的性能，结果表明，所提算法能有效提升空闲频谱利用能力，提升传输效率。

4.2 系统模型与问题建模

4.2.1 系统模型

考虑一个由 M 个主用户和 N 个次用户组成的动态频谱接入系统，该系统以分布式方式构建，如图 4-1 所示。$N=\{n\,|\,n=1,2,...,N\}$ 和 $M=\{m\,|\,m=1,2,...,M\}$ 分别表示次用户和主用户的两个集合，主用户和次用户的数量满足 $M<N$。每个主用户占用不同信道，且每次只使用一个信道，确保彼此的频谱范围相互独立，从而避免主用户之间干扰。为了确保描述的普适性，每个用户都对应一对发射机与接收机。次用户在主用户可容忍的干扰范围内，机会性地接入并与主用户和其他次用户共享的当前无线信道。

当 M 个主用户和 N 个次用户在三维空间随机分布，并且在已知发射机和接收机传输距离的前提下，可建立无线信道的传播路径损耗模型，进一步分析不同用户之间的信道增益。由于网络缺乏集中控制，次用户可能会面临来自主用户和其他次用户的干扰。当次用户 n 接入信道 m 时，次用户 n 对应接收机处的信干噪比（Signal to Interference Plus Noise Ratio, SINR）为

$$SINR_n^m=\frac{p_{n,m}\cdot\left|h_{nn,m}\right|^2}{\underbrace{p_{m,m}\cdot\left|h_{mn,m}\right|^2}_{\text{来自主用户干扰}}+\underbrace{\sum_{i,i\neq n}^{N}p_{i,m}\cdot\left|h_{in,m}\right|^2}_{\text{来自其他次用户干扰}}+\underbrace{B\cdot N_0}_{\text{噪声}}} \tag{4.1}$$

中国知网 https://www.cnki.net

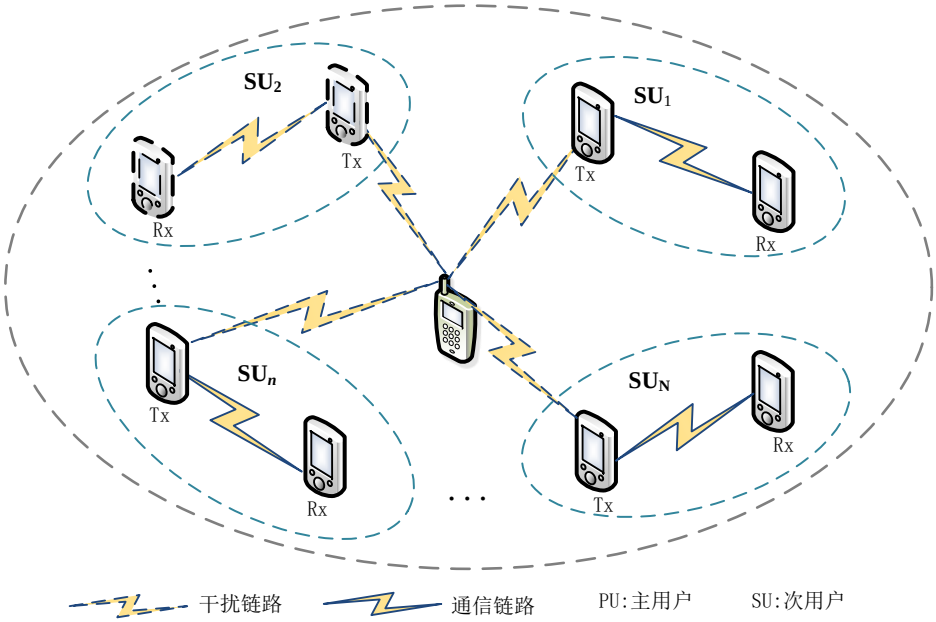

图 4-1 系统模型

其中 $p_{n,m}, p_{m,m}, p_{i,m}$ 分别表示信道 m 上用户 n,m,i 的发射功率，$h_{nn,m}, h_{mn,m}, h_{in,m}$ 分别表示信道 m 上用户 n,m,i 到次用户 n 接收端的信道增益，B 和 N_0 分别代表信道带宽和功率谱密度。

根据香农定理，次用户 n 在信道 m 上传输速率为

$$Rate_n^m = \log_2(1 + SINR_n^m) \tag{4.2}$$

为了表述方便，本章使用如表 4-1 所列出的主要符号。

表 4-1　符号

符号	含义
M	主用户授权信道数量
N	DSA 用户数量
$SINR_n^m$	DSA 用户 n 接入信道 m 的信干噪比
$p_{n,m}$	DSA 用户 n 在信道 m 的发射功率
$h_{nn,m}$	DSA 用户 n 发送端到接收端信道增益
N_0	高斯噪声
B	信道带宽
$Rate_n^m$	DSA 用户 n 在信道 m 上获得的传输速率

4.2.2 问题建模

本章的工作重点在于利用深度强化学习实现信道的选择与功率分配，目标通过优

中国知网 https://www.cnki.net

化每个信道上次用户的传输速率以最大化系统的传输速率。因此，动态频谱接入问题的优化目标可公式化为

$$\begin{aligned} &\max \sum_{n\in N}\sum_{m\in M} Rate_n^m \\ &s.t. \quad \sum_{m\in M} p_{n,m} \le p_{\max},\ \forall n\in N \end{aligned} \tag{4.3}$$

其中，约束条件限制每个用户在所有信道上的总功率不得超过 $p_{\max}$，因此次用户 n 发射功率满足 $0 \le \sum_{m\in M} p_{n,m} \le p_{\max}$,。在下一节中，介绍基于预测的深度强化学习频谱接入方案，该方案提出了一种以分布式方式解决此优化问题的方法。

4.3 算法设计

4.3.1 深度强化学习

强化学习由于其具有无模型特征，已在无线通信领域得到广泛应用。与深度学习不同，深度学习需使用标记数据或训练数据优化网络参数，而强化学习只需通过与环境的进行交互获取经验数据，并根据这些数据进行学习和优化。

如图 4-2 所示，环境是智能体所处的外部系统，可以是简单的虚拟模拟环境，也可以是真实世界中的复杂系统。智能体通过感知和观测当前时刻的环境状态 s，根据已有的经验策略选择最优动作 a，执行动作后，环境发生改变并反馈对应的期望奖励值 r。不断重复上述过程直到满足迭代次数上限或任务精度要求。在充分探索环境后，智能体可以选择为当前状态带来最大奖励值的动作。

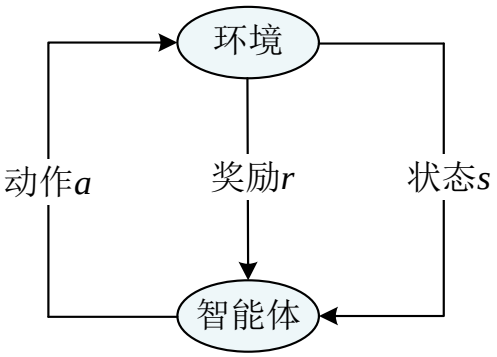

图 4-2 强化学习框架

$Q^{\pi}(s,a)$ 表示动作-价值函数，描述了智能体在状态 s 遵循策略 π 采取行动 a 获得的预期奖励值总和。通过选择最大动作-价值函数值 $Q^{*}(s,a)=\max_{\pi} Q^{\pi}(s,a)$ 确定最佳策略。

中国知网 https://www.cnki.net

$Q^*(s,a)$ 存储在 Q 表中，并根据以下等式更新 Q 表

$$Q(s,a)=Q(s,a)+\alpha\left(r+\gamma\max_{a'}Q\left(s',a'\right)-Q(s,a)\right) \tag{4.4}$$

其中 α 是学习率，s' 是状态 s 执行动作 a 后的下一个状态。

深度强化学习是将强化学习与深度学习相结合的一种方法，通过神经网络将包含环境信息的状态空间映射到动作空间，解决强化学习难以解决的高维状态空间问题。DQN 算法是深度强化学习的经典方法之一，其主要过程与传统强化学习类似，改进点在于引入目标网络和经验回放机制来解决训练过程中的不稳定问题。通过冻结并定期更新目标网络参数，可以提高学习稳定性和加速训练过程。通过构建经验复用池，保存探索过程中经验样本并通过随机样本抽样实现批次训练，减少数据间相关性。同时，经验复用池还能扩展探索空间，使得智能体更充分利用过去的经验，提高训练效率和性能。

4.3.2 基于预测的接入优化方法

本章采用深度强化学习方法，使用 DQN 进行频谱接入。在深度强化学习中，每个次用户被视为一个独立的智能体，其内部包含两个结构相同的深度神经网络，分别为评价网络和目标网络。次用户在 t 时刻的观测状态为大小为 2M 的向量，其中 M 个观测包含 M 个信道状态的统计信息，即当前信道次用户的干扰功率与主用户传送功率的比值，另外 M 个观测为信道未来状态预测值，即主用户行为的预测信息。如图 4-3 所示，频谱预测模型采用基于深度学习的结构，以历史主用户功率值为基础，进行未来主用户行为的预测。通过将滑动窗口内的数据作为输入，模型将生成的预测数据 $\hat{s}_t$ 作为输出，将观测状态用符号 $\varphi(s_t)=(s_t,\hat{s}_t)$ 表示。

关于动作的执行，本章希望选择合适的策略 π^n 解决联合信道接入与功率分配问题，即 $\pi^n=(\pi_c^n,\pi_p^n)$。其中，$\pi_c^n\in\{1,2,3,...,M\}$ 是信道选择策略，M 为可接入信道数；$\pi_p^n\in\{0,1,2,...,k\}$ 是功率分配策略，k 为连续功率值量化等级，不同的等级代表不同接入功率的大小。换而言之，本章主要目标是在认知无线电网络中找到最优策略 $\pi^*=(\pi^1,\pi^2,...,\pi^n,...,\pi^N)$，使得神经网络将环境状态映射为包含信道和功率选择的二元数组 $a^n=(a_c,a_p)$，使智能体能够同时在这两个关键动作做出决策。环境中可用信道共有 M 个并且用户的发射功率量化为 k 个等级，因此每个用户在传输时有 $M\times k$ 种可能

中国知网 https://www.cnki.net

的动作。

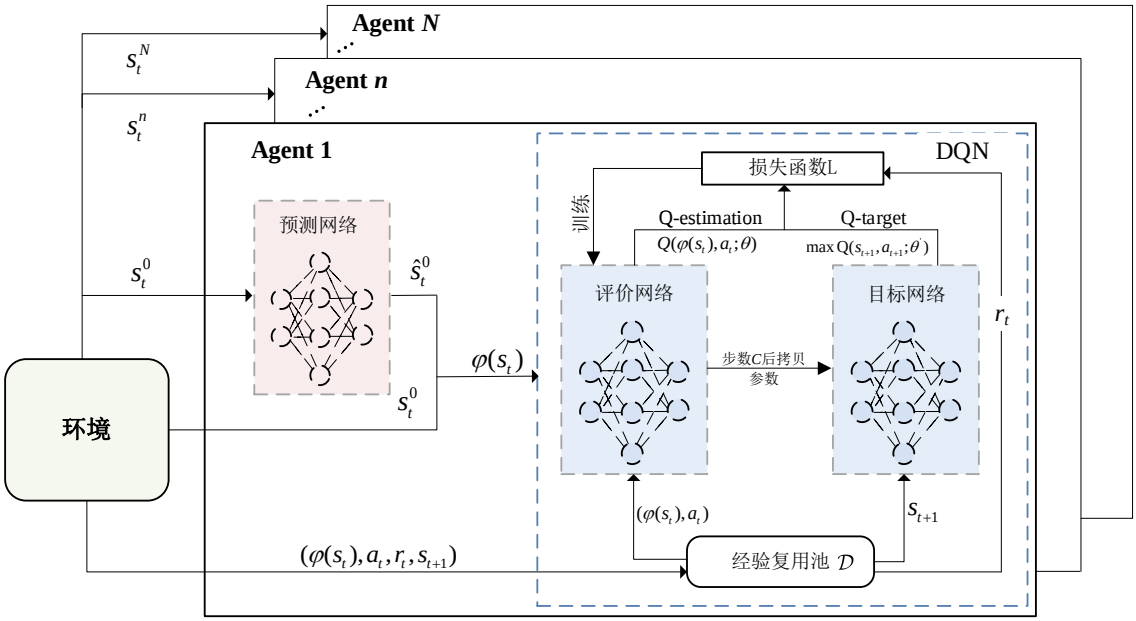

图 4-3 基于预测的深度强化学习频谱接入

奖励函数的设置要综合考虑次用户的传输速率和主用户干扰水平，因此在某一时刻次用户 n 的奖励函数设置为

$$r^n = C^n - \gamma \cdot \sum_{m=1}^{M} e^{\frac{I_{n,m}}{\hat{I}}} \tag{4.5}$$

其中，$I_{n,m} = p_{n,m} \cdot \left|h_{nn,m}\right|^2$ 表示主用户 m 所受干扰。$\hat{I}$ 为主用户承受干扰阈值，$\gamma \in (0,1)$，C^n 是次用户 n 的传输速率，表达式为

$$C^n = \sum_{m \in M} \log_2(1 + SINR_{n,m}) \tag{4.6}$$

智能体将当前频谱环境状态 $\varphi(s_t)$ 输入评价网络 θ_n，评价网络对当前状态下所有动作对应的 Q 值进行估计，根据 ε-*greedy* 策略以 ε 概率随机选择动作，以 1-ε 概率选择动作 $\arg\max Q_n(s_t^n, a_t^n; \theta_n)$。通过智能体不断的与环境交互得到每个时间 t 的状态转移序列 $e_t = (\varphi(s_t), a_t, r_t, s_{t+1})$，存储到经验复用池 $\mathcal{D} = \{e_1, e_2, ..., e_n\}$ 中，每次训练从 $\mathcal{D}$ 中随机抽取小批量样本，通过最小化评价网络的损失函数 $L(\theta_n)$ 来更新参数 θ_n，在每次迭代处的损失函数 $L(\theta_n)$ 计算公式为

$$L(\theta_n) = \mathbb{E}[y_n - Q(s_t^n, a_t^n; \theta_n)]^2 \tag{4.7}$$

其中

中国知网 https://www.cnki.net

$$y_n = \mathbb{E}[r^n + \gamma \cdot \max_{a_{t+1}^n} \mathrm{Q}^*(s_{t+1}^n, a_{t+1}^n; \theta_n^{'}) \mid s, a] \tag{4.8}$$

使用随机梯度采样的方式更新网络参数θ_n，公式如下：

$$\nabla_{\theta_n} L(\theta_n) = \mathbb{E}[(r^n + \gamma \max_{a_{t+1}^n} Q(s_{t+1}^n, a_{t+1}^n; \theta_n^{'}) - Q(s_t^n, a_t^n; \theta_n)) \nabla_{\theta_n} Q(s_t^n, a_t^n; \theta_n)] \tag{4.9}$$

目标网络参数$\theta_n^{'}$在一定步数后复制评价网络参数进行更新。

4.3.3 算法流程

综上所述，本章通过算法 4-1 描述了基于预测的深度强化学习频谱接入的整体过程。在每个时隙开始时，各智能体首先利用历史的频谱数据对主用户未来状态$\hat{s}_t$进行预测。预测模型作为后验模型嵌入环境中，与当前信道的统计信息组合成$\varphi(s_t)$作为智能体的输入状态。接着，智能体根据策略$\pi = (\pi^1, \pi^2, ..., \pi^N)$将做出信道选择$a_c$和功率大小决策$a_p$，并对其进行奖励大小的评估。所获状态转移序列$e_t = (\varphi(s_t), a_t, r_t, s_{t+1})$存储于经验复用池。在学习过程中，智能体随机采样经验池中数据并不断优化频谱接入策略，重复上述过程直至模型收敛得到最优分配策略(π_c^*, π_p^*)使得网络传输速率最大化。

算法 4-1：基于预测的深度强化学习频谱接入过程

输入: s_t

输出: 评估网络参数 θ_n，目标网络参数 θ_n'；最优策略 $\pi^* = (\pi_c^*, \pi_p^*)$

```
随机初始化学习率 α ，折扣率 γ，ε-greedy 中 ε，更新目标网络步数 C，
批处理大小 B，经验池大小 D
随机初始化评价网络和目标网络的参数
for t ∈ {1,2,...,T} do
    for n ∈ {1,2,...,N} do
        根据预测网络得到预测值 ŝt
        得到当前状态 φ(st)=(st, ŝt)
        根据 ε-greedy 选取动作 at=(ac, ap)
        执行动作 at, 获取下一时刻状态 st+1，并根据公式(4.4)获取奖励 rt
        存储 (φ(st), at, rt, st+1) 至经验复用池𝒟
        从𝒟中随机抽取维度为 B 的多维数组 (st, at, rt, st+1)
        根据公式(4.8)获取目标值 y
        根据公式(4.7)最小化损失函数来更新网络参数 θ
        每 C 步更新目标网络参数 θ′=θ
    end for
end for
```


中国知网 https://www.cnki.net

图 4-4 为所提预测辅助深度强化学习频谱接入算法流程图。

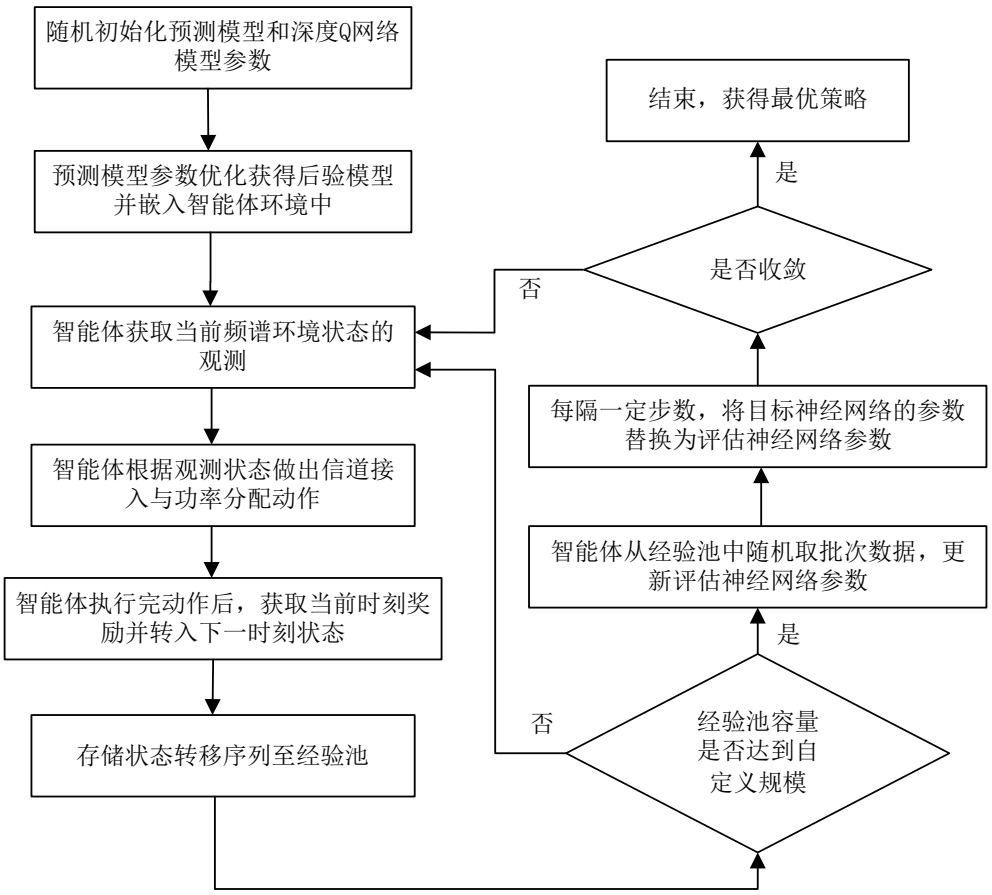

图 4-4 预测辅助深度强化学习频谱接入算法流程图

4.4 仿真与结果分析

4.4.1 仿真设置与评价指标

考虑由 5 个主用户、8 个次用户组成的动态频谱接入系统，次用户和主用户随机分布在 300m×300m 区域中。将训练总回合设置为 90，每个回合时间步设置为 100，学习率设置为 0.01，为了让次用户充分探索所有可能的策略，ε 的值取 0.9 并逐渐下降，连续功率值量化为 6，优化器为 Adam，经验复用池大小为 2000，批处理大小为 32，更新目标网络参数步数为 100。仿真实验基于 Python 3.7 的 Pytorch 0.13.1 框架进行开发，实验过程中使用 NVIDIA DeForce RTX2050 的独立显卡进行训练，表 4-2 为仿真中的参数配置。

中国知网 https://www.cnki.net

表 4-2 环境仿真参数

参数名称	值
场景范围	300×300m^2
主用户数量	5
次用户数量	8
训练回合数	90
学习率	0.01
ε	0.9→0.05
功率值量化值	6
经验复用池大小	2000
批处理大小	32
目标网络更新频率	100
功率值限制	300mW
干扰阈值	8×10^{-6}mW
优化器	Adam

选择 Dueling Network 作为深度强化学习神经网络，其主要包括特征提取层、价值层、优势层、输出层。特征提取层用于对输入状态进行转换和提取特征，经过线性层和 ReLU 激活函数输出 256 维特征表示；价值层以特征提取层输出为输入，经过维度 128 和 1 的线性层输出单一值表示的状态价值；优势层接收特征提取层的输出，经过 128 和 30 维的线性层，输出每个动作的优势值，30 是所有可能出现的动作数。输出层将价值层和优势层相结合，计算动作 Q 值。

频谱接入公平性指在共享频谱资源的情况下，不同用户或设备在频谱资源的分配和利用方面能够获得公平对待的机会。因此，确保高公平性对于提高用户满意度和社会资源利用公平性至关重要。在本章中，公平性指标计算公式如下：

$$Fairness = \frac{\left(\sum_{\mathrm{i}}^{N} Rate_i\right)^2}{N \times \sum_{\mathrm{i}}^{N} Rate_i^{\,2}} \tag{4.10}$$

其中 $Rate_i$ 表示第 i 个用户的传输速率，N 代表次用户数。若每个用户速率差异较小，则公平性较高；如果某些用户的速率远高于其他用户，则公平性较低。

4.4.2 仿真结果分析

图 4-5 比较了三种不同接入方法的系统总奖励，即所有用户奖励总和与训练步数之

中国知网 https://www.cnki.net

间关系。集中式接入方法因可以通过全局优化整个系统的性能，更容易进行节点的协同，所以结果最接近全局最优状态。基于预测的分布式接入相比于没有预测的频谱接入，其预测信息可提供未来频谱状态信息，使得次用户能够更智能的做出信道选择和功率分配，避免不必要的频谱切换来提高整体性能。经过 40 次迭代后收敛，总奖励与没有预测的分布式接入方法相比系统奖励提高了 15.5%。在相同回报值下，所提方法搜索次数减少了 56.2%。

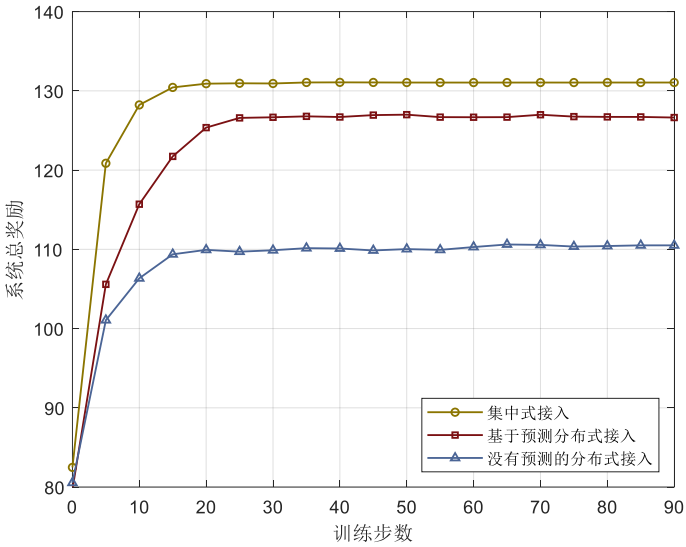

图 4-5 系统总奖励

图 4-6 展示了所有次用户总速率。在分布式模型中，次用户需要在提高传输速率与保持通信质量之间取得平衡。从图中可以看出，集中式接入由于存在中心控制在传输速率方面依然有出色表现。相比于没有预测的分布式接入，基于预测的频谱接入传输速率提高了 14.5%。

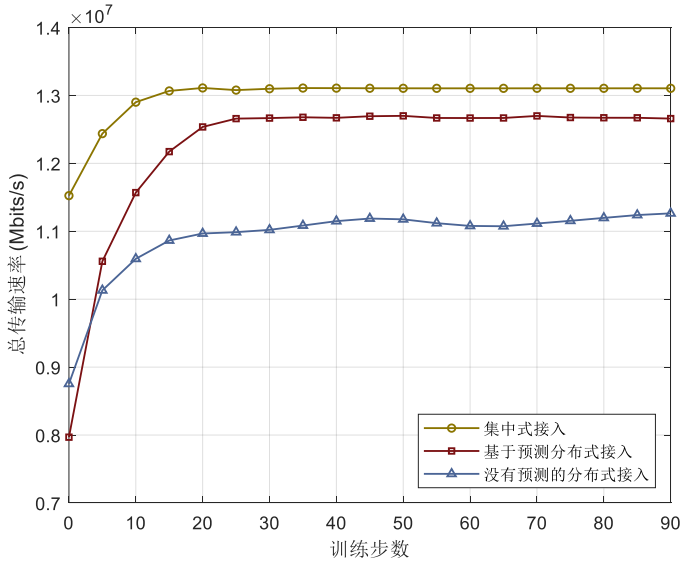

图 4-6 传输速率对比

中国知网 https://www.cnki.net

图 4-7 是三种接入方式公平性对比，从图中可以看出基于预测的分布式接入的公平性更高， 相比于没有预测的分布式接入提升了 5.1%。 通过预测信息对用户行为有深入的了解，各用户相对独立的进行资源分配和竞争，以满足用户不同需求，提升了公平性。

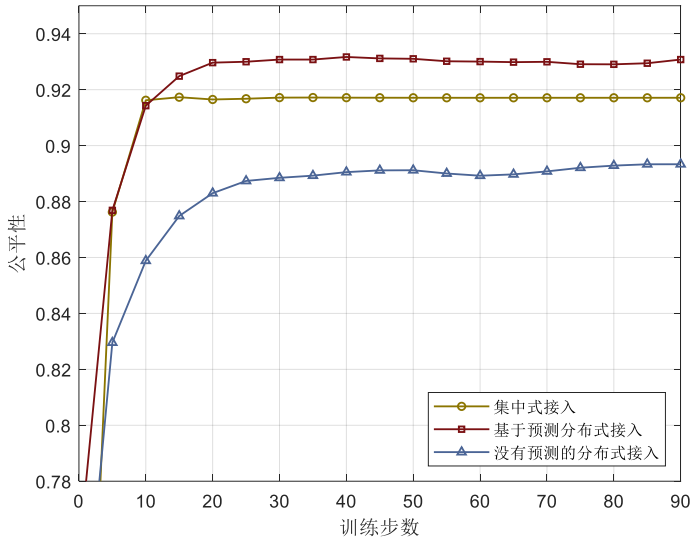

图 4-7 公平性对比

图 4-8 展示了主用户受到的干扰强度。从图中可以看出，基于预测分布式接入因能够预测未来用户行为，并据此调整资源分配策略，从而减少用户间干扰，呈现出较低的干扰强度变化趋势。经过 40 次迭代后趋于收敛，与对比算法比较分别减少了 34.7% 和 33.1%。

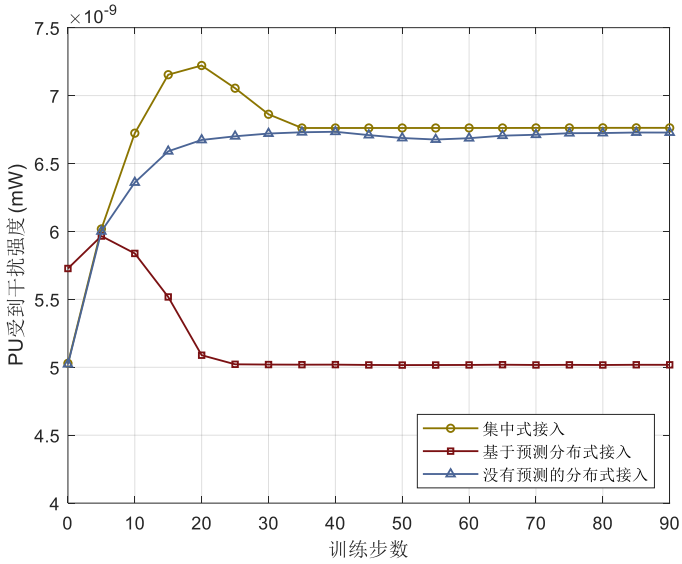

图 4-8 干扰强度对比

为了评估所提算法的鲁棒性，仿真比较了不同数量的用户场景下传输速率。如图 4-9 所示，随着可接入信道增加，系统总传输速率呈现明显增加趋势；在不同主次用户

中国知网 https://www.cnki.net

数情况下，基于预测的分布式接入在系统总传输速率方面表现出色，均优于对比算法。这表明本章提出算法的鲁棒性和适应性，即使在不同规模的用户配置下，算法依然能够有效提升系统性能。

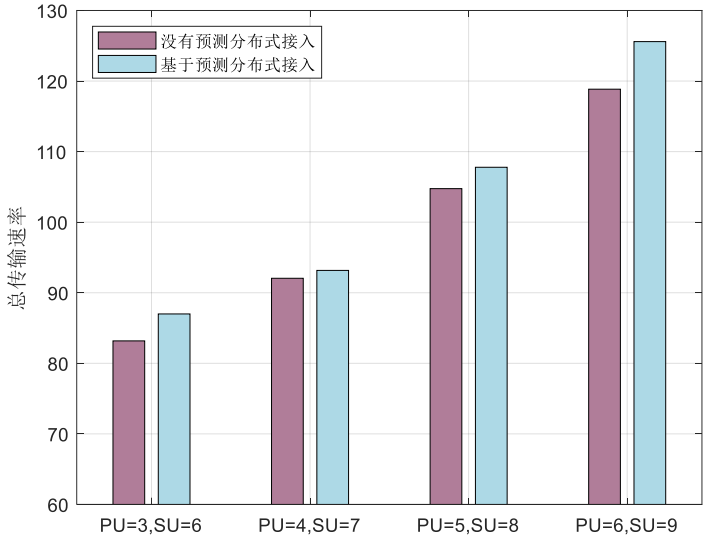

图 4-9 不同主次用户数总传输速率对比

4.5 本章小结

针对无线通信场景中主用户活动会影响频谱接入问题，提出了一种基于预测的动态频谱接入算法。该算法基于分布式动态频谱接入网络，通过融合主用户行为预测，将预测模型作为后验模型融入环境中。每个次用户同时做出联合信道接入和功率分配决策。仿真结果表明，该算法在传输速率、公平性和降低干扰方面相较于没有预测的频谱接入算法表现出明显优势，在系统总传输速率上提高了 14.5%，在相同回报值下，搜索次数减少了 56.2%。

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 论文工作总结

论文针对频谱数据时间关联挖掘问题、现有频谱预测模型待训练参数多、样本需求量大的问题以及基于预测的频谱接入问题，分别提出了基于小样本学习的算法，并通过基于实测数据的仿真分析验证了算法的有效性。本文开展了小样本情况下频谱预测技术和多用户多信道场景下频谱接入技术的研究与验证，主要工作及其创新总结如下：

1）针对实测频谱数据中时间相关性数据挖掘问题，构建了一种基于时间卷积网络的自迁移频谱预测模型，并在动态时间规整分析不同频段的相似性基础上，讨论了迁移学习的性能。仿真结果表明，所提模型与原始 TCN 网络相比有一定的性能提升，在评价指标 RMSE 和 MAE 上分别降低了 5.8%、4.2%。优化后 TCN 相比于 LSTM 和 CNN-LSTM 在 RMSE 上分别减少了 19.5 %和 18.8%，相比于 LSTM 在 MAE 上也减少了 14.6%。同时，在相似性差距较小情况下，使用迁移学习在一定程度上提高预测性能。

2） 针对频谱预测模型在训练时参数过多、训练样本量需求较大问题，提出了结合知识蒸馏和时间卷积网络的 TCN-KD 频谱预测方法。以预训练自迁移时间卷积网络为教师网络，以双分支神经网络为教师网络，通过知识蒸馏将复杂模型知识传递给双分支神经网络，所提方法相比于 LSTM 预测在样本充足情况下精确度提升了 19.5%，减少了 71.1%待训练参数，此外，在历史数据稀缺情况下，与门控循环单元相比预测准确性提高了 17.9%。

3） 针对次用户过度依赖频谱感知检测频谱空洞问题，提出了一种基于预测的深度强化学习频谱接入方法。该方法通过引入对主用户行为的预测，帮助智能体更快的学习和优化接入策略，并根据次用户传输速率和主用户受干扰情况同步优化信道选择和传输功率。仿真结果表明，所提方法在传输速率、公平性和降低干扰方面相较于没有预测的频谱接入算法表现出明显优势，在系统总传输速率上提高了 15.5%，在相同回报值下，搜索次数减少了 56.2%。

中国知网 https://www.cnki.net

5.2 展望

本论文针对复杂电磁频谱环境中样本稀疏和当前频谱利用率不高问题，分别探讨了智能电磁频谱管控领域中基于迁移学习的时间卷积网络频谱预测方法、基于知识蒸馏的小样本频谱预测方法、基于预测的深度强化学习频谱接入方法，仿真结果证明了所提算法的有效性和优越性。但由于环境和知识的限制，未来将结合当下研究热点，进一步考虑以下研究对现有成果进行完善：

1）本文研究的是实测频谱数据中时间相关性数据挖掘问题，将频谱预测扩展到频域、空间等维度将为模型提供更丰富的频谱信息，或将实测频谱数据与其他相关数据源进行融合，如天气状况、地理信息等，构建多维或多源的数据融合频谱预测模型，将有助于提高预测准确度。

2） 本文仅考虑了小样本情况下频谱状态信息预测，尚未涉及频谱行为预测与意图推理，然而，在资源有限的电磁频谱环境中，准确的理解用户的频谱使用意图至关重要。因此，未来可以考虑在小样本情况下，如何从频谱状态信息中推断用户的频谱使用的真实意图。

3）下一步研究除了进行仿真模拟外，还需要结合硬件平台和实际场景，开展实物或半实物仿真验证。根据不同场景下频谱使用特点构建相应模型，以应对不同频谱需求变化。

中国知网 https://www.cnki.net

参考文献

[1] 杨蔚, 高祺, 王渊, 等. 俄乌冲突中电磁频谱应用分析[J]. 航天电子对抗, 2023, 39(3): 1-4.

[2] Feng D, Jiang C, Lim G, et al. A survey of energy-efficient wireless communications[J]. IEEE Communications Surveys & Tutorials, 2012, 15(1): 167-178.

[3] Jasim S I, Akawee M M, Hasan R A. Spectrum sensing approaches in cognitive radio network[J]. Period. Eng. Nat. Sci, 2019, 7(4): 1555-1562.

[4] Cisco U. Cisco annual internet report (2018–2023) white paper[J]. Cisco: San Jose, CA, USA, 2020, 10(1): 1-35.

[5] Song H, Fang X, Wang C X. Cost-reliability tradeoff in licensed and unlicensed spectra interoperable networks with guaranteed user data rate requirements[J]. IEEE Journal on Selected Areas in Communications, 2016, 35(1): 200-214.

[6] Mitola J, Maguire G Q. Cognitive radio: making software radios more personal[J]. IEEE personal communications, 1999, 6(4): 13-18.

[7] 高向东, 郭晓莹. DARPA 着眼开发频谱共享技术[J]. 国际电子战, 2013, 00(4): 37-37.

[8] 王汝群 . 战场电磁环境 [M]. 北京 : 解放军出版社, 2006.

[9] Ercan, A O, Jiwoong L, Sofie P, et al. A Revenue Enhancing Stackelberg Game for Owners in Opportunistic Spectrum Access. 2008 3rd IEEE Symposium on New Frontiers in Dynamic Spectrum Access Networks, Chicago, IL, USA, 2008: 1-8.

[10] 张健美,赵杭生,柳永祥等.美军新型频管工具——全球电磁频谱信息系统浅析[C]//中国通信学会.2013年全国无线电应用与管理学术会议论文集.南京电讯技术研究所,2013:9.

[11] Shurbanov V. BBN Technologies Cambridge, MA[C]//Conference Record. Institute of Electrical and Electronics Engineers., 2004, 1: 34.

[12] Zhao Y, Morales L, Gaeddert J, et al. Applying radio environment maps to cognitive wireless regional area networks[C]//2007 2nd IEEE International Symposium on New Frontiers in Dynamic Spectrum Access Networks. IEEE, 2007: 115-118.

[13] Yarkan S, Arslan H. Binary time series approach to spectrum prediction for cognitive radio[C]//2007 IEEE 66th vehicular technology conference. IEEE, 2007: 1563-1567.

中国知网 https://www.cnki.net

[14] Akbar I A, Tranter W H. Dynamic spectrum allocation in cognitive radio using hidden Markov models: Poisson distributed case[C]//Proceedings 2007 IEEE SoutheastCon. IEEE, 2007: 196-201.

[15] Chang-hyun P, Sang-won K, Sun-rain L. HMM based channel status predictor for cognitive radio[C]//Proceedings of Asia-Pacific Microwave Conference. 2007.

[16] Yang X, Li Y. Analysis on the Performance of Spectrum Prediction in HF Communications[C]//2019 IEEE 19th International Conference on Communication Technology (ICCT). IEEE, 2019: 599-604.

[17] Rajendran S, Meert W, Lenders V, et al. Unsupervised wireless spectrum anomaly detection with interpretable features[J]. IEEE transactions on cognitive communications and networking, 2019, 5(3): 637-647.

[18] Taj M I, Akil M. Cognitive radio spectrum e volution prediction using artificial neural networks based multivariate time series modelling[C]//17th European Wireless 2011-Sustainable Wireless Technologies. VDE, 2011: 1-6.

[19] Yu L, Chen J, Ding G. Spectrum prediction via long short term memory[C]//2017 3rd IEEE International Conference on Computer and Communications (ICCC). IEEE, 2017: 643-647.

[20] Yin S, Chen D, Zhang Q, et al. Prediction-based throughput optimization for dynamic spectrum access[J]. IEEE transactions on vehicular technology, 2010, 60(3): 1284-1289.

[21] Gorcin A, Celebi H, Qaraqe K A, et al. An autoregressive approach for spectrum occupancy modeling and prediction based on synchronous measurements[C]//2011 IEEE 22nd International Symposium on Personal, Indoor and Mobile Radio Communications. IEEE, 2011: 705-709.

[22] Mennes R, Claeys M, De Figueiredo F A P, et al. Deep learning-based spectrum prediction collision avoidance for hybrid wireless environments[J]. IEEE Access, 2019, 7: 45818-45830.

[23] Ding G, Zhai S, Chen X, et al. Robust spectral-temporal two-dimensional spectrum prediction[C]//Machine Learning and Intelligent Communications: First International Conference, MLICOM 2016, Shanghai: Springer International Publishing, 2017: 393-401.

[24] Ge C, Wang Z, Zhang X. Robust long-term spectrum prediction with missing values and

中国知网 https://www.cnki.net

sparse anomalies[J]. IEEE Access, 2019, 7: 16655-16664.

[25] Ding G, Wang J, Wu Q, et al. Joint spectral-temporal spectrum prediction from incomplete historical observations[C]//2014 IEEE Global Conference on Signal and Information Processing (GlobalSIP). IEEE, 2014: 1325-1329.

[26] Yu L, Chen J, Zhang Y, et al. Deep spectrum prediction in high frequency communication based on temporal-spectral residual network[J]. China Communications, 2018, 15(9): 25-34.

[27] Aygül M A, Nazzal M, Ekti A R, et al. Spectrum occupancy prediction exploiting time and frequency correlations through 2D-LSTM[C]//2020 IEEE 91st Vehicular Technology Conference (VTC2020-Spring). IEEE, 2020: 1-5.

[28] Aygül M A, Nazzal M, Arslan H. Deep RL-based spectrum occupancy prediction exploiting time and frequency correlations[C]//2022 IEEE Wireless Communications and Networking Conference (WCNC). IEEE, 2022: 2399-2404.

[29] Kim S J, Giannakis G B. Cognitive radio spectrum prediction using dictionary learning[C]//2013 IEEE Global Communications Conference (GLOBECOM). IEEE, 2013: 3206-3211.

[30] Wang Y, Zhang Z, Yu Q, et al. A novel prediction-based spectrum allocation mechanism for mobile cognitive radio networks[J]. KSII Transactions on Internet and Information Systems (TIIS), 2013, 7(9): 2101-2119.

[31] Li X, Liu Z, Chen G, et al. Deep learning for spectrum prediction from spatial–temporal–spectral data[J]. IEEE Communications Letters, 2020, 25(4): 1216-1220.

[32] Lin F, Chen J, Ding G, et al. Spectrum prediction based on GAN and deep transfer learning: A cross-band data augmentation framework[J]. China Communications, 2021, 18(1): 18-32.

[33] Li K, Li C, Chen J, et al. Boost spectrum prediction with temporal-frequency fusion network via transfer learning[J]. IEEE Transactions on Mobile Computing, 2021, 22(6): 3209-3223.

[34] Lin F, Chen J, Sun J, et al. Cross-band spectrum prediction based on deep transfer learning[J]. China Communications, 2020, 17(2): 66-80.

[35] Peng C, Zhang M, Hu W, et al. Cross-band spectrum prediction algorithm based on

中国知网 https://www.cnki.net

transfer learning and meta learning[C]//2021 7th International Conference on Computer and Communications (ICCC). IEEE, 2021: 2303-2307.

[36] 郭军成, 万刚, 胡欣杰, 等. 太阳射电频谱爆发识别的元学习方法[J]. 系统工程与电子技术, 2022, 44(8): 2410-2418.

[37] Li T, Li J, Liu Z, et al. Few sample knowledge distillation for efficient network compression[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 14639-14647.

[38] Muthumeenakshi K, Radha S. A Generalized Markovian Based Framework for Dynamic Spectrum Access in Cognitive Radios[J]. KSII Transactions on Internet and Information Systems (TIIS), 2014, 8(5): 1532-1553.

[39] Qu Z, Qiao J, Zhu Q, et al. A Novel Dynamic Spectrum Access Framework Based on MC-SMSE for Cognitive Radio Network[C]//2018 Eighth International Conference on Instrumentation & Measurement, Computer, Communication and Control (IMCCC). IEEE, 2018: 723-727.

[40] 张静, 徐以涛, 丁国如, 等. 基于信道质量分析的动态频谱接入研究[J]. 通信技术, 2016, 49(9): 1181-1185.

[41] Liu X, Zhu R, Jalaian B, et al. Dynamic spectrum access algorithm based on game theory in cognitive radio networks[J]. Mobile Networks and Applications, 2015, 20: 817-827.

[42] Yao F, Jia L. A collaborative multi-agent reinforcement learning anti-jamming algorithm in wireless networks[J]. IEEE wireless communications letters, 2019, 8(4): 1024-1027.

[43] Morozs N, Grace D, Clarke T. Distributed Q-learning based dynamic spectrum access in high capacity density cognitive cellular systems using secondary LTE spectrum sharing[C]//2014 International Symposium on Wireless Personal Multimedia Communications (WPMC). IEEE, 2014: 462-467.

[44] Cha H, Kim S L. A reinforcement learning approach to dynamic spectrum access in Internet-of-Things networks[C]//ICC 2019-2019 IEEE International Conference on Communications (ICC). IEEE, 2019: 1-6.

[45] Cong Q, Lang W. Deep multi-user reinforcement learning for centralized dynamic multichannel access[C]//2021 6th International Conference on Intelligent Computing and Signal Processing (ICSP). IEEE, 2021: 824-827.

中国知网 https://www.cnki.net

[46] Shi Z, Xie X, Lu H, et al. Deep-reinforcement-learning-based spectrum resource management for industrial Internet of Things[J]. IEEE Internet of Things Journal, 2020, 8(5): 3476-3489.

[47] Chang H H, Song H, Yi Y, et al. Distributive dynamic spectrum access through deep reinforcement learning: A reservoir computing-based approach[J]. IEEE Internet of Things Journal, 2018, 6(2): 1938-1948.

[48] Yadav M A, Li Y, Fang G, et al. Deep Q-network based reinforcement learning for distributed dynamic spectrum access[C]//2022 IEEE 2nd International Conference on Computer Communication and Artificial Intelligence (CCAI). IEEE, 2022: 1-6.

[49] Jia L, Xu Y, Sun Y, et al. A game-theoretic learning approach for anti-jamming dynamic spectrum access in dense wireless networks[J]. IEEE Transactions on Vehicular Technology, 2018, 68(2): 1646-1656.

[50] Zeng L, Yao F, Zhang J, et al. Dynamic spectrum access based on prior knowledge enabled reinforcement learning with double actions in complex electromagnetic environment[J]. China Communications, 2022, 19(7): 13-24.

[51] Mosavat-Jahromi H, Li Y, Cai L, et al. Prediction and modeling of spectrum occupancy for dynamic spectrum access systems[J]. IEEE Transactions on Cognitive Communications and Networking, 2021, 7(3): 715-728.

[52] 陈曦, 杨健. 动态频谱接入中基于最小贝叶斯风险的稳健频谱预测[J]. 电子与信息学报, 2018, 40(3): 734-742.

[53] Eltholth A. Forward backward autoregressive spectrum prediction scheme in cognitive radio systems[C]//2015 9th International Conference on Signal Processing and Communication Systems (ICSPCS). IEEE, 2015: 1-5.

[54] Yin L, Yin S X, Hong W, et al. Spectrum behavior learning in cognitive radio based on artificial neural network[C]//2011-MILCOM 2011 Military Communications Conference. IEEE, 2011: 25-30.

[55] Wang X, Peng T, Zuo P L, et al. Spectrum prediction method for ISM bands based on LSTM[C]//2020 5th International Conference on Computer and Communication Systems (ICCCS). IEEE, 2020: 580-584.

[56] Zhang Y, Hu G, Cai Y. Proactive spectrum monitoring with spectrum monitoring data tra

中国知网 https://www.cnki.net

nsmission in dynamic spectrum sharing network: Joint design of precoding and antenna s election[J]. IET Communications, 2021, 15(18): 2265-2274.

[57] 孔青, 张建照, 柳永祥. 基于有意义扰动掩码的频谱预测解释方法[J]. 电讯技术, 2023, 63(10) :1500-1506.

[58] Wellens M. Empirical modelling of spectrum use and evaluation of adaptive spectrum sensing in dynamic spectrum access networks[D]. Aachen, Techn. Hochsch., Diss., 2010.

[59] 吴启晖, 丁国如, 孙佳琛. 电磁频谱数据挖掘理论与应用[M]. 科学出版社, 2020:82-87

[60] Harell A, Makonin S, Bajić I V. Wavenilm: A causal neural network for power disaggregation from the complex power signal[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 8335-8339.

[61] Chang S Y, Li B, Simko G, et al. Temporal modeling using dilated convolution and gating for voice-activity-detection[C]//2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 5549-5553.

[62] Ding G, Wu F, Wu Q, et al. Robust online spectrum prediction with incomplete and corru pted historical observations[J]. IEEE Transactions on Vehicular Technology, 2017, 66(9): 8022-8036.

[63] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J].Computer Science, 2015,14(7):38-39.

[64] 邵仁荣, 刘宇昂, 张伟, 等. 深度学习中知识蒸馏研究综述[J]. 计算机学报, 2022, 45(8): 1638-1673.

[65] 翟乃举, 周晓锋, 李帅, 等. 基于迁移学习和知识蒸馏的加热炉温度预测[J]. 计算机集成制造系统, 2022, 28(6): 1860.

[66] 张小燕,刘月峰.基于知识蒸馏压缩混合模型的航空发动机剩余寿命预测研究[J].计算机集成制造系统2022, 28(10): 1-25.

[67] Ay E, Devanne M, Weber J, et al. A study of knowledge distillation in fully convolutional network for time series classification[C]//2022 International Joint Conference on Neural Networks (IJCNN). IEEE, 2022: 1-8.

[68] Song H, Liu L, Ashdown J, et al. A deep reinforcement learning framework for spectrum management in dynamic spectrum access[J]. IEEE Internet of Things Journal, 2021,

中国知网 https://www.cnki.net

8(14): 11208-11218.

[69] Kumar Acharya P A, Singh S, Zheng H. Reliable open spectrum communications through proactive spectrum access[C]//Proceedings of the first international workshop on Technology and policy for accessing spectrum. 2006: 5-es.

[70] 鲜永菊, 吴东伟. 认知无线电中基于灰色系统的频谱预测机制研究[J]. 计算机应用研究, 2010 (12): 4726-4728.

[71] Li Y, Wang Y, Li Y, et al. Multi-User Dynamic Spectrum Access Based on LRQ Deep Reinforcement Learning Network[C]//2023 25th International Conference on Advanced Communication Technology (ICACT). IEEE, 2023: 79-84.

中国知网 https://www.cnki.net