基于深度学习的频谱智能管控技术发展思考

张有志

（某项目中心，北京 100071）

【摘　要】　首先介绍了基于深度学习的智能化技术和频谱管控技术的基本原理。然后基于频谱管控的OODA循环，介绍了深度学习技术在频谱智能感知、频谱智能认知、频谱智能决策等场景下的应用情况。最后结合OODA循环，从频谱感知认知、频谱决策生成、频谱决策执行等角度，对深度学习技术在频谱管控领域的发展提出建议。

【关键词】　频谱管控；深度学习；人工智能

doi:10.3969/j.issn.1006-1010.20230926-0001　　中图分类号：TN929.5
文献标志码：A　　文章编号：1006-1010(2024)08-0129-08
引用格式：张有志. 基于深度学习的频谱智能管控技术发展思考[J]. 移动通信, 2024,48(8): 129-136.
ZHANG Youzhi. Thoughts on the Development of Deep-Learning Based Intelligent Spectrum Management and Control[J]. Mobile Communications, 2024,48(8): 129-136.

OSID：扫描二维码与作者交流

Thoughts on the Development of Deep-Learning Based Intelligent Spectrum Management and Control

ZHANG Youzhi

(A Project Center, Beijing 100071, China)

[Abstract]　Firstly, the basic principles of intelligent technology and spectrum management technology based on deep learning are introduced. Then, based on the OODA loop of spectrum management and control, the applications of deep learning technology are presented in the scenarios such as spectrum intelligent perception, spectrum intelligent cognition, and spectrum intelligent decision-making. Finally, based on the OODA loop, some suggestions are provided on the development of deep learning technology in the fields of spectrum management and control from the perspectives of spectrum perception and cognition, spectrum decision generation, and spectrum decision execution.

[Keywords]　spectrum management and control; deep learning; artificial intelligence

0　引言

电磁频谱是一种特殊的自然资源，其自身不具有消耗性，也不存在可再生性的问题。但是，电磁频谱在一定的频段、时间和空间内的可用量是有限的。随着人类对电磁频谱的利用越来越广泛，电磁频谱资源的竞争也越来越激烈。伴随着无线通信技术的发展以及移动互联网等业务的兴起，用频设备的数量和用户对带宽的需求不断增加，有限的频谱资源总量和急剧增加的频谱资源需求之间的矛盾日益突出。

近年来，人工智能技术在各领域展现出独有的发展潜力，并且深刻改变着社会生产和思维模式。频谱管控技术也在人工智能浪潮的推动下加快了智能化发展的步伐。频谱智能管控是一种利用人工智能技术对无线电频谱进行管理和控制的方法，这种智能性体现在用频数据处理、用频行为推理、用频策略生成等多个管控相关的方面。例如，在处理用频数据时，通过智能算法同时从时、频、空等多个维度感知电磁频谱资源态势。推理用频行为时，借助人工智能的主动推理能力实现频谱数据信息到用频行为意图的转换，并且能够预测未来一段时间内的用频行为。生成用频策略时，可以采用智能算法对频谱资源进行动态分配和调度，以实现频谱资源的最优配置和最大化利用。

深度学习作为一种典型的智能化技术，正在频谱管控领域发挥着重要的作用。借助于海量的频谱监测数据，深度学习能够最大化地发挥其数据驱动模式的优势，充分挖掘历史数据中隐含的频谱行为，有助于实现

收稿日期：2023-09-26

中国知网 https://www.cnki.net

更加精准高效的频谱管控模式。目前已有大量的研究工作关注深度学习在频谱信号分析、频谱态势感知、用频行为预测等管控相关问题中的应用，充分展示了深度学习在任务准确度上的优势。现阶段采用的深度学习方法在可解释性、数据隐私、模型偏见等方面还具有一定的改进和提升空间，这也为频谱智能管控在未来的发展提出了新的课题。本文尝试技术角度对深度学习在频谱管控领域中的发展进行探讨，并且给出发展建议。

1 基于深度学习的智能化技术

深度学习是一种机器学习方法，其本质上是一个多层的神经网络，利用给定的数据资料进行训练，获取数据中隐含的统计规律信息，并将这些信息用于后续的决策任务。传统的智能化技术依赖于领域先验信息或者人工经验，这些先验信息或者经验体现在繁杂的数据预处理方法以及算法的约束条件中。以深度学习为代表的一类智能化方法，采用数据驱动的算法优化模式，利用训练数据自动完成表征学习，从而避开了领域先验信息或者人工经验对智能算法的性能限制。

基于深度学习的智能算法开发流程如图1所示。模型训练阶段使用训练数据对深度学习模型进行优化。模型训练结束后，把测试数据送入深度学习模型获取测试结果并计算任务性能指标。根据指标结果可以从数据采集、网络结构、优化策略等不同的方面入手，进一步提升算法性能。整个过程无须手工设计特征提取算法，网络在训练阶段会自动获取数据中隐含的与当前任务相关的特征信息。

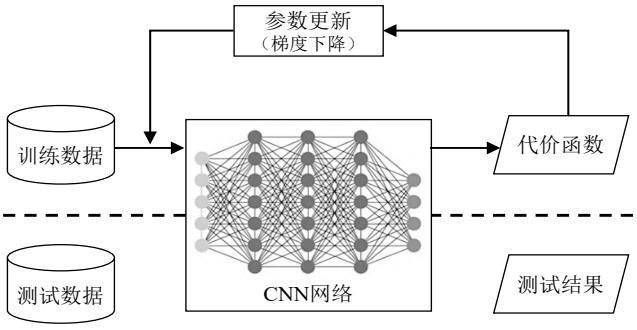

图1　基于深度学习的智能算法开发流程

深度学习的一个典型实例是卷积神经网络（CNN，Convolutional Neural Network）。CNN是一种前馈神经网络，在结构上和图片的空间结构更为贴近，都是二维的结构。CNN最初是为解决图像识别等问题设计的。早期研究工作中最大的挑战是如何通过人工经验有效地提取并组织图像特征。卷积神经网络可以在训练中自动完成特征提取，显著降低了应用图像识别的难度。除了图像识别，深度学习也逐渐被引入语音识别、自然语言处理等领域，促进了相关应用领域的发展。

2 频谱管控技术内涵

频谱管控是指对电磁频谱资源的使用进行预先筹划、常态监测、动态协调，保障电磁频谱资源的合理分配和安全使用，最大化满足用频需求。频谱管控需要频谱感知、频谱认知、用频决策、用频协同等多种技术能力共同协作，协作的整个过程可以采用OODA循环的形式来实现。

OODA循环是一种用于描述决策过程的模型，该模型包括观察（Observe）、定位（Orient）、决策（Decide）、行动（Act）等四个阶段。图2展示了一个完整的OODA循环。实际操作中可能会发现观察到的信息和预期的不同，此时需要重复进行OODA循环，及时调整决策和行动以适应不断变化的环境。

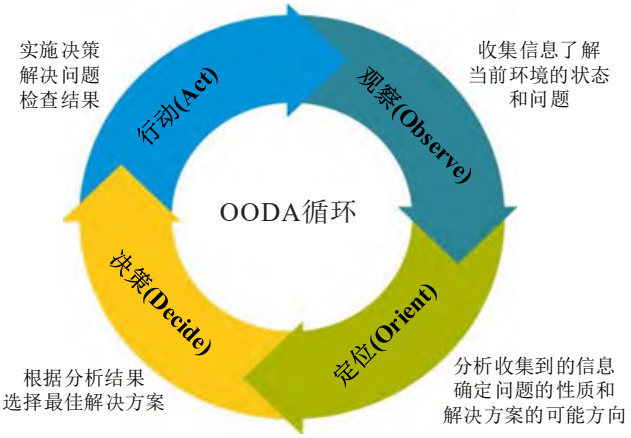

图2　OODA循环示意图

对于频谱管控，OODA循环的四个阶段需要分别完成下面的任务：

（1）观察（Observe）：对频谱使用情况进行监测和观察，以了解当前的频谱使用情况。

（2）定位（Orient）：分析观察到的数据，进一步获取与用频行为有关的信息，为后续的用频决策提供依据。

（3）决策（Decide）：根据判断结果制定频谱管理策略，并决定如何分配频谱资源。

（4）行动（Act）：可以将决策结果付诸实践，对频谱资源进行管理和分配。

随着无线通信技术的发展，用频业务量急剧增加，电磁环境日益复杂，频谱管控也面临着资源紧张、干扰频繁等挑战。因此，频谱管控技术也需要不断地更新和

中国知网 https://www.cnki.net

完善，以满足不断变化的用频需求和管控挑战。近年来，在人工智能、大数据、云计算等新兴技术的加持下，频谱管控正在从粗放低效的人工模式向精准高效的智能模式转变，通过加快OODA循环执行效率实现频谱资源的最大化利用和优化配置。

3 深度学习在频谱管控OODA循环中的应用

在频谱管控OODA循环中，目前除了最后的“A”环节，其他的环节均有深度学习相关的研究成果。根据不同工作的应用领域，在图3中列出了目前深度学习在OODA循环各阶段中的应用情况：

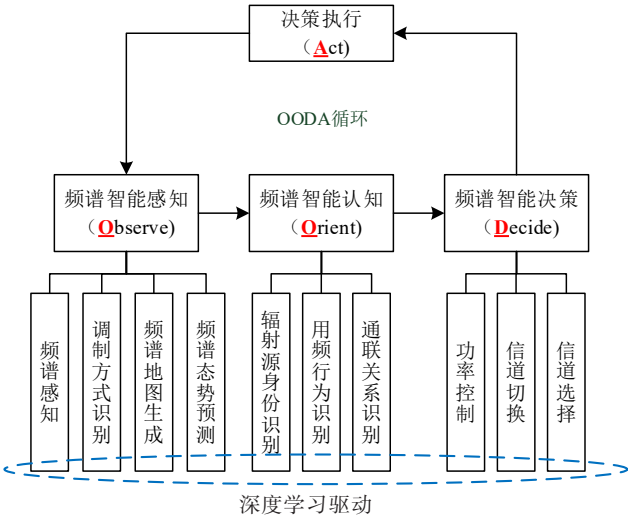

图3 深度学习在频谱管控OODA循环中的应用

第一个“O”完成频谱智能感知。频谱智能感知以信号特征提取和信号分析为主。在感知领域有大量的原始频谱数据可用，使得深度学习较容易地使用在频谱感知任务中。大量的研究工作也关注于深度学习在频谱感知中的应用。

第二个“O”和第三个“D”分别完成频谱智能认知和频谱智能决策。这两个部分需要获取任务相关的信息，例如用户身份、通联关系、用频决策等。不过与频谱感知相比，认知和决策是相对“高级”的智能技术，也是实现智能频谱管控的核心，当然在实现上也具有相当的难度。

3.1 频谱智能感知（Observe）

频谱智能感知的主要目的是获取频谱资源的使用情况。这个阶段涉及的主要任务有频谱感知、调制识别、频谱地图生成、频谱态势预测等。

（1）频谱感知

为了能够提高频谱利用效率，认知用户（SU, Secondary User）可以在授权用户（PU, Primary User）空闲时使用其频段完成通信任务。为此，SU需要检测PU是否在使用自身的频段。

经典的检测方法有匹配滤波、能量检测、循环平稳特征等。这些方法或多或少依赖于应用领域先验信息以及人工经验，在面对应用场景的限制（例如无法获知PU信号的参数）以及多变的信道环境（例如噪声、选择性衰落）时感知性能会受到不同程度的影响。

近年来有部分工作引入CNN，通过数据驱动的方式挖掘信号中隐含的丰富特征信息，进一步提升频谱感知性能。例如文献[1]设计了一个从信号协方差矩阵预测检验统计量的CNN模型，该模型利用最大后验概率作为代价函数进行优化。基于提取的统计量，作者根据Neyman-Pearson引理得出了似然比检验方法用于完成信号检测，并且对方法的有效性进行了理论分析。文献[2]直接把感知过程设计为从输入数据到二分类结果的映射，利用CNN网络预测PU是否在使用自身频段，无需预测检验统计量，简化了预测流程。通过在CNN的基础上加入LSTM（长短时记忆网络）和DNN（全连接深度网络），在同时提取信号频域和时域相关特征的基础上增强了特征变换能力。文献[3]以Choi-Williams时频分布变换结果作为输入，实现了8种雷达波形的识别。

为了实现更高效的频谱感知，可以同时对不同频带区间的信号进行感知。此时需要解决宽带频谱感知问题。文献[4]把感知频带范围内每个子带的协方差矩阵送入CNN学习不同子带间的相关性信息，同时结合信号能量、多天线相关性等信息实现频谱感知。文献[5]使用Faster R-CNN目标检测网络实现了Wi-Fi信号的感知，并且就Faster R-CNN的设计对感知性能的影响进行了分析。文献[6]基于YOLO目标检测网络设计了WRIST方法，实现了100 MHz带宽内5种通信制式（蓝牙、Lightbridge、Wi-Fi、XPD和ZigBee）的感知。

（2）调制方式识别

近年来有部分工作利用CNN实现信号特征的自动提取以及调制识别，避免了复杂的人工特征设计过程，并且获得了显著的性能提升。O`Shea等[7]以IQ信号作为输入，使用了一个4层的CNN网络实现调制方式识别，识别精度优于许多传统方法。Yashashwi等[8]设计了可训练的偏移校正模块，在把IQ信号送入CNN前对信号进行频率和相位偏移校正。Huang等[9]对IQ信号进行了旋转、翻转、加噪等操作，扩充了训练样本数量。这些改进进一步提升了识别准确度。Kulin等[10]针对不同SNR的情形研究了IQ序列、幅度/相位序列和FFT序列三种数据形式对

中国知网 https://www.cnki.net

识别性能的影响。

CNN的结构与二维图像数据有直接的对应关系，因此有部分方法把信号序列变换到图像域进行调制识别。时频图能够直观展现不同时间和频率范围内信号的分布情况，并且不同调制方式的信号在时频图上呈现出特有的纹理图样。借助这个特性，利用图像目标检测网络可以同时对宽频带范围内多个信号的调制方式进行识别[11]。星座图是IQ信号映射到二维复平面后形成的散点图。每种调制方式具有特定的星座图样式，因此可以利用CNN对星座图样式进行分类从而实现调制方式识别[12]。此类方法能够更好地识别较高阶调制方式（例如64QAM），相应地对于信号质量也具有较高的要求。例如文献[13]把信号特征量（例如峰均比、瞬时幅值偏度峰度、高阶统计量等）映射到复平面上，利用不同调制方式在复平面上数据分布的差异完成识别。文献[14]对不同调制方式的信号绘制模糊函数（Ambiguity Function）的二维平面图，利用CNN提取不同调制方式的模糊函数实现自动识别。基于循环稳态特性，文献[15]计算信号的频谱相关函数（SCF, Spectral Correlation Function），获得信号频率与循环频率的关系并转化为二维图像进行调制方式识别。

（3）频谱地图生成

受限于成本等因素，频谱数据的采集通常发生在离散的时间点、频段和空间位置，感知数据呈现出碎片化局部化的特点。构建频谱态势前，需要对离散化的感知数据进行补全，生成电磁频谱地图（RadioMap）。深度学习在频谱地图生成的应用主要包括三类方法：自编码器、卷积神经网络和生成对抗网络。

基于自编码器的频谱地图生成方法是将输入数据映射到隐空间，然后从隐空间解码出完整的数据，实现数据补全[16-17]。自编码器可以从大量的训练数据中学习到信号传播和衰减特征，从而在没有明确物理模型的情况下预测环境电磁强度分布。模型的性能较多地依赖于网络架构和参数的选择，可能涉及大量的试错过程。

基于卷积神经网络的频谱地图生成方法指利用卷积神经网络进行空间缺失值预测，完成数据插值[18-19]。空间插值能够自动学习频谱数据的局部和全局分布模式，使网络表现出较好的适应性和泛化能力。对于采样点极为稀疏的情况，网络预测准确性可能会受到影响。

基于生成对抗网络的频谱地图生成方法由生成器生成原始数据，由判别器判断不同数据之间的相似性，通过生成器和判别器的博弈从而优化模型[20]。生成对抗网络具有强大的非线性拟合能力，能够有效模拟复杂的电磁传播环境，但是训练过程较为复杂且过程不稳定。

（4）频谱态势预测

在已有感知数据的基础上，可以进一步挖掘用频规律，预测未来一段时间内频谱态势的变化趋势。传统方法主要从时间、频率、空间等维度出发，采用人工经验构建数学模型处理感知数据，预测频谱资源的使用状况。这类方法受限于模型的复杂性，无法有效利用数据中隐含的其他维度的特征信息。近期的方法主要采用深度学习实现频谱态势预测，通过递归网络[21]、长短时记忆网络[22]等技术手段从数据中抽取隐含的特征信息，获得更高精度的预测结果。

3.2 频谱智能认知（Orient）

频谱智能认知的主要目的是对频谱智能感知阶段获取的数据进行进一步处理，得到与当前频谱监测任务相适应的更高层级的用频信息，例如辐射源身份、用频行为、通联关系等。

（1）辐射源身份识别

辐射源身份识别是指从接收信号中提取能够反映辐射源个体差异的特征信息，并结合先验信息判断辐射源的身份。传统方法主要利用信号瞬态参数、瞬态能量分布等人工特征“指纹”进行身份识别。这种方法在面对辐射源发射模式（如信号参数、信道环境等）变化的情况时，所提取的指纹特征也会变得不稳定，进而影响识别准确度。目前有大量的研究工作转向基于深度学习的辐射源身份识别方法。采用数据驱动的模式让CNN从信号中自行寻找能够反映设备独特性的特征信息。根据输入数据的类型，基于深度学习的辐射源身份识别方法主要分为基于时域数据的方法和基于图像数据的方法。

基于时域数据的射频指纹识别方法利用接收的IQ信号作为深度网络的输入，CNN从IQ信号中直接提取指纹特征。文献[23]运用时域数据对三种LoRa设备的射频符号，使用CNN识别每个信号的发射源，同时还与支持向量机和传统多层神经网络进行性能比较，展示了CNN在性能上的优势。文献[24]利用CNN识别不同的ZigBee设备以识别仿冒的通信用户，他们利用时域复基带误差信号作为输入。文献[25]采用把复值时间序列送入复值CNN网络的方法解决Wi-Fi设备和ADS-B设备的识别问题。直接输入IQ信号进行辐射源识别，可以免去复杂的数据预处理流程，利用CNN直接学习IQ信号到辐射源个体的映射关系，但是训练过程中会捕获IQ信号中的噪声数据，容易出现过拟合的问题。

基于图像数据的方法是把时域IQ信号经过处理变换

中国知网 https://www.cnki.net

成二维数据的形式，并将其作为图像送入CNN完成个体识别。文献[26]使用STFT变换获得时频图作为CNN的输入实现了对5种辐射源的识别。文献[27]把时域信号转换为递归图送入CNN网络，对同一型号的多个物联网设备进行识别。文献[28]提出使用差分星座跟踪图（DCTF）作为CNN的输入提取指纹特征。文献[29]研究了辐射源导致的信号畸变与信号矢量图样式之间的关系，利用CNN网络读取接收信号的矢量图来预测信号对应的辐射源个体。把时域IQ信号通过变换得到类似图像的数据通常能提取到更复杂有效的指纹特征差异，但是局限于现阶段对信号数学模型和辐射源机理的认知，这些方法具有较强的尝试性，主要通过实验方式确定。

（2）用频行为识别

本文所提的用频行为是指与频谱资源使用有关的活动，例如通联规律、通信建链过程等。最直观的用频行为识别方式是直接对捕获的用频数据进行内容解析与识别。这种做法对数据质量具有较高的完整性要求，复杂的数据解析处理操作也会影响识别结果的实时性。

文献[30]证明了在不了解信号内容、信号形式等具体技术细节的条件下，可以直接利用频谱感知数据所呈现出的特征实现对用频行为的识别。该成果为深度学习等的人工智能方法在用频行为识别中的应用提供了可行性依据，并促成了基于深度学习的用频行为识别方法的快速发展[31]。

文献[32]和[33]把频谱感知数据转化为二维伪图像数据，利用DenseNet、LeNet等深度网络，实现非合作条件下的短波通信建链行为预测，无需对频谱感知数据进行解密等预处理。深度学习对训练数据量具有较高的要求，实际应用中数据的采集与获取成本会限制深度学习技术的应用。文献[34]直接采用生成对抗网络生成训练样本，有效提升了相同网络模型的用频行为识别精度。文献[35]针对所研究频段训练样本数据不足的情况，结合迁移学习与生成对抗网络，利用其他频段的具有相似用频行为的数据，生成所研究频段的数据。

与频谱感知、辐射源身份识别等问题相比，当前利用深度学习技术解决用频行为识别问题的最大挑战是缺乏训练数据。前述工作采用数据增强的方法能够在一定程度上缓解困境，但是模型的计算成本有所增加。因此，根据实际场景的先验信息和数据条件，提出相适应的用频行为分析方案仍然是一个挑战。

（3）通联关系识别

通联关系通常是指不同用频实体之间因通信业务往来而产生的关系。在拥有用频规则、用频协议等先验信息的前提下，对频谱感知数据进行多域特征提取和统计，进行关联性分析，可以获得通联关系[36]。在能够直接获取相当数量的频谱感知数据时，可以采用数据驱动的方式进行通联关系挖掘。具有代表性的方法是基于聚类的通联关系识别[37-38]，这类方法利用信号分布规律或者信号特征统计信息，采用聚类算法对数据进行处理，然后采用关联匹配的方法得出通联关系。

基于深度学习的通联关系识别方法[39]，直接采用原始的频谱感知数据作为输入，通过深度网络得出通联关系。与基于聚类的方法相比不需要预先提取信号特征，能够较容易地实现快速的通联关系识别。此外，与聚类方法不同，深度学习技术对数据中的干扰因素具有一定的鲁棒性，训练过程中对很高质量的监测数据并没有明确要求。

3.3 频谱智能决策（Decision）

频谱智能决策是指在频谱资源和用频规则的约束下，基于频谱感知数据以及从数据中衍生出的信号特征、用频行为、资源占用等信息，提供新的频谱资源使用建议，优化频谱资源的使用配置。用频策略生成本质上是一个最优化问题，通过调整频谱特征参数（频率、功率、波形参数等）最大化频谱操作效用。传统的用频策略生成方法主要是采用博弈论、图论、拍卖理论等方法[40]构建用频策略数学模型并进行求解。

深度学习方法的实质是训练一个深层神经网络去拟合训练数据集，并且使网络具备一定的泛化性，能够对训练集以外的数据产生正确的预测结果。从这个角度看，深度学习方法也是在求解一个最优化问题。因此，可以采用深度学习实现频谱智能决策任务。文献[41]使用遗传算法生成的数据训练深度网络，使其具备对频谱资源决策能力。文献[42]使用深度网络实现对用户发射功率的自适应调整，有效地实现了相同频谱资源在不同用户之间的共享。

在深度学习的基础上，深度强化学习方法逐渐引入到用频策略生成中。深度强化学习是深度学习和强化学习两种方法的结合。一方面，考虑到频谱特征参数之间较为复杂的关系，使用深度学习方法能够避开参数建模过程，直接构建频谱分析数据到用频策略的映射关系。另一方面，用频环境是动态变化的，用频策略的生成也应该适应这种变化。强化学习方法通过智能体（用频策略生成算法）与外界环境（电磁频谱空间）的互动，调节智能体的策略生成结果，从而达到学习目的。目前，深度强化学习的有效性在功率控制[43]、信道切换[44]、信道选择[45]等问题上得到了验证。

中国知网 https://www.cnki.net

4 对频谱智能管控技术发展的思考

以深度学习为代表的智能算法已经在频谱智能管控领域展示了发展潜力，相关的技术研究以及工程应用也成为了近两年关注的热点。深度学习技术在展现出性能优势的同时，也为频谱管控领域的研究以及工程应用带来新的挑战。

本节基于频谱管控OODA循环，从频谱智能感知、频谱智能认知、频谱智能决策、频谱决策执行等角度出发，考虑智能管控领域的发展思路，推动频谱智能管控技术的发展。

4.1 频谱智能感知与认知——建立高质量电磁数据集

频谱感知与认知能力是频谱决策等后段能力的基础。目前，深度学习技术在频谱感知与认知方面已经积累有大量的研究成果。然而，在真实环境中，复杂的电磁环境导致频谱数据的多样性，为深度学习技术的应用带来了挑战。

首先，真实环境的电磁信号在采集过程中容易受到采集设备自身条件以及采集环境电磁空间的影响。考虑到电磁环境的时变特性，异常罕有模式信号难以获取，导致相应的样本数据缺乏，进而会影响到对异常用频事件的感知。针对这个问题，可以考虑在频谱数据库中纳入计算机仿真数据，以较低的成本扩大样本规模，缓解数据量不足的问题。

其次，算法的训练需要以数据中的标注信息作为监督，标注的质量会对训练效果产生较大的影响。上述问题导致带标注的可信数据集难以建立，制约了高性能算法的设计与部署。工程应用中可以通过规范数据类型和标注格式的方法，以不同渠道来源的真实信号重构频谱管控信息数据库，为智能算法开发提供可靠的数据集；也可以引入半监督、无监督等新式机器学习方法，绕开数据质量对算法部署的限制。

4.2 频谱智能决策——在算法创新与算法可靠性上发力

频谱智能决策技术研究的目标是让系统能够根据频谱感知和认知结果，自动生成符合当前用频环境和资源状况的频谱决策。深度学习技术在频谱智能决策问题上已经展现出了其独特的优势，能够在一定程度上克服依赖人为设定、突发情况应对不足的缺点。面对复杂多变的电磁环境，现有的频谱决策方法在管控方法的创新性、可靠性等方面仍然具有一定的提升空间。

（1）在现有技术基础上探索新式智能管控算法

目前深度学习算法以离线式学习模式为主，这种模式下需要预先准备训练数据。在频谱大数据利用过程中，往往存在网络状态以及环境条件快速变化的问题，这种问题会使得预先采集的数据无法对应到新的电磁频谱环境。此时可以考虑引入强化学习（Reinforcement Learning）技术。强化学习以在线的方式动态完成“学习—决策—执行”的流程，较少依赖于先验环境信息，可以实现边学边用。通过结合深度学习和强化学习，能够进一步提升智能算法对动态电磁频谱环境的适应性，有助于实现信道调整、功率控制等决策任务。

目前深度学习算法是在训练和测试数据同分布的假设下运行的。频谱感知设备和地理频谱数据库的数据具有异质化的特点，可能导致训练和测试阶段使用的数据在格式以及统计分布上产生差异，导致数据同分布假设不再成立。迁移学习（Transfer Learning）技术能够突破训练测试数据同分布的限制，应用先前学到的知识来更快速地解决新遇到的问题。对于频谱大数据利用而言，迁移学习可以基于自身的知识迁移能力，快速适应不同电磁频谱环境下的决策问题，有助于实现更好的频谱智能管控。

（2）实现知识和数据双驱动的智能频谱管控

深度学习采用数据驱动的方式实现智能算法，这种方式只能让算法“理解”数据中所呈现的规律，这些规律可能与客观现实之间存在偏差，影响算法在实际环境中的鲁棒性和泛化能力。引入知识信息可以在一定程度上缓解深度学习过度依赖数据的现状。通过把频谱管控领域的专家知识信息嵌入到深度学习算法中，让模型进一步利用知识信息优化决策过程，从而提高模型的性能和泛化能力，实现数据和专家经验混合驱动的频谱智能管控。

（3）研究可信度可解释度高的智能管控方法

对于实现频谱智能管控系统中人机交互，促进人机协同工作至关重要。深度学习技术的核心是基于多层神经网络的数据表征学习技术。多层神经网络内部连接复杂难以用数学表达式准确描述，使用过程中通常被当作“黑盒子”，只关注输入输出是否符合预期。这种“黑盒子”特性使得用户无法真正掌握输入输出之间的具体关系，最近有关深度网络遭受对抗性攻击的研究[46]说明了这种“黑盒子”特性会影响深度学习技术的安全性。在频谱管控流程的决策阶段，模型算法的可解释性会影响决策结果的可信度。在复杂多变的电磁环境下，频谱数据可能会包含不完全的或者虚假的信息。提高模型的可解释性有助于掌握决策过程机理，降低信息对决策结果的影响，提升决策结果的置信度。

4.3 频谱决策执行——探索用频决策智能化执行

在频谱管控OODA循环中，最后的执行阶段

中国知网 https://www.cnki.net

（Act）负责执行用频决策。在复杂快变电磁环境下，执行阶段接收到的用频决策信息有可能失效，为此需要进一步探索用频决策智能化执行机制。一方面，可以引入执行结果反馈机制，从被动执行固定用频决策向策略动态调整转变，使得决策执行过程能够适应外界电磁环境的快速变化。另一方面，在多个用频系统共存的环境下，每个用频系统有自己单独的OODA循环。此时，可以在不同用频系统的OODA循环直接建立协同机制，在各用频系统完成决策后，通过执行阶段的协同处理，实现不同用频系统直接的信息交互，提升多个用频系统的整体用频效能。

5 结束语

深度学习作为一种典型的人工智能技术，正逐渐在频谱智能管控领域中发挥重要作用。频谱态势感知、用频行为预测、用频策略生成等具体问题中，深度学习的应用也成为了近几年的研究热点，并且在工程应用方面取得了一定的成效。本文从频谱管控OODA循环出发，对深度学习技术在频谱的应用进行介绍，并且从频谱感知认知、频谱智能决策、频谱决策执行等方面，就深度学习技术在频谱管控领域的发展提出了建议。希望本文内容能够帮助频谱管控领域的研究与工程人员了解发展现状，推动频谱管控技术的智能化发展。

参考文献：

[1] Liu C, Wang J, Liu X, et al. Deep CM-CNN for spectrum sensing in cognitive radio[J]. IEEE Journal on Selected Areas in Communications, 2019,37(10): 2306-2321.

[2] Ke D, Huang Z, Wang X, et al. Blind detection techniques for non-cooperative communication signals based on deep learning[J]. IEEE Access, 2019,7: 89218-89225.

[3] Zhang M, Diao M, Guo L. Convolutional neural networks for automatic cognitive radio waveform recognition[J]. IEEE access, 2017,5: 11074-11082.

[4] Zhang J, He Z Q, Rui H, et al. Multiband joint spectrum sensing via covariance matrix-aware convolutional neural network[J]. IEEE Communications Letters, 2022,26(7): 1578-1582.

[5] Prasad K N R S V, Dsouza K B, Bhargava V K, et al. A deep learning framework for blind time-frequency localization in wideband systems[C]//2020 IEEE 91st Vehicular Technology Conference (VTC2020-Spring). IEEE, 2020: 1-6.

[6] Nguyen H N, Vomvas M, Vo-Huu T, et al. Wideband, Real-time Spectro-Temporal RF Identification[C]//Proceedings of the 19th ACM International Sym-posium on Mobility Management and Wireless Access. 2021: 77-86.

[7] O' Shea T J, Corgan J, Clancy T C. Convolutional radio modulation recognition networks[C]//Engineering Applications of Neural Networks: 17th Interna-tional Conference, EANN 2016, Aberdeen, UK, September 2-5, 2016, Proceedings 17. Springer International Publishing, 2016: 213-226.

[8] Yashashwi K, Sethi A, Chaporkar P. A learnable distortion correction module for modulation recognition[J]. IEEE Wireless Communications Letters, 2018,8(1): 77-80.

[9] Huang L, Pan W, Zhang Y, et al. Data augmentation for deep learning-based radio modulation classification[J]. IEEE access, 2019,8: 1498-1506.

[10] Kulin M, Kazaz T, Moerman I, et al. End-to-end learning from spectrum data: A deep learning approach for wireless signal identification in spectrum monitoring applications[J]. IEEE access, 2018,6: 18484-18501.

[11] Vagollari A, Schram V, Wicke W, et al. Joint detection and classification of RF signals using deep learning[C]//2021 IEEE 93rd Vehicular Technology Conference (VTC2021-Spring). IEEE, 2021: 1-7.

[12] Peng S, Jiang H, Wang H, et al. Modulation classification using convolutional neural network based deep learning model[C]//2017 26th Wireless and Optical Communication Conference (WOCC). IEEE, 2017: 1-5.

[13] Lee J H, Kim K Y, Shin Y. Feature image-based automatic modulation classification method using CNN algorithm[C]//2019 International Conference on Artificial Intelligence in Information and Communication (ICAIIC). IEEE, 2019: 1-4.

[14] Dai A, Zhang H, Sun H. Automatic modulation classification using stacked sparse auto-encoders[C]//2016 IEEE 13th international conference on signal processing (ICSP). IEEE, 2016: 248-252.

[15] Mendis G J, Wei J, Madanayake A. Deep learning-based automated modulation classification for cognitive radio[C]//2016 IEEE International Conference on Communication Systems (ICCS). IEEE, 2016: 1-6.

[16] TEGANYA Y, ROMERO D. Data-Driven Spectrum Cartography via Deep Completion Autoencoders[C]//ICC 2020-2020 IEEE International Conference on Communications(ICC). Dublin: IEEE, 2020: 1-7.

[17] 江金生 . 基于卷积自编码器的反射地震数据去噪和插值方法研究 [D]. 浙江 : 浙江大学 , 2020.

[18] HASHIMOTO R, SUTO K. SICNN: Spatial Interp olation with Convolutional Neural Networks for Radio Environment Mapping[C]//Proceedings of 2020 International Conference on Artificial Intelligence in Infor-mation and Communication(ICAIIC). IEEE, 2020: 167-170.

[19] LEVIE R, YPAR Ç, KUTYNIOK G, et al. RadioUNet: Fast Radio Map Estimation With Convolutional Neural Networks[J]. IEEE Transactions on Wireless Communications, 2021,20(6): 4001-4015.

[20] LI Z, CAO J N, WANG H W, et al. Sparsely Self-Supervised Generative Adversarial Nets for Radio Frequency Estimation[J]. IEEE Journal on Selected Areas in Communications, 2019,37(11): 2428-2442.

[21] Xie J, Liu C, Liang Y C, et al. Activity pattern aware spectrum sensing: A CNN-based deep learning approach[J]. IEEE Communications Letters, 2019,23(6): 1025-1028.

[22] Ke D, Huang Z, Wang X, et al. Blind detection techniques for non-cooperative communication signals based on deep learning[J]. IEEE Access, 2019,7: 89218-89225.

[23] Robyns P, Marin E, Lamotte W, et al. Physical-layer fingerprinting of LoRa devices using supervised and zero-

中国知网 https://www.cnki.net

shot learning[C]//Proc.ACM Conf.Secur.Privacy Wireless Mobile Netw.(WiSec), Boston, MA, USA, 2017: 58-63.

[24] Merchant K, Revay S, Stantchev G, et al. Deep learning for RF device fingerprinting in cognitive communication networks[J].IEEE J.Sel.Topics Signal Process.,2018,12(1):160-167.

[25] Gopalakrishnan S, Cekic M, Madhow U. Robust wireless fingerprinting via complex-valued neural networks[C]//2019 IEEE Global Communications Conference (GLOBECOM). IEEE, 2019: 1-6.

[26] Zong L, Xu C, Yuan H L. A rf fingerprint recognition method based on deeply convolutional neural network[C]//2020 IEEE 5th Information Technology and Mechatronics Engineering Conference (ITOEC). IEEE, 2020: 1778-1781.

[27] Baldini G, Giuliani R, Dimc F. Physical layer authentication of Internet of Things wireless devices using convolu-tional neural networks and recurrence plots[J]. Internet Technol. Lett., 2019,2(2): e81.

[28] Peng L, Zhang J, Liu M, et al. Deep learning based RF fingerprint identification using differential constellation trace figure[J]. IEEE Transactions on Ve-hicular Technology, 2019,69(1): 1091-1095.

[29] 潘一苇，杨司韩，彭华，等．基于矢量图的特定辐射源识别方法 [J]. 电子与信息学报，2020,42(4): 941-949.

[30] ZHOU H J, YANG L F, WU Z L, et al. Feasibility analysis of tactical radio station communication behaviors cognition[C]//Proceedings of the Asia-Pacific Conference on Communications Technology and Computer Sci-ence(ACCTCS). Shenyang, China:[s.n.], 2021: 22-24.

[31] QIN Z J, ZHOU X W, ZHANG L, et al. 20 years of evolution from cognitive to intelligent communica-tions[J]. IEEE Transactions on Cognitive Communications and Networking, 2020,6(1): 6-20.

[32] WU Z L, CHEN H, LEI Y K, et al. Recognizing automatic link establishment behaviors of a short-wave radio station by an improved unidimensional DenseNet[J]. IEEE Access, 2020,8: 96055-96064.

[33] WU Z L, CHEN H, LEI Y K. Recognizing non-collaborative radio station communication behaviors using an ameliorated LeNet[J]. Sensors, 2020,20(15): 4320.

[34] WU Z L,CHEN H, LEI Y K. Unidimensional ACGAN applied to link establishment behaviors recognition of a short-wave radio station[J]. Sensors, 2020,20(15): 4270.

[35] LIN F D, CHEN J, DING G R, et al. Spectrum prediction based on GAN and deep transfer learning: A cross-band data augmentation framework[J]. China Communications, 2021,18(1): 18-32.

[36] PAN T, WU X, YAO C, et al. Communication behavior structure mining based on electromagnetic spectrum analysis[C]//Proceedings of the 8th IEEE Joint International Information Technology and Artificial Intelligence Confer-ence(ITAIC). Chongqing,China: IEEE, 2019: 1611-1616.

[37] LIU C K, WU X R, ZHU L, et al. The communication relationship discovery based on the spectrum monitoring data by improved DBSCAN[J]. IEEE Access, 2019,7: 121793-121804.

[38] LIU C K,WU X R,ZHU L, et al. Research on communication network structure mining based on spectrum monitoring data[J]. IEEE Access, 2020,8: 3945-3959.

[39] 张海波，姚昌华，王磊，等．基于频谱数据端到端的电台通联关系研究 [J]. 通信技术，2020,53(11): 2745-2748.

[40] MASONTA M T, MZYECE M, NTLATLAPA N, et al. Spectrum deci-sion in cognitive radio networks:A survey [J].IEEE Communications Surveys and Tutorials,2013, 15(3): 1088-1107

[41] Ahmed K I, Tabassum H, Hossain E. Deep learning for radio resource allocation in multi-cell networks[J]. IEEE Network, 2019,33(6): 188-195.

[42] Lee W. Resource allocation for multi-channel underlay cognitive radio network based on deep neural network[J]. IEEE Communications Letters, 2018,22(9): 1942-1945.

[43] XIAO L, LI Y, DAI C, et al. Reinforcement learning-based NOMA power allocation in the presence of smart jamming[J].IEEE Transac-tions on Vehicular Technolo-gy, 2018,67(4): 3377-3389

[44] HAN G, XIAO L, POOR H V, et al. Two-dimensional anti-jamming communication based on deep reinforcement learning[C] // 2017IEEE International Conference on Acoustics, Speech and Signal Pro-cessing(ICASSP). Piscataway: IEEE Press, 2017: 2087-2091

[45] YAO F, JIA L. A collaborative multi-agent reinforcement learning anti-jamming algorithm in wireless networks[J]. IEEE Wireless Commu-nications Letters, 2019,8(4): 1024-1027.

[46] Sadeghi M, Larsson E G. Adversarial attacks on deep-learning based radio signal classification[J]. IEEE Wireless Communications Letters, 2018,8(1): 213-216. ★

作者简介

张有志：硕士，现为某项目中心高级工程师，研究方向为通信与信息系统。

中国知网 https://www.cnki.net